




گروه پژوهشی ایک



دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی برق - گروه مهندسی کنترل

یادگیری ماشین

مینی پروژه سوم

نام و نام خانوادگی	امیر جهانگرد علیرضا امیری
شماره دانشجویی	۴۰۲۰۲۴۱۴۱۴۰۳۱۵۳۸۴
تاریخ	خرداد ماه ۱۴۰۴



فهرست مطالب

۲	۱.SVM	۱
۲	۱.۱	۱.۱
۳	۲.۱	۲.۱
۳	۱.۲.۱	۱.۲.۱
۴	۲.۲.۱	۲.۲.۱
۵	۳.۲.۱	۳.۲.۱
۶	۴.۲.۱	۴.۲.۱
۶	۵.۲.۱	۵.۲.۱
۸	۶.۲.۱	۶.۲.۱
۸	۷.۲.۱	۷.۲.۱
۲۲	۸.۲.۱	۸.۲.۱
۲۳	۹.۲.۱	۹.۲.۱
۲۴	۱۰.۲.۱	۱۰.۲.۱
۲۵	۱۱.۲.۱	۱۱.۲.۱
۲۵	۱۲.۲.۱	۱۲.۲.۱
۳۳	۱۳.۲.۱	۱۳.۲.۱
۳۴	۱۴.۲.۱	۱۴.۲.۱
۳۶	۱۵.۲.۱	۱۵.۲.۱
۳۶	۳.۱	۳.۱
۳۶	۱.۳.۱	۱.۳.۱
۳۷	۲.۳.۱	۲.۳.۱
۳۸	۳.۳.۱	۳.۳.۱
۳۹	۴.۳.۱	۴.۳.۱
۴۱	۵.۳.۱	۵.۳.۱
۴۳	کاهش ابعاد	۲
۴۳	۱.۲	سوالات
۴۳	۱.۱.۲	الف
۴۴	۲.۱.۲	ب
۴۵	۳.۱.۲	ج
۴۶	۴.۱.۲	د
۴۷	۵.۱.۲	ه
۴۸	۶.۱.۲	و
۴۹	۷.۱.۲	ز
۵۰	۲.۲	امتیازی

۱. SVM

برای مشاهده نوت‌بوک من اینجا کلیک کنید: [لینک گوگل کولب](#)

۱.۱ ۱.۱

در این بخش به توضیح فرایند حل یک مسئله ی SVM با قید سخت (Hard Margin) خواهیم پرداخت. به طور کلی، این مسئله به صورت یک فرایند بهینه سازی به شرح زیر تعریف می شود:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{to subject} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 \quad \forall i \end{aligned}$$

که در آن، $\mathbf{w}$ بردار های وزن، b مقادیر بایاس، y برچسب ها و $\mathbf{x}$ بردار ورودی است. برای یافتن مقدار بهینه ی این سوال، از دوگان روابط بالا استفاده می شود و به جای حل مسئله ی کمینه سازی، این مسئله را به صورت بیشینه سازی به صورت زیر تعریف می کنیم.

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{to subject} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \\ & \alpha_i \geq 0 \quad \forall i \end{aligned}$$

حال برای استفاده در کد بهینه سازی و تبدیل این معادلات به فرمت ماتریسی، در نهایت خواهیم داشت:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \alpha^\top P \alpha + \mathbf{q}^\top \alpha \\ \text{to subject} \quad & G \alpha \leq \mathbf{h}, \\ & A \alpha = b \end{aligned}$$

که در آن:

$$P = (y_i y_j) (\mathbf{x}_i^\top \mathbf{x}_j)$$

$$\mathbf{q} = -\mathbf{1}$$


$$G = -I$$

$$\mathbf{h} = \mathbf{0}$$

$$A = y^\top$$

$$b = 0$$

در شکل [شکل ۱](#) صفحه ی به دست آمده برای این مسئله نمایش داده شده است.



شکل ۱: نمایش svm

که در آن پارامتر های صفحه به صورت زیر خواهند بود:

$$\mathbf{w} = \begin{bmatrix} -0.499956384 \\ -0.000174464249 \\ 1.0 \end{bmatrix}, \quad b = -1.4998865982379106$$

۲.۱ ۲.۱

۱.۲.۱ ۱.۲.۱

در این بخش، دیتاست معیار آلودگی هوای پکن را دانلود کرده و پس از ذخیره ی آن به عنوان یک دیتافریم، پند سطر ابتدای آن را مشاهده می کنیم.

	No	year	month	day	hour	pm2.5	DEWP	TEMP	PRES	cbwd	lws	ls	lr
0	1	2010	1	1	0	NaN	-21	-11.0	1021.0	NW	1.79	0	0
1	2	2010	1	1	1	NaN	-21	-12.0	1020.0	NW	4.92	0	0
2	3	2010	1	1	2	NaN	-21	-11.0	1019.0	NW	6.71	0	0
3	4	2010	1	1	3	NaN	-21	-14.0	1019.0	NW	9.84	0	0
4	5	2010	1	1	4	NaN	-20	-12.0	1018.0	NW	12.97	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...
95	96	2010	1	4	23	31.0	-26	-15.0	1035.0	NW	198.45	0	0
96	97	2010	1	5	0	30.0	-26	-17.0	1035.0	NW	201.58	0	0
97	98	2010	1	5	1	34.0	-26	-18.0	1035.0	NW	205.60	0	0
98	99	2010	1	5	2	27.0	-26	-19.0	1035.0	NW	208.73	0	0
99	100	2010	1	5	3	25.0	-27	-18.0	1035.0	NW	213.65	0	0

100 rows × 13 columns

شکل ۲: سطر های اول دیتاست خام

با بررسی ویژگی های موجود در این دیتافریم به شرح زیر خواهیم داشت:

Description	Type	Feature
modeling) for necessary (not index Row	Integer	No
(۲۰۱۴ to ۲۰۱۰) observation of Year	Integer	year
(۱۲-۱) Month	Integer	month
(۳۱-۱) month the of Day	Integer	day
(۲۳-۰) day the of Hour	Integer	hour
pol- for variable (target ۲ micrograms/m in concentration PM۲.۵	Float	pm۲.۵
lution)		
(°C) Point Dew	Float	DEWP
(°C) Temperature	Float	TEMP
(hPa) pressure Atmospheric	Float	PRES
'cv' 'SE' , 'NE' , 'NW' , (e.g., direction wind Combined	Categorical	cbwd
(m/s) speed wind Cumulated	Float	Iws
snow of hours Cumulated	Float	Is
rain of hours Cumulated	Float	Ir

جدول ۱: Description of the features in the PM۲.۵ dataset

با این ویژگی ها؛ مشاهده می کنیم که مقدار pm۲.۵ به طور مشخص معیار اندازه گیری شده از آلودگی هوا است و در این پژوهش، به عنوان هدف در نظر گرفته می شود. به غیر از این ستون، ویژگی های زمانی مانند سال و ماه و روز، یا ویژگی های جوی مانند فشار، دمای شبی و دمای هوا، ویژگی های مربوط بهخ رطوبت هوا از جمله باران و برف، و ویژگی های مربوط به جهت باد هر یک می توانند تاثیر به سزایی در تشخیص آلودگی داشته باشند.


۲.۲.۱ ۲.۲.۱

در اینجا، به بررسی ساختار و داده های موجود در دیتافریم حاضر خواهیم پرداخت. ابتدا وجود داده های NaN را بررسی می کنیم. همان طور که در شکل ۳ مشاهده می شود، تنها مقادیر هدف برای تعدادی از داده ها مجهول هستند که در ادامه باید رفع شوند. [


حال به بررسی توزیع داده ها خواهیم پرداخت.

و برای بررسی داده همبستگی داده ها، ماتریس همبستگی را رسم می کنیم.

می توان نتیجه گرفت که دیتافریم موجود دارای ستون هایی برای مقادیر زمانی است که به طور مستقیم ویژگی نیستند و باید از آنها ویژگی استخراج شود. علاوه بر این، توزیع داده های pm۲.۵ نشان می دهد که بیشتر داده ها در سمت آلودگی کمتر قرار دارند اما طولانی بودن انتهای این توزیع نشان دهنده ی وجود مقداری با آلودگی های زیاد نیز هست. که این نشان دهنده ی نیاز به تقسیم بازه های این ویژگی و binning است. علاوه بر این، در نظر گرفتن outlier ها در اینجا اهمیت پیدا می کند.




شکل ۳: بررسی داده های Nan



شکل ۴: توزیع داده های عددی دیتافریم

۳.۲.۱ ۳.۲.۱

حال در اینجا به کنترل وضعیت داده های NaN خواهیم پرداخت. چنان که بیان شد، تنها تعدادی از داده های $pm_{2.5}$ مجهول هستند و از آنجا که این مقادیر خود هدف مسئله هستند، نمی توان برای آنها داده هایی را درون یابی کرد، چرا که این امر به معنی وارد کردن داده های نامطمئن به دیتاست خواهد بود. با این حال، از آنجا که داده ها در این دیتافریم وابستگی زمانی دارند و در ادامه ی فرایند لازم است از داده های گذشته برای تعیین ویژگی های داده های آینده استفاده شود، حذف این سطر ها در ادامه به بروز مشکلاتی منجر می شود. بنابراین، با در نظر داشتن این مورد که در نهایت این



شکل ۵: توزیع داده های دسته بندی دیتافریم


سطرها باید حذف شوند، فعلا آنها را نگه می داریم تا ابتدا فرایند استخراج ویژگی های زمانی انجام شود و سپس این داده ها را حذف می کنیم. در اینجا، ویژگی های زمانی مربوط به مقادیر گذشته ی ۲.۵pm در ۱، ۲، ۳، ۴ و ۱۶ ساعت گذشته را برای هر داده به دست می آوریم. پس از استخراج این ویژگی ها، می توانیم سطرهایی که مقادیر گذشته ی آنها وجود ندارد و همچنین سطرهایی که مقدار هدف آنها NAN است را حذف کنیم.

۴.۲.۱ ۴.۲.۱

در این بخش، به بررسی داده های دسته بندی خواهیم پرداخت. مشاهده می کنیم که تنها ستون با این نوع داده، مربوط به جهت باد است که دسته بندی های آن در **شکل ۵** نمایش داده شده است. برای تبدیل این داده های این ستون به مقادیر عددی، از روش *OneHotEncoding* استفاده شده است و در نتیجه، چهار ستون به جای آن تعریف می شود؟؟

۵.۲.۱ ۵.۲.۱

در این بخش به بررسی داده های پرت خواهیم پرداخت. می دانیم که وجود این مقادیر در دیاست، می تواند مدل را به دلیل وجود تعداد کمی داده ی پرت، از یادگیری بخش غالب داده ها منحرف کند. این مقادیر به دلیل آنکه مقدار بسیار بیشتر و یا کمتری دارند، تاثیر بیشتری بر وزن های سیستم خواهند داشت و در نتیجه بسیار مهم است که بتوانیم آنها را مدیریت کنیم. برای این منظور، در دیتاست حاضر، توزیع ویژگی هایی که مقادیر عددی دارند را به صورت *boxPlot* رسم می کنیم



شکل ۶: ماتریس همبستگی

```
pm2.5_lag3      2070
pm2.5_lag24     2091
pm2.5_lag168    2235
pm2.5_lag1      2068
pm2.5_lag2      2069
dtype: int64
```

شکل ۷: ۷

همان طور که مشاهده می شود، در ستون های lws و pm2.5 داده های پرت وجود دارد. مجدداً با توجه به اینکه داده های موجود در pm2.5 مقادیر هدف هستند، نمی توان آنها را تغییر داد و یا حذف کرد. اما برای ستون lws ابتدا توزیع آن را مشاهده می کنیم.


در شکل ۱۱ توزیع داده های lws را مشاهده می کنیم. برای رفع مشکل داده های پرت در این ستون، از روش capping استفاده می کنیم. به همین صورت که مقادیر بیشتر از ۹۹ درصد داده ها برابر با بیشترین داده در این بازه و مقادیر کمتر از ۱ درصد داده ها برابر با کمترین داده در این بازه


```
Rows with NaN in 'pm2.5': 2067
Total rows: 43824
Percentage to be dropped: 4.72%
```

شکل ۸: میزان داده های NaN

cbwd_NE	cbwd_NW	cbwd_SE	cbwd_cv
0	0	0	1
0	1	0	0
0	1	0	0
0	1	0	0
0	1	0	0

شکل ۹: encoding hot One



شکل ۱۰: توزیع ویژگی های عددی برای پیدا کردن داده های پرت

تعیین می شود.


در نتیجه، توزیع داده ها پس از اعمال این تغییرات به صورت زیر خواهد بود.

۶.۲.۱ ۶.۲.۱


هدف از پیاده سازی این بخش، تقسیم داده ها به مقادیر دسته بندی به جای مقادیر عددی است. برای این منظور، مطابق جدول زیر داده ها را تقسیم می کنیم. پس از این تقسیم، توزیع داده ها به صورت زیر به دست خواهد آمد.

۷.۲.۱ ۷.۲.۱

مطابق با خواسته ی سوال، در این بخش لازم است ویژگی های Lag بر اساس داده های قبلی استخراج شوند. اما به دلیل آنکه قصد داشتیم داده های NaN را حذف کنیم، پیش از این موارد را اضافه کنیم. در اختیار داشتن داده های قبلی، می تواند اطلاعاتی از روند تغییرات را به مدل آموزش دهد و معیار تصمیم گیری آن را نه تنها بر اساس داده های فعلی، که بر اساس داده های قبلی تعیین کند. با این حال، در داده های ابتدایی که به این تعداد



شکل ۱۱: توزیع داده های lws



شکل ۱۲: توزیع داده ها پس از حذف داده های پرت


از داده های قبل در اختیار نداریم، مقادیر NAN باقی خواهد ماند. به دلیل آنکه به این تعداد از داده های قبل را در اختیار نداریم، نمی توانیم این داده ها را نگه داریم و ناچار به حذف آن خواهیم بود.

حال به رسم نمودار این داده های با تاخیر خواهیم پرداخت. **شکل ۱۵**

سپس، میزان همبستگی این مقادیر را با مقدار لحظه ای رسم می کنیم. چنان که انتظار می رود، همبستگی این داده ها با داده های نزدیک بسیار

Category AQI	PM _{2.5} Range (μg/m ³)
Good	۰.۱۲ - ۰.۰
Moderate	۴.۳۵ - ۱.۱۲
Groups Sensitive for Unhealthy	۴.۵۵ - ۵.۳۵
Unhealthy	۴.۱۵۰ - ۵.۵۵
Unhealthy Very	۴.۲۵۰ - ۵.۱۵۰
Hazardous	۵۰۰ - ۵.۲۵۰
Extreme	۵۰۰ <

جدول ۲: Concentration PM_{2.5} on Based Categories AQI



شکل ۱۳: توزیع داده ها پس از دسته بندی مقدار هدف

بیشتر است و روند آن با داده های قدیمی تر کمتر می شود.

حال به ایجاد ویژگی های Rolling و آماری بر روی داده ها خواهیم پرداخت. این ویژگی ها به صورت زیر خواهند بود و بر اساس داده های ۲۴ ساعت گذشته تعریف می شوند.

• PM_{2.5} of mean rolling ۲۴-hour - pm2.5_roll_mean_24h

• PM_{2.5} of deviation standard rolling ۲۴-hour - pm2.5_roll_std_24h

• PM_{2.5} of variance rolling ۲۴-hour - pm2.5_roll_var_24h


• PM_{2.5} of minimum rolling ۲۴-hour - pm2.5_roll_min_24h

• PM_{2.5} of maximum rolling ۲۴-hour - pm2.5_roll_max_24h


• PM_{2.5} of median rolling ۲۴-hour - pm2.5_roll_median_24h

• PM_{2.5} of skewness rolling ۲۴-hour - pm2.5_roll_skew_24h

• PM_{2.5} of kurtosis rolling ۲۴-hour - pm2.5_roll_kurt_24h




شکل ۱۴: نمودار پای توزیع داده ها




شکل ۱۵: نمودار تغییرات آلودگی هوا با معیار های تاخیردار

به طور طبیعی اگر بخواهیم این فرایند را برای تمام داده ها لحاظ کنیم، در مقادیر اول یا مقدار NAN خواهیم داشت و یا مقادیر ثابت می شوند. اما برای این داده ها در صورتی که پنجره زمانی را انعطاف پذیر در نظر بگیریم و تنها ویژگی های مربوط به داده های قبلی آن را در محاسبه لحاظ کنیم، آنگاه مقادیر ثابت یا NAN باقی نمی ماند.



شکل ۱۶: همبستگی ویژگی‌های زمانی


24-hour Rolling Mean of pm2.5



شکل ۱۷: نمودار میانگین ۲۴ ساعت گذشته

در گام بعد، به انکود کردن ویژگی های تناوبی خواهیم پرداخت. از آنجا که در این دیتافریم معیارهای زمانی مانند ساعت، روز، هفته، ماه و فصل و سال وجود دارد، و اتفاقات موجود به صورت تکرار شونده در این بازه ها رخ می دهند، بنابراین در نظر داشتن این تناوب اهمیت زیادی خواهد داشت.

با استفاده از تبدیل فوریه، مقادیر تناوبی را به دست می آوریم.



شکل ۱۸: فرکانس های غالب داده ها

```
Dominant Frequency 1: 0.003175 (Period: 314.95 hours)
Dominant Frequency 2: 0.004268 (Period: 234.29 hours)
Dominant Frequency 3: 0.000338 (Period: 2955.69 hours)
Dominant Frequency 4: 0.000104 (Period: 9606.00 hours)
Dominant Frequency 5: 0.000130 (Period: 7684.80 hours)
```


شکل ۱۹: دامنه ها

کد ارائه شده از تبدیل فوریه (FFT) برای تحلیل طیف فرکانسی داده های $PM_{2.5}$ استفاده کرده است. در مرحله اول، مقادیر $PM_{2.5}$ از دیتاست استخراج و مقادیر گمشده (NaN) حذف شده اند. سپس با استفاده از تابع `fft` از کتابخانه `scipy`، طیف فرکانسی محاسبه شده و تنها فرکانس های مثبت برای تحلیل حفظ شده اند. در نهایت، نمودار دامنه برحسب فرکانس (با واحد $1/\text{hour}$ رسم شده و ۵ فرکانس غالب با بیشترین دامنه شناسایی شده اند. اگرچه این کد مستقیماً به انکودینگ ویژگی های تناوبی نپرداخته، اما نتایج آن می تواند برای شناسایی الگوهای زمانی تکرار شونده در داده های $PM_{2.5}$ مفید باشد.

نتایج تحلیل FFT نشان می دهد که بالاترین دامنه مربوط به فرکانس $0.003175 (1/\text{hour})$ با دوره تناوب 95.314 ساعت (۱۳ روز) است که احتمالاً نشان دهنده الگوی فصلی در آلودگی هوا می باشد. نمودار طیف فرکانسی تأیید می کند که بیشترین انرژی سیگنال در فرکانس های پایین متمرکز است، که نشان دهنده تغییرات بلندمدت در داده های $PM_{2.5}$ است. این یافته ها می توانند به طراحی ویژگی های تناوبی هوشمند برای بهبود مدل های پیش بینی کمک کنند، هرچند برای نتیجه گیری دقیق تر نیاز به بررسی بیشتر وجود دارد.

در ادامه کد ارائه شده یک هیت مپ (نقشه حرارتی) برای نمایش میانگین غلظت ذرات $PM_{2.5}$ بر اساس ساعات روز و ماه های سال ایجاد کرده است. در این کد، ابتدا با استفاده از تابع `groupby`، داده ها بر اساس ماه و ساعت گروه بندی شده و میانگین $PM_{2.5}$ برای هر ترکیب ماه-ساعت محاسبه شده است. سپس با استفاده از کتابخانه `seaborn` و تابع `heatmap`، این داده ها به صورت یک ماتریس دو بعدی با رنگ بندی `coolwarm` نمایش داده شده اند. محور افقی نشان دهنده ساعات روز (۰ تا ۲۳) و محور عمودی نشان دهنده ماه های سال (۱ تا ۱۲) می باشد.


نتایج هیت مپ نشان می دهد که الگوی تغییرات $PM_{2.5}$ هم به ساعت روز و هم به ماه سال وابسته است. بیشترین غلظت آلودگی در ساعات



شکل ۲۰: نمودار هیت مپ

صبح (معمولاً بین ساعت ۸ تا ۱۰) و همچنین در ماه‌های سرد سال مشاهده می‌شود که احتمالاً به دلیل وارونگی دمایی و افزایش فعالیت‌های انسانی است. در مقابل، کمترین میزان آلودگی در ساعات اولیه صبح (۴ تا ۶) و ماه‌های گرم‌تر دیده می‌شود. این الگوها می‌توانند برای پیش‌بینی بهتر آلودگی هوا و برنامه‌ریزی راهکارهای کاهش آن مورد استفاده قرار گیرند.


در ادامه پروژه، برای بررسی الگوی تغییرات آلودگی هوا، میانگین غلظت ذرات $PM_{2.5}$ بر اساس ساعات روز و سال‌های مختلف محاسبه شده است. در این بخش، داده‌ها ابتدا بر اساس سال و ساعت گروه‌بندی گردیدند و سپس با استفاده از تکنیک نقشه حرارتی، نتایج به صورت گرافیکی نمایش داده شدند. این روش امکان شناسایی الگوهای زمانی را به خوبی فراهم می‌کند، به طوری که محور افقی نشان‌دهنده ساعات شبانه‌روز و محور عمودی سال‌های مورد مطالعه را نمایش می‌دهد.



شکل ۲۱: نمودار هیت مپ ساعت به سال

نتایج حاصل از این تحلیل نشان می‌دهد که توزیع آلودگی هوا در ساعات مختلف روز و سال‌های متفاوت، تغییرات قابل توجهی دارد. در اینجا مشاهده می‌شود که بیشترین غلظت ذرات معلق معمولاً در ساعات میانی روز و همچنین در سال‌های خاصی رخ می‌دهد. این الگوها احتمالاً به عوامل مختلفی از جمله تغییرات آب‌وهوایی، فعالیت‌های انسانی و سیاست‌های محیط زیستی مرتبط هستند. سپس با مقایسه سال‌های مختلف می‌توان روند تغییرات آلودگی هوا را در طول زمان بررسی کرد که برای برنامه‌ریزی‌های آینده بسیار ارزشمند خواهد بود.

در این مرحله از پروژه، به بررسی تغییرات غلظت ذرات $PM_{2.5}$ در طول هفته پرداخته شده است. ابتدا با استخراج روزهای هفته از داده‌های زمانی، میانگین آلودگی برای هر ساعت از روزهای مختلف محاسبه گردید. سپس این اطلاعات به صورت یک نقشه حرارتی سازماندهی شد که در آن محور عمودی نشان‌دهنده روزهای هفته (از دوشنبه تا جمعه) و محور افقی ساعات شبانه‌روز را نمایش می‌دهد. این رویکرد امکان شناسایی الگوهای هفتگی آلودگی هوا را فراهم می‌سازد.




شکل ۲۲: نمودار هیت مپ

نتایج این تحلیل الگوی جالبی از تغییرات آلودگی هوا را نشان می‌دهد. به طور مشخص، روزهای میانی هفته (سه‌شنبه تا پنجشنبه) در ساعات اوج ترافیک صبحگاهی و عصرگاهی، بالاترین غلظت $PM_{2.5}$ را دارند. همچنین مشاهده می‌شود که روزهای پایانی هفته (جمعه) الگوی متفاوتی را نمایش می‌دهند که احتمالاً به دلیل کاهش فعالیت‌های صنعتی و ترافیکی است. این یافته‌ها می‌توانند برای برنامه‌ریزی‌های شهری و مدیریت ترافیک در روزهای مختلف هفته مورد استفاده قرار گیرند.


در ادامه بررسی الگوهای زمانی آلودگی هوا، از روش کدگذاری چرخه‌ای برای ویژگی‌های زمانی شامل ساعت روز، روز هفته و ماه سال استفاده شد. این روش با اعمال توابع سینوسی و کسینوسی بر روی مقادیر زمانی، ماهیت چرخشی آنها را حفظ می‌کند. سپس برای نمایش گرافیکی، میانگین غلظت $PM_{2.5}$ در ساعات مختلف روز بر روی یک نمودار دایره‌ای با تقسیم‌بندی دوره‌های زمانی مختلف (شب، سحرگاه، روز و غروب) ترسیم شد. هر نقطه در این نمودار نشان‌دهنده یک ساعت خاص از روز است که رنگ آن بیانگر میزان آلودگی در آن ساعت می‌باشد.

نتایج این تحلیل الگوی جالبی از تغییرات آلودگی هوا در طول روز را نشان می‌دهد. بیشترین غلظت ذرات معلق در ساعات روز (بین ۸ تا ۱۷) مشاهده می‌شود که همزمان با اوج فعالیت‌های انسانی و ترافیک شهری است. در مقابل، کمترین میزان آلودگی در ساعات شب (۲۰ تا ۵ صبح) ثبت شده است. نکته قابل توجه تفاوت محسوس بین ساعات سحرگاه و غروب است که احتمالاً به عوامل جوی و تغییرات دمایی مربوط می‌شود. این یافته‌ها می‌توانند در برنامه‌ریزی‌های شهری و مدیریت ترافیک مورد استفاده قرار گیرند.




شکل ۲۳: نمودار انکودینگ چرخه ای در ساعت

در این بخش از تحلیل، الگوی تغییرات فصلی غلظت ذرات $PM_{2.5}$ با استفاده از روش کدگذاری چرخه ای ماهانه مورد بررسی قرار گرفته است. ابتدا میانگین ماهانه آلودگی هوا محاسبه شده و سپس با اعمال تبدیلات سینوسی و کسینوسی، ماهیت چرخشی فصول حفظ گردیده است. برای نمایش بصری، یک نمودار دایره ای طراحی شده که در آن هر نقطه نشان دهنده یک ماه خاص بوده و رنگ آن بیانگر میزان متوسط آلودگی در آن ماه می باشد. همچنین مناطق مختلف نمودار با رنگ های متمایز برای فصول چهارگانه سال (زمستان، بهار، تابستان و پاییز) مشخص شده اند. نتایج این تحلیل نشان می دهد که الگوی تغییرات آلودگی هوا از توزیع فصلی مشخصی پیروی می کند. بیشترین غلظت ذرات معلق در ماه های زمستان (دی، بهمن و اسفند) مشاهده می شود که احتمالاً ناشی از پدیده وارونگی دمایی و افزایش مصرف سوخت های فسیلی است. در مقابل، کمترین میزان آلودگی در ماه های تابستان (خرداد تا شهریور) ثبت شده که با بهبود شرایط جوی و کاهش پایداری هوا مرتبط می باشد. نکته جالب توجه، کاهش تدریجی آلودگی از فصل پاییز به زمستان و سپس افزایش ناگهانی آن در اواسط زمستان است که می تواند نشان دهنده تأثیر همزمان عوامل جوی و انسانی باشد.



شکل ۲۴: نمودار انکودینگ چرخه ای در ماه


در این بخش از پژوهش، الگوی هفتگی تغییرات آلودگی هوا با استفاده از کدگذاری چرخه ای روزهای هفته مورد بررسی قرار گرفته است. ابتدا میانگین غلظت $PM_{2.5}$ برای هر روز هفته محاسبه شده و سپس با تبدیل سینوسی-کسینوسی، ماهیت تناوبی هفته حفظ گردیده است. نمودار دایره ای طراحی شده، روزهای هفته را به چهار بخش «تعطیل»، «ابتدای هفته»، «میان هفته» و «پایان هفته» تقسیم کرده که هر بخش با رنگ متمایزی مشخص شده است. هر نقطه در این نمودار نمایانگر یک روز خاص بوده و رنگ آن بیانگر میزان متوسط آلودگی در آن روز می باشد. نتایج تحلیل نشان می دهد که الگوی آلودگی هوا در طول هفته نوسانات معناداری دارد. بیشترین غلظت ذرات معلق در روزهای میانی هفته (سه شنبه تا پنجشنبه) مشاهده می شود که احتمالاً ناشی از فعالیت های صنعتی و ترافیک کاری است. در مقابل، روزهای تعطیل (یکشنبه) کمترین میزان آلودگی را نشان می دهند. نکته جالب توجه، کاهش محسوس آلودگی در روزهای پایانی هفته (جمعه) نسبت به روزهای میانی است که می تواند نشان دهنده کاهش فعالیت های اقتصادی در آستانه تعطیلات باشد. این یافته ها برای برنامه ریزی های مدیریت ترافیک و کنترل آلودگی هوا در روزهای مختلف هفته حائز اهمیت است.



شکل ۲۵: نمودار انکودینگ چرخه ای در هفته


به طور خلاصه در این دیتاست، ویژگی‌های تناوبی متعددی شامل ساعت روز، روز هفته و ماه سال وجود دارد که به دلیل ماهیت چرخشی شان نیاز به کدگذاری ویژه دارند. برای انکودینگ این ویژگی‌ها از روش سینوسی-کسینوسی استفاده شده است، چرا که این روش با تبدیل مقادیر خطی به مختصات دایره‌ای، فاصله‌ی معنادار بین مقادیر انتهایی (مثلاً ساعت ۲۳ و ۰) را حفظ می‌کند و از ایجاد ناپوستگی در داده‌ها جلوگیری می‌نماید. در این تحلیل، ویژگی ساعت روز با این روش کدگذاری شده و نتایج آن در قالب یک نمودار اسکاتر دایره‌ای نمایش داده شده است. این نمودار به وضوح نشان می‌دهد که بیشترین غلظت $PM_{2.5}$ در ساعات میانی روز (بین ۱۰ تا ۱۷) رخ می‌دهد که با ساعات اوج فعالیت‌های انسانی و ترافیکی همخوانی دارد. همچنین با بررسی توزیع نقاط بر روی نمودار می‌توان الگوهای تکرارشونده‌ی را شناسایی کرد که نشان‌دهنده‌ی افزایش متناوب آلودگی در ساعات خاصی از روز هستند. این یافته‌ها اهمیت در نظر گرفتن ویژگی‌های تناوبی در مدل‌سازی را نشان می‌دهد، چرا که به مدل کمک می‌کند تا الگوهای زمانی پیچیده‌ی موجود در داده‌ها را بهتر درک و پیش‌بینی کند.

در بخش تحلیل ویژگی‌های زمانی پیشرفته، الگوی فصلی تغییرات آلودگی هوا با دقت بیشتری مورد بررسی قرار گرفته است. ابتدا با تخصیص ماه‌ها به چهار فصل (زمستان، بهار، تابستان و پاییز) و کدگذاری عددی آنها، از تبدیل سینوسی-کسینوسی با دوره تناوب ۴ استفاده شد تا ماهیت چرخشی فصول حفظ شود. نتایج حاصل از نمودار دایره‌ای نشان می‌دهد که بیشترین غلظت $PM_{2.5}$ در فصل زمستان (رنگ بنفش تیره) و کمترین میزان در فصل تابستان (رنگ زرد) مشاهده می‌شود. این الگو به وضوح تأثیر پدیده‌های جوی مانند وارونگی دمایی در زمستان و نیز افزایش بارش‌های تابستانی را در کاهش آلودگی هوا نشان می‌دهد. نکته قابل توجه، توزیع متقارن مقادیر آلودگی در چهار ربع دایره است که بیانگر تفاوت معنادار غلظت ذرات معلق در فصول مختلف می‌باشد. این یافته‌ها برای پیش‌بینی‌های فصلی آلودگی هوا و برنامه‌ریزی‌های مدیریت محیط زیست حائز اهمیت است.




شکل ۲۶: نمودار انکودینگ چرخه ای در فصول سال

نمودار همبستگی ارائه شده، روابط بین متغیرهای مختلف با غلظت ذرات $PM_{2.5}$ را به صورت کمی نشان می‌دهد. بر اساس این تحلیل، متغیر دما (TEMP) با ضریب همبستگی -0.83 بیشترین ارتباط معکوس را با $PM_{2.5}$ دارد که نشان‌دهنده کاهش آلودگی هوا با افزایش دماست. از سوی دیگر، فشار هوا (PRES) با ضریب 0.75 همبستگی مثبت نشان می‌دهد که احتمالاً به دلیل ارتباط آن با پدیده وارونگی دمایی است. نکته جالب توجه همبستگی نسبتاً قوی متغیر IWS (سرعت باد) با مقدار -0.75 است که تأثیر پاک‌کنندگی باد بر آلودگی هوا را تأیید می‌کند. این یافته‌ها برای مدل‌سازی پیش‌بینی کیفیت هوا حائز اهمیت بوده و نشان می‌دهد که پارامترهای جوی می‌توانند به عنوان شاخص‌های خوبی برای پیش‌بینی آلودگی هوا مورد استفاده قرار گیرند.




شکل ۲۷: نمودار هیت مپ همبستگی مربوطه

تحلیل نمودار جعبه‌ای نشان می‌دهد که جهت باد تأثیر معناداری بر غلظت ذرات معلق دارد. بادهای شمال شرقی (NE) بالاترین میانگین $PM_{2.5}$ را نشان می‌دهند که احتمالاً ناشی از انتقال آلاینده‌ها از مناطق صنعتی است. در مقابل، بادهای جنوب شرقی (SE) کمترین میزان آلودگی را دارند که می‌تواند به دلیل منشأ دریایی این بادهای باشد. حالت بدون باد مشخص (CV) نیز غلظت بالایی از ذرات را نشان می‌دهد که تأییدکننده نقش تهویه طبیعی در کاهش آلودگی است. دامنه تغییرات گسترده در بادهای شمال غربی (NW) نشان‌دهنده نوسانات زیاد آلودگی در این جهت باد است. این یافته‌ها اهمیت جهت باد را به عنوان یک ویژگی کلیدی در مدل‌های پیش‌بینی کیفیت هوا برجسته می‌سازد. با توجه به نتایج، می‌توان سیستم‌های هشدار آلودگی را با در نظر گرفتن الگوهای باد طراحی کرد. همچنین این تحلیل می‌تواند به شناسایی منابع آلاینده کمک کند، چرا که جهت‌های باد با آلودگی بالا احتمالاً به سمت مناطق صنعتی یا پرترافیک اشاره دارند. نتایج این بخش می‌تواند مبنای علمی برای برنامه‌ریزی‌های شهری و تعیین جهت توسعه آینده شهر قرار گیرد.



شکل ۲۸: نمودار جهت باد

تحلیل نمودار ویولن نشان‌دهنده توزیع غلظت $PM_{2.5}$ در جهت‌های مختلف باد است که اطلاعات جامع‌تری نسبت به نمودار جعبه‌ای ارائه می‌دهد. در این تحلیل مشاهده می‌شود که توزیع آلودگی در شرایط بدون باد (CV) به شکل دو قلوئی مشخصی ظاهر شده که نشان‌دهنده دو حالت متمایز آلودگی در این شرایط است. بادهای شمال شرقی (NE) نه تنها میانگین بالاتری دارند، بلکه دارای دنباله بلندی در مقادیر بالا هستند که حاکی از وقوع دوره‌های شدید آلودگی در این جهت باد است. در مقابل، بادهای جنوب شرقی (SE) دارای توزیع فشرده‌تری هستند که نشان‌دهنده ثبات بیشتر در کیفیت هوا است. این یافته‌ها اهمیت در نظر گرفتن هم میانگین و هم پراکندگی داده‌ها را در تحلیل‌های کیفیت هوا نشان می‌دهد و می‌تواند به شناسایی شرایط بحرانی آلودگی هوا کمک شایانی کند.




شکل ۲۹: نمودار ویولین

نمودارهای وابستگی جزئی (PDP) تأثیر غیرخطی متغیرهای محیطی بر غلظت $PM_{2.5}$ را به خوبی نشان می‌دهند. در مورد سرعت باد، (IWS)

رابطه کاهشی آشکاری دیده می شود که نشان می دهد افزایش سرعت باد به کاهش آلودگی منجر می شود، با شیب تند در محدوده سرعت های پایین (۰-۵۰) که حاکی از اثرگذاری بیشتر باد در سرعت های متوسط است. برای دما، (TEMP) یک رابطه U شکل معکوس مشاهده می شود که نشان دهنده بیشترین آلودگی در دماهای بسیار پایین (پدیده وارونگی دما) و بسیار بالا (افزایش واکنش های فتوشیمیایی) است. فشار هوا (PRES) نیز رابطه مثبت با آلودگی نشان می دهد، به طوری که در فشارهای بالای ۱۰۲۰ هکتوپاسکال، افزایش فشار منجر به رشد قابل توجه غلظت $PM_{2.5}$ می شود که احتمالاً به دلیل تثبیت شرایط جوی است. این یافته ها برای مدل سازی دقیق تر روابط پیچیده بین پارامترهای جوی و کیفیت هوا بسیار ارزشمند هستند.

Partial Dependence Plots for Wind, Temp, and Pressure



شکل ۳۰: نمودار تاثیرات فشار هوا، دما و باد


در بخش تحلیل ویژگی های زمانی پیشرفته، ابتدا با ایجاد شاخص فصلی مشخص شد که بیشترین غلظت $PM_{2.5}$ در فصل زمستان (میانگین ۱۲۰ میکروگرم بر مترمکعب) و کمترین میزان در تابستان (میانگین ۸۰ میکروگرم بر مترمکعب) رخ می دهد که علت اصلی آن پدیده وارونگی دمایی و افزایش مصرف سوخت های فسیلی در زمستان است. در بررسی روزهای هفته، روزهای سه شنبه تا پنجشنبه بالاترین آلودگی را نشان دادند که با ترافیک کاری و فعالیت های صنعتی مرتبط است. تحلیل تاثیر پارامترهای جوی نشان داد که افزایش دما (ضریب -۸۳.۰) و سرعت باد (ضریب -۷۵.۰) اثر کاهنده بر آلودگی دارند، در حالی که فشار بالا (ضریب +۷۵.۰) با افزایش آلودگی همراه است. همچنین الگوی ساعتی مشخص کرد که بیشترین غلظت $PM_{2.5}$ در ساعات ۸ تا ۱۷ و کمترین میزان در ساعات ۲۰ تا ۵ صبح رخ می دهد که با الگوی فعالیت های انسانی و شرایط جوی مرتبط است. این یافته ها با استفاده از روش های پیشرفته ای مانند کدگذاری چرخه ای سینوسی-کسینوسی برای ویژگی های زمانی و تحلیل های وابستگی جزئی به دست آمده اند که امکان مدل سازی دقیق تر روابط پیچیده بین زمان و آلودگی هوا را فراهم می کنند.

۸.۲.۱ ۸.۲.۱

در قسمت های قبلی به این بخش پرداخت شده است.


۹.۲.۱ ۹.۲.۱

بررسی توزیع داده‌ها نشان می‌دهد که دیتاست حاضر از نظر دسته‌بندی‌های شاخص کیفیت هوا (AQI) به شدت نامتوازن است. به طوری که دسته «ناسالم» (Unhealthy) با ۱۴۳۸۸ نمونه بیشترین فراوانی و دسته «خطرناک» (Extreme) با تنها ۱۱۷ نمونه کمترین فراوانی را دارد. این عدم توازن به وضوح در نمودار میل‌های نیز مشهود است که در آن دسته‌های مختلف AQI اختلاف فاحشی در تعداد نمونه‌ها نشان می‌دهند. برای متوازن‌سازی این داده‌ها می‌توان از روش‌هایی مانند نمونه‌برداری بیش نمونه (oversampling) برای دسته‌های کم‌نمونه یا نمونه‌برداری کم‌نمونه (undersampling) برای دسته‌های پرتعداد استفاده کرد. همچنین می‌توان از روش‌های ترکیبی مانند SMOTE یا تغییر وزن کلاس‌ها در الگوریتم‌های یادگیری ماشین بهره برد. این متوازن‌سازی برای بهبود عملکرد مدل‌های طبقه‌بندی ضروری است، چرا که مدل‌های آموزش دیده بر داده‌های نامتوازن معمولاً به سمت کلاس‌های پرتعداد سوگیری خواهند داشت.



شکل ۳۱: نمودار توزیع داده‌ها


در این بخش از پروژه، ابتدا توزیع نامتوازن دسته‌های مختلف شاخص کیفیت هوا (AQI) مورد بررسی قرار گرفت که نشان‌دهنده تفاوت فاحش در تعداد نمونه‌های هر دسته بود. برای حل این مشکل، از روش نمونه‌برداری مجدد (resampling) با جایگزینی استفاده شد که در آن تمامی دسته‌ها به تعداد بیشترین دسته موجود (۱۴۳۸۸ نمونه) افزایش یافتند. این فرآیند منجر به ایجاد یک دیتاست متوازن با ۱۰۰۷۱۶ نمونه شد که در آن هر دسته AQI به تعداد مساوی وجود دارد. بررسی ستون‌های دیتاست متوازن شده نشان می‌دهد که تمامی ویژگی‌های اصلی و ویژگی‌های جدید ایجاد شده در مراحل قبلی پروژه حفظ شده‌اند. این متوازن‌سازی برای آموزش مدل‌های یادگیری ماشین ضروری است، چرا که از سوگیری مدل به سمت دسته‌های پرتعداد جلوگیری کرده و به مدل اجازه می‌دهد الگوهای تمامی دسته‌ها را به خوبی یاد بگیرد. نمودار جدید توزیع دسته‌ها به وضوح نشان‌دهنده موفقیت‌آمیز بودن فرآیند متوازن‌سازی است.



شکل ۳۲: نمودار توزیع داده ها که متوازن شده

۱۰.۲.۱ ۱۰.۲.۱

در بخش نرمال سازی داده ها، از روش استاندارد سازی (StandardScaler) استفاده شد که هر ویژگی را با کم کردن میانگین و تقسیم بر انحراف معیار نرمال سازی می کند. این روش به دلایل زیر انتخاب شد: (۱) حفظ ساختار توزیع داده ها، (۲) مناسب برای الگوریتم هایی که به فاصله ها حساس هستند (مانند SVM و KNN)، عملکرد بهتر برای ویژگی هایی که مقیاس های مختلف دارند. پس از نرمال سازی، داده ها در دیتافریم جدیدی به نام X_scaled ذخیره شدند. سپس با استفاده از مدل LightGBM اهمیت ویژگی ها بررسی شد که نتایج نشان داد ویژگی های تأخیری (lag) و آماری (مانند چولگی و کشیدگی) بیشترین اهمیت را در پیش بینی کیفیت هوا دارند. این یافته ها تأیید می کند که نرمال سازی صحیح داده ها می تواند به مدل کمک کند تا روابط پیچیده بین ویژگی ها را بهتر یاد بگیرد.



شکل ۳۳: نمودار مهمترین ویژگی ها

۱۱.۲.۱ ۱۱.۲.۱

طبق خواسته سوال، داده ها را به سه بخش تقسیم کردیم.

۱۲.۲.۱ ۱۲.۲.۱

در این بخش از پروژه، از الگوریتم ماشین بردار پشتیبان (SVM) با سه نوع کرنل مختلف (خطی، چندجمله‌ای و RBF) برای طبقه‌بندی کیفیت هوا بر اساس شاخص AQI استفاده شده است. ابتدا داده‌های متوازن شده به سه بخش آموزش (۷۰٪)، اعتبارسنجی (۱۵٪) و آزمون (۱۵٪) تقسیم شدند. هر سه مدل SVM با تنظیمات پیش فرض ($C=1.0$) آموزش دیدند و عملکرد آنها بر اساس معیارهای دقت، یادآوری و $F1$ -Score برای هر یک از ۷ دسته AQI ارزیابی شد. کرنل RBF با میانگین دقت ۸۲٪ بهترین عملکرد را نشان داد، در حالی که کرنل چندجمله‌ای با دقت ۷۷٪ ضعیف‌ترین نتیجه را داشت. این تفاوت احتمالاً به دلیل توانایی بهتر کرنل RBF در مدل‌سازی مرزهای تصمیم‌گیری غیرخطی پیچیده‌تر است.

نتایج طبقه‌بندی نشان می‌دهد که تمامی مدل‌ها در تشخیص دسته "Extreme" (با دقت ۹۷٪-۹۶٪) بهترین عملکرد را دارند، در حالی که دسته "Moderate" با دقت حدود ۶۷٪-۷۰٪ سخت‌ترین دسته برای طبقه‌بندی بوده است. این موضوع احتمالاً به دلیل همپوشانی بیشتر ویژگی‌های این دسته با دسته‌های مجاور است. همچنین مشاهده می‌شود که مدل‌ها در دسته "Good" تمایل به پیش‌بینی مثبت کاذب بیشتری دارند (یادآوری بالا اما دقت متوسط)، که نشان‌دهنده شباهت نمونه‌های این دسته با دسته‌های با آلودگی بالاتر است.

مقایسه نتایج بین داده‌های آموزش، اعتبارسنجی و آزمون نشان می‌دهد که همه مدل‌ها از مشکل بیش‌برازش (overfitting) قابل توجهی رنج نمی‌برند، چرا که اختلاف دقت بین داده‌های آموزش و آزمون کمتر از ۱٪ است. این نشان‌دهنده تعمیم‌پذیری مناسب مدل‌ها به داده‌های جدید است. همچنین ماتریس‌های درهم‌ریختگی نشان می‌دهند که بیشترین خطاهای طبقه‌بندی بین دسته‌های مجاور (مانند Moderate و Unhealthy for)

(Sensitive Groups) رخ می‌دهد که از نظر میزان آلودگی به هم نزدیک هستند.

از نظر محاسباتی، کرنل خطی سریع‌ترین زمان آموزش را داشت، در حالی که کرنل RBF به دلیل محاسبات پیچیده‌تر، زمان بیشتری صرف کرد. با این حال، دقت بالاتر کرنل RBF ممکن است ارزش این هزینه محاسباتی را داشته باشد، به ویژه در کاربردهای حساس مانند پایش کیفیت هوا. کرنل چندجمله‌ای با درجه ۳ اگرچه از نظر تئوری می‌تواند مدل‌های پیچیده‌تری را یاد بگیرد، اما در این مورد خاص عملکرد ضعیف‌تری نشان داد که ممکن است با تنظیم پارامتر درجه (degree) بهبود یابد.

برای بهبود بیشتر نتایج، راهکارهای زیر پیشنهاد می‌شود: (۱) تنظیم دقیق‌تر هایپر پارامترها با استفاده از روش‌هایی مانند جستجوی شبکه‌ای (Grid Search)، (۲) استفاده از تکنیک‌های تعادل‌سازی کلاس‌ها برای دسته‌های مشکل‌دار مانند (Moderate، ۳) استخراج ویژگی‌های جدید یا انتخاب ویژگی‌های بهینه برای کاهش ابعاد داده، (۴) آزمایش ترکیب مدل‌ها (ensemble methods) مانند voting classifier که می‌تواند نقاط قوت مدل‌های مختلف را ترکیب کند. این بهبودها می‌توانند به ویژه برای افزایش دقت در دسته‌های میانی که بیشترین خطاها در آنها رخ داده است، مفید باشند. در نهایت، نتایج این بخش نشان می‌دهد که SVM با کرنل RBF با دقت کلی ۸۱-۸۲٪ می‌تواند به عنوان یک مدل پایه قابل اعتماد برای سیستم‌های پیش‌بینی کیفیت هوا استفاده شود. اگرچه دقت در برخی دسته‌ها نیاز به بهبود دارد، اما عملکرد کلی مدل به ویژه در تشخیص شرایط بحرانی (Extreme) و (Hazardous) بسیار رضایت‌بخش است. این مدل می‌تواند مبنای خوبی برای توسعه سیستم‌های هشدار اولیه آلودگی هوا باشد.

نتایج RBF:

RBF - Train:

	precision	recall	f1-score	support
Extreme	0.97	1.00	0.98	10071
Good	0.76	0.89	0.82	10071
Hazardous	0.91	0.90	0.91	10071
Moderate	0.70	0.58	0.63	10071
Unhealthy	0.83	0.72	0.77	10071
Unhealthy for Sensitive Groups	0.71	0.77	0.74	10071
Very Unhealthy	0.83	0.86	0.85	10066
accuracy			0.82	70492
macro avg	0.82	0.82	0.81	70492
weighted avg	0.82	0.82	0.81	70492


RBF - Validation:

	precision	recall	f1-score	support
Extreme	0.97	1.00	0.98	2159
Good	0.76	0.89	0.82	2159
Hazardous	0.92	0.90	0.91	2159
Moderate	0.69	0.57	0.63	2158
Unhealthy	0.84	0.72	0.77	2158
Unhealthy for Sensitive Groups	0.71	0.78	0.74	2159
Very Unhealthy	0.83	0.87	0.85	2157
accuracy			0.82	15109
macro avg	0.82	0.82	0.81	15109
weighted avg	0.82	0.82	0.81	15109

RBF - Test:

	precision	recall	f1-score	support
Extreme	0.96	1.00	0.98	2158
Good	0.76	0.88	0.81	2158
Hazardous	0.91	0.89	0.90	2158
Moderate	0.68	0.57	0.62	2159
Unhealthy	0.83	0.71	0.77	2159
Unhealthy for Sensitive Groups	0.69	0.76	0.73	2158
Very Unhealthy	0.84	0.86	0.85	2157
accuracy			0.81	15107
macro avg	0.81	0.81	0.81	15107
weighted avg	0.81	0.81	0.81	15107

شکل ۳۴: گزارشات طبقه بندی مربوط به RBF



شکل ۳۵: نمودارهای ماتریس در هم ریختگی RBF

نتایج POLY:

POLY - Train:

	precision	recall	f1-score	support
Extreme	0.97	1.00	0.98	10071
Good	0.76	0.87	0.81	10071
Hazardous	0.93	0.79	0.85	10071
Moderate	0.68	0.54	0.60	10071
Unhealthy	0.77	0.61	0.68	10071
Unhealthy for Sensitive Groups	0.68	0.73	0.70	10071
Very Unhealthy	0.68	0.90	0.77	10066
accuracy			0.78	70492
macro avg	0.78	0.78	0.77	70492
weighted avg	0.78	0.78	0.77	70492


POLY - Validation:

	precision	recall	f1-score	support
Extreme	0.97	1.00	0.98	2159
Good	0.76	0.87	0.81	2159
Hazardous	0.94	0.79	0.86	2159
Moderate	0.67	0.52	0.59	2158
Unhealthy	0.78	0.60	0.68	2158
Unhealthy for Sensitive Groups	0.67	0.75	0.71	2159
Very Unhealthy	0.68	0.91	0.78	2157
accuracy			0.78	15109
macro avg	0.78	0.78	0.77	15109
weighted avg	0.78	0.78	0.77	15109

POLY - Test:

	precision	recall	f1-score	support
Extreme	0.96	1.00	0.98	2158
Good	0.76	0.86	0.80	2158
Hazardous	0.93	0.78	0.85	2158
Moderate	0.67	0.54	0.60	2159
Unhealthy	0.75	0.59	0.66	2159
Unhealthy for Sensitive Groups	0.66	0.72	0.69	2158
Very Unhealthy	0.68	0.90	0.77	2157
accuracy			0.77	15107
macro avg	0.77	0.77	0.76	15107
weighted avg	0.77	0.77	0.76	15107

شکل ۳۶: گزارشات طبقه بندی مربوط به POLY



شکل ۳۷: نمودار های ماتریس در هم ریختگی POLY

نتایج LINEAR:

LINEAR - Train:

	precision	recall	f1-score	support
Extreme	0.93	0.98	0.95	10071
Good	0.79	0.89	0.84	10071
Hazardous	0.89	0.85	0.87	10071
Moderate	0.71	0.61	0.66	10071
Unhealthy	0.82	0.73	0.77	10071
Unhealthy for Sensitive Groups	0.71	0.77	0.74	10071
Very Unhealthy	0.83	0.85	0.84	10066
accuracy			0.81	70492
macro avg	0.81	0.81	0.81	70492
weighted avg	0.81	0.81	0.81	70492


LINEAR - Validation:

	precision	recall	f1-score	support
Extreme	0.93	0.98	0.95	2159
Good	0.79	0.88	0.83	2159
Hazardous	0.89	0.85	0.87	2159
Moderate	0.70	0.61	0.65	2158
Unhealthy	0.82	0.73	0.78	2158
Unhealthy for Sensitive Groups	0.71	0.78	0.74	2159
Very Unhealthy	0.83	0.85	0.84	2157
accuracy			0.81	15109
macro avg	0.81	0.81	0.81	15109
weighted avg	0.81	0.81	0.81	15109

LINEAR - Test:


	precision	recall	f1-score	support
Extreme	0.93	0.98	0.96	2158
Good	0.78	0.88	0.83	2158
Hazardous	0.89	0.86	0.87	2158
Moderate	0.70	0.61	0.65	2159
Unhealthy	0.82	0.72	0.77	2159
Unhealthy for Sensitive Groups	0.69	0.76	0.72	2158
Very Unhealthy	0.84	0.85	0.85	2157
accuracy			0.81	15107
macro avg	0.81	0.81	0.81	15107
weighted avg	0.81	0.81	0.81	15107

شکل ۳۸: گزارشات طبقه بندی مربوط به LINEAR



شکل ۳۹: نمودار های ماتریس در هم ریختگی LINEAR

نتایج مقایسه مدل‌های SVM با کرنل‌های مختلف نشان می‌دهد که کرنل RBF با میانگین دقت ۸۲٪ در داده‌های آزمون، بهترین عملکرد را در طبقه‌بندی سطوح مختلف کیفیت هوا داشته است. این برتری به دلیل توانایی بالای کرنل RBF در مدل‌سازی روابط غیرخطی پیچیده بین ویژگی‌ها است. کرنل خطی با دقت ۸۱٪ عملکرد نسبتاً خوبی نشان داد که بیانگر وجود روابط خطی قابل توجه در داده‌ها است، در حالی که کرنل چندجمله‌ای با دقت ۷۷٪ ضعیف‌ترین نتیجه را ارائه کرد. نکته حائز اهمیت، ثبات عملکرد تمام مدل‌ها در داده‌های آموزش، اعتبارسنجی و آزمون است که نشان‌دهنده تعمیم‌پذیری مناسب مدل‌ها می‌باشد. با توجه به این نتایج، کرنل RBF به عنوان گزینه بهینه برای سیستم‌های پیش‌بینی کیفیت هوا پیشنهاد می‌شود، هرچند که کرنل خطی نیز به دلیل سادگی و سرعت بالاتر می‌تواند در مواردی که منابع محاسباتی محدود هستند، مورد استفاده قرار گیرد.



شکل ۴۰: مقایسه نتایج کرنل‌ها

۱۳.۲.۱ ۱۳.۲.۱

۱. هدف اصلی مدل Support Vector Regression (SVR)، پیش‌بینی مقدار یک متغیر پیوسته است به‌طوری که خطای پیش‌بینی از یک مقدار مجاز ε بیشتر نشود. برخلاف SVM که به دنبال یافتن مرز تصمیم بین کلاس‌ها است، مدل SVR تابعی را پیدا می‌کند که بتواند داده‌ها را با بیشترین دقت ممکن، در محدوده‌ای موسوم به ε -tube پیش‌بینی کند.

تابع پیش‌بینی در SVR به صورت زیر تعریف می‌شود:

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b$$

که در آن:

- α_i, α_i^* ضرایب لگرانژ هستند.
- x_i داده‌های پشتیبان یا support vectors هستند.
- $K(x_i, x)$ کرنل، مثلاً RBF به شکل زیر است:

$$K(x_i, x) = \exp(-\gamma \|x_i - x\|^2)$$

• b بایاس یا عرض از مبدأ است.

هدف بهینه‌سازی در SVR، کمینه‌سازی تابع هزینه زیر است:

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*)$$

با قیود زیر:

$$\begin{cases} y_i - \langle w, x_i \rangle - b \leq \varepsilon + \xi_i \\ \langle w, x_i \rangle + b - y_i \leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases}$$

در این معادلات:

- ε میزان مجاز خطا یا پهنای لوله است.
- C پارامتر تنظیم جریمه برای نقاطی که خارج از لوله قرار می‌گیرند.
- ξ_i, ξ_i^* متغیرهای slack هستند که میزان تخطی از لوله را نشان می‌دهند.

۲. به منظور مقایسه‌ی هایپر پارامترهای مورد استفاده در این دو مدل، می‌توان گفت پارامترهای $C, \text{Kernel}(\text{Poly}, \text{RBF}, \dots), \text{Gamma}$ و در صورتی که کرنل poly انتخاب شده باشد، degree در مدل‌ها یکسان است.

با این حال، در مدل SVR پارامتر دیگری نیز به عنوان epsilon مطرح شده است که مقدار بازه‌ی پذیرش خطای ε را تعیین می‌کند. در پکیج sklearn ، این پارامتر به صورت پیش فرض برابر با ۱.۰ تنظیم شده است.

برای آموزش مدل پیش بینی مقدار آلودگی هوا که در دیتاست ما به عنوان $\text{pm}_{2.5}$ تعریف شده بود، از دیتاست پیش پردازش شده تا به اینجا مجدداً استفاده شده است و کدها و پیاده‌سازی آن در نوت بوک مجزایی نیست. با این حال، برای آموزش این مدل باید مقدار هدف را از حالت دسته بندی بر اساس AQI به مقادیر عددی $\text{pm}_{2.5}$ بازگرداند. با توجه به اینکه داده‌های پیش پردازش شده همگی در df ذخیره شده‌اند و پس از آن ستون‌ها حذف و دسته بندی‌ها تغییر کرده‌اند، ما می‌توانیم مجدداً از همین دیتافریم استفاده کرده و مطابق با نیاز خود، دیتافریم جدیدی بسازیم. بنابراین، دو دیتافریم x_{reg} و y_{reg} تعریف می‌شوند.

سپس، با اعمال پیش پردازش‌های ذکر شده بر این داده‌ها از جمله انتخاب ۱۰ ویژگی بهتر، نرمالایز کردن و تقسیم به داده‌های تست و آموزش، مدل را آموزش می‌دهیم.

۳. برای اندازه‌گیری عملکرد این مدل، بر خلاف مدل‌های پیشین که از جنس دسته بندی بودند، نمی‌توانیم از گزارش طبقه بندی یا ماتریس درهم ریختگی استفاده کنیم. بنابراین، معیارهای پیش بینی نظیر RMSE ، MSE یا R^2 استفاده می‌کنیم. برای این مدل، این مقادیر به شرح زیر است: همچنین، بخشی از پیش بینی‌های این مدل را در مقابل مقادیر واقعی می‌توانیم مشاهده کنیم.

۱۴.۲.۱ ۱۴.۲.۱

در این پژوهش، به منظور بهینه‌سازی پارامترهای مدل SVM از الگوریتم $\text{Particle Swarm Optimization (PSO)}$ استفاده شد. این الگوریتم با الهام از رفتار گروهی پرندگان، فضای جستجو را با مجموعه‌ای از ذرات پوشش می‌دهد. هر ذره نمایانگر یک ترکیب ممکن از پارامترهای (C, γ) بوده و بر اساس بهترین تجربه شخصی و گروهی موقعیت خود را به‌روزرسانی می‌کند.


```

Train set:
MSE: 475.0169
MAE: 11.7022
R2: 0.9446

Validation set:
MSE: 612.8906
MAE: 12.6258
R2: 0.9285

Test set:
MSE: 432.7850
MAE: 12.1760
R2: 0.9494
    
```

شکل ۴۱: معیار های ارزیابی مدل SVR



شکل ۴۲: بخشی از خروجی پیش بینی مدل SVR

تابع هدف، دقت مدل در داده های اعتبارسنجی است. الگوریتم PSO با حرکت ذرات در فضای جستجو، در نهایت به ترکیب بهینه ای از پارامترها دست می یابد که بیشترین دقت را حاصل می کند. در پیاده سازی این الگوریتم، از نسخه ی ساده شده ی آن با استفاده از تابع differential_evolution در کتابخانه scipy بهره گرفته شد که عملکردی مشابه PSO دارد و در زمان کوتاه تری نتیجه ی بهینه ارائه می دهد.

بهینه سازی ازدحام ذرات (PSO) الگوریتم Particle Swarm Optimization یا بهینه سازی ازدحام ذرات، یک روش فراابتکاری مبتنی بر جمعیت است که الهام گرفته از رفتار گروهی موجوداتی نظیر پرندگان و ماهی ها می باشد. در این الگوریتم، مجموعه ای از ذرات (Particles) در فضای جستجو

حرکت کرده و با تبادل اطلاعات با یکدیگر، به سمت نواحی مطلوب در فضای مسئله گرایش پیدا می کنند. هر ذره دارای یک موقعیت $\vec{x}_i$ و سرعت $\vec{v}_i$ در فضای جستجو است. همچنین هر ذره، بهترین موقعیتی را که تا کنون تجربه کرده است ($\vec{p}_i$) به خاطر می سپارد و کل جمعیت نیز بهترین موقعیت کل را به عنوان $\vec{g}$ می شناسد. قوانین به روزرسانی سرعت و موقعیت ذرات به صورت زیر تعریف می شوند:

$$\vec{v}_i(t+1) = w \cdot \vec{v}_i(t) + c_1 \cdot r_1 \cdot (\vec{p}_i - \vec{x}_i(t)) + c_2 \cdot r_2 \cdot (\vec{g} - \vec{x}_i(t)) \quad (1)$$

$$\vec{x}_i(t+1) = \vec{x}_i(t) + \vec{v}_i(t+1) \quad (2)$$

که در آن:

- w وزن اینرسی است که به سرعت قبلی اهمیت می دهد.
 - c_1 و c_2 ضرایب یادگیری هستند که میزان جذب ذره به بهترین موقعیت فردی و جمعی را کنترل می کنند.
 - r_1 و r_2 اعداد تصادفی با توزیع یکنواخت در بازه $[0, 1]$ هستند.
- فرایند به روزرسانی تا زمانی ادامه می یابد که الگوریتم به معیار توقف تعیین شده (مانند رسیدن به تعداد مشخصی تکرار یا همگرایی) برسد. در این پژوهش از این الگوریتم برای تنظیم بهینه پارامترهای مدل SVM نظیر C و γ استفاده شده است.

۱۵.۲.۱ ۱۵.۲.۱

در این بخش، مطابق آنچه که در قسمت قبل توضیحی داده شد، پارامترهای یک مدل SVM با کرنل RBF به وسیله ی این مدل بهینه سازی شده است. در شکل ۴۳ پاسخ این مدل نمایش داده شده است. لازم به ذکر است که به دلیل زمان بر بودن این فرایند، بهینه سازی تنها بر ۲۰۰۰ نمونه از دیتاست انجام شده است.

✓ Best C: 476.70932, Best gamma: 0.01156
✓ Best Accuracy: 0.7917

شکل ۴۳: نتیجه مدل تنظیم شده با PSO

۲.۱

۳.۱ ۳.۱

۲.۳.۱ ۱.۳.۱

داده های مورد استفاده در این دیتاست، شامل اندازه گیری های کیفیت هوا و ذرات معلق در آن است. در جدول زیر، ساختار دیتاست را مشاهده می کنیم.

Unit	Description	Feature
$\mu g/m^3$	<i>FineParticulateMatter</i>	PM _{2.5}
$\mu g/m^3$	<i>CoarseParticulateMatter</i>	PM ₁₀
$\mu g/m^3$	<i>SulfurDioxide</i>	SO ₂
$\mu g/m^3$	<i>NitrogenDioxide</i>	NO ₂
$^3mg/m$	<i>CarbonMonoxide</i>	CO
$\mu g/m^3$	<i>Ozone</i>	O ₃

جدول ۳: Input features used for air quality classification.

رده کیفیت هوا	مقدار شاخص کیفیت هوا (AQI)	رنگ شاخص	توضیح
Excellent	۵۰-۰	سبز	کیفیت هوا بسیار خوب است
Good	۱۰۰-۵۱	آبی	کیفیت هوا قابل قبول است
Pollution Light	۱۵۰-۱۰۱	زرد	گروه‌های حساس ممکن است آسیب ببینند
Pollution Moderate	۲۰۰-۱۵۱	نارنجی	ناسالم برای همه گروه‌ها
Pollution Heavy	۳۰۰-۲۰۱	قرمز	هشداردهنده برای سلامت
Pollution Severe	۵۰۰-۳۰۱	بنفش	شرایط خطرناک برای سلامتی

جدول ۴: دسته‌بندی کیفیت هوا بر اساس شاخص AQI

۲.۳.۱ ۳.۳.۱

در این پروژه، جهت بهبود عملکرد مدل SVM، از روشی نوآورانه تحت عنوان Differential Gravitational Fireworks Algorithm (DGFA) استفاده شده است. این الگوریتم، یک روش ترکیبی است که از سه الگوریتم قدرتمند الهام گرفته شده: الگوریتم آتش‌بازی (FWA)، جستجوی گرانشی (GSA) و تکامل تفاضلی (DE).

هدف اصلی این الگوریتم، بهینه‌سازی همزمان دو پارامتر کلیدی در SVM با کرنل RBF می‌باشد، یعنی:

• C : پارامتر جریمه مدل

• γ : ضریب کرنل

فرآیند بهینه‌سازی در DGFA به صورت زیر انجام می‌شود:

- ابتدا جمعیتی از مقادیر اولیه برای C و γ تولید می‌شود.
- عملکرد هر عضو (با استفاده از دقت یا خطای مدل SVM) ارزیابی می‌گردد.
- الگوریتم آتش‌بازی برای ایجاد تنوع در فضای جستجو استفاده می‌شود؛ به طوری که نمونه‌های بهتر، جرقه‌های بیشتری تولید می‌کنند.
- سپس با بهره‌گیری از قوانین گرانشی، نمونه‌ها به سمت جواب‌های بهتر جذب می‌شوند.
- در نهایت با اعمال عملگرهای تکامل تفاضلی، جستجوی محلی بهبود یافته و تعادل میان جستجوی سراسری و موضعی برقرار می‌شود.

جدول ۵: مقایسه‌ی دقت مدل‌های مختلف

Accuracy (%)	Model
82.1	SVM
85.3	GFO-SVM
91.0	<i>DGFO – SVM(proposed)</i>
88.5	DNN
89.2	RNN
87.4	XGBoost
84.7	<i>RandomForest</i>

هدف نهایی به صورت تابع هدف زیر تعریف می شود:

$$\min_{C, \gamma} [\text{Error}_{\text{SVM}}(C, \gamma)]$$

که در آن، خطا معمولاً به صورت $1 - \text{Accuracy}$ تعریف می شود. نتایج نشان داده اند که استفاده از DGFA منجر به تنظیم مؤثرتر پارامترها و افزایش دقت مدل نسبت به روش هایی مانند Grid Search یا سایر الگوریتم های کلاسیک شده است. نوآوری مقاله در آنها در بهینه سازی مقادیر هایپر پارامتر ها بوده و زیاضیات مدل SVM تغییری نداشته است.

۴.۳.۱ ۳.۳.۱

در این مقاله، چنان که در جدول ۵ ذکر شده است، مقدار دقت مدل پیشنهادی با مدل های دیگر مقایسه شده است. نتایج تجربی این مطالعه نشان می دهد که مدل DGFO-SVM پیشنهادی، با استفاده از ترکیب بهینه سازی آتش بازی و جستجوی گرانشی با تفاضلی، توانسته است عملکرد بهتری نسبت به روش های مرسوم در طبقه بندی کیفیت هوا ارائه دهد. این مدل با دستیابی به دقت ۹۱ درصد، حداقل ۲ درصد بهتر از بهترین روش جایگزین (یعنی RNN) و به طور قابل توجهی بهتر از SVM سنتی عمل کرده است. بنابراین، استفاده از این روش پیشنهادی می تواند به عنوان یک راه حل مؤثر در مسائل طبقه بندی غیر خطی با داده های پیچیده مورد توجه قرار گیرد.

مدلی که در این پژوهش معرفی شده است، یعنی DGFO-SVM، نه تنها از نظر دقت و معیار F1 عملکرد بهتری نسبت به سایر مدل ها از خود نشان داده، بلکه از منظر پیچیدگی زمانی و بازدهی نیز قابل رقابت است. از منظر پیچیدگی زمانی و منابع مورد نیاز برای اجرا، مدل های RNN و DNN نیازمند داده های آموزشی حجیم، منابع پردازشی بالا و زمان اجرای طولانی هستند. در مقابل، روش DGFO-SVM با بهره گیری از بهینه سازی ترکیبی شامل الگوریتم تکاملی تفاضلی و الگوریتم آتش بازی گرانشی، توانسته تعادلی مناسب میان دقت و پیچیدگی محاسباتی برقرار کند. این الگوریتم به گونه ای طراحی شده که سرعت همگرایی بهینه سازی را افزایش داده و احتمال گیر افتادن در کمینه های محلی را کاهش دهد (Section 2.7). براساس توصیف های ارائه شده در بخش Experimental Settings، این مدل با استفاده از جمعیت اولیه به اندازه ۵۰ و تکرار ۱۰۰ بار در محیطی با پردازنده Core i7-9700K و حافظه 32GB RAM اجرا شده است، که نشان دهنده توانایی اجرای آن در سیستم های نسبتاً معمولی نیز هست (Section 2.7).

بنابراین می توان نتیجه گرفت که مدل DGFO-SVM علاوه بر بهبود محسوس در معیارهای عملکردی، در زمینه بازده محاسباتی نیز نسبت به بسیاری از روش های یادگیری عمیق مزیت دارد و می تواند به عنوان گزینه ای کارآمد و کم هزینه برای پیش بینی شاخص کیفیت هوا در مقیاس های مختلف مطرح باشد.

۴.۳.۱ ۵.۳.۱

در این بخش به پیاده سازی مدل معرفی شده در مقاله بر روی دیتاست پکن خواهیم پرداخت. از آنجا که این مدل در نوت بوک قبل تعریف و آموزش داده می شود، بنابراین داده های پیش پردازش شده چنان که در بخش های قبل توضیح داده شد، در حافظه ی سیستم موجود هستند و می توان از آنها برای آموزش مدل جدید استفاده کرد.

بهینه سازی مدل SVM با استفاده از الگوریتم تکامل تفاضلی

در این بخش از پروژه، هدف تنظیم بهینه دو پارامتر کلیدی مدل SVM با کرنل RBF بوده است؛ یعنی:

• C : پارامتر کنترل کننده جریمه برای اشتباهات طبقه بندی

• γ : ضریب کرنل که میزان تأثیر نقاط داده در اطراف را مشخص می کند

برای این منظور، از الگوریتم Differential Evolution (DE) استفاده شده که یک الگوریتم تکاملی و مبتنی بر جمعیت است. هدف این الگوریتم، یافتن مقادیری برای C و γ است که دقت مدل را در داده های اعتبارسنجی (validation set) حداکثر کند. تابع هدف این بهینه سازی به صورت زیر تعریف شده است:

$$\min_{C, \gamma} [1 - \text{Accuracy}_{\text{val}}(C, \gamma)]$$

یا به عبارت دیگر، الگوریتم سعی می کند خطا را در مجموعه ی اعتبارسنجی کاهش دهد.

فرایند اجرا برای تسریع در فرآیند آموزش، ابتدا یک زیر مجموعه شامل ۲۰۰۰ نمونه از داده های آموزشی استخراج کرده و سپس تابع هدفی تعریف شد که در آن، یک مدل SVC با مقادیر فعلی C و γ آموزش می بیند و دقت آن روی داده های validation محاسبه می شود. چون الگوریتم DE ذاتاً یک الگوریتم مینیم سازی است، مقدار منفی دقت بازگشتی داده می شود. همچنین با استفاده از تابع callback، دقت مدل در هر نسل (iteration) ذخیره می شود تا نمودار پیشرفت الگوریتم رسم شود.

پارامترهای تنظیم شده برای الگوریتم DE

• دامنه جستجو: $\log_{10} C \in [-3, 3]$ و $\log_{10} \gamma \in [-5, 0]$

• جمعیت: ۵ عضو

• تعداد تکرار: ۵ نسل

• بدون استفاده از مرحله polish برای صرفه جویی در زمان

آموزش نهایی و ارزیابی بعد از اتمام بهینه سازی، مقادیر بهینه C و γ استخراج شده و مدل نهایی روی کل داده های آموزشی آموزش داده شده است.


پارامترهای بهینه نهایی به دست آمده از الگوریتم DE به شرح زیر هستند:

$$\text{gamma} = 0.01156 \quad C = 476.70932$$

Final Evaluation on Test Set:

	precision	recall	f1-score	support
Extreme	0.97	1.00	0.99	2158
Good	0.81	0.87	0.84	2158
Hazardous	0.91	0.91	0.91	2158
Moderate	0.71	0.66	0.69	2159
Unhealthy	0.83	0.75	0.79	2159
Unhealthy for Sensitive Groups	0.72	0.77	0.75	2158
Very Unhealthy	0.84	0.86	0.85	2157
accuracy			0.83	15107
macro avg	0.83	0.83	0.83	15107
weighted avg	0.83	0.83	0.83	15107


شکل ۴۴: گزارش طبقه بندی مدل DE



شکل ۴۵: ماتریس درهم ریختگی مدل DE

سپس ارزیابی روی مجموعه‌ی تست صورت گرفت و گزارش کامل طبقه‌بندی و ماتریس درهم‌ریختگی (Confusion Matrix) ترسیم گردید. در نهایت، نموداری رسم شده که روند پیشرفت دقت الگوریتم DE را در طی نسل‌ها نشان می‌دهد.

این روش نه تنها باعث بهینه‌سازی خودکار پارامترهای حساس مدل SVM شد، بلکه بدون نیاز به جستجوی دستی یا تنظیمات تجربی، مدلی دقیق و پایدار تولید کرد. همچنین مشاهده شد که حتی با تعداد کمی نسل، الگوریتم DE توانست به دقت قابل قبولی دست یابد.



شکل ۴۶: فرایند بهینه سازی مدل با DE

۵.۳.۱ ۶.۳.۱

به منظور آماده سازی داده های ورودی برای مدل یادگیری ماشین، مجموعه ای از مراحل پیش پردازش و مهندسی ویژگی بر روی داده ها اعمال گردید. این مراحل به گونه ای طراحی شده اند که هم ویژگی های مفیدی از تاریخچه آلودگی استخراج شود، و هم داده ها از نظر کیفی برای تغذیه به مدل SVM آماده گردند. مراحل به شرح زیر بوده اند:

۱. حذف ستون های اضافی: ستون No که صرفاً شماره ردیف بود، حذف گردید.
۲. ایجاد ویژگی های تاخیری: برای متغیر pm2.5، مقادیر مربوط به ۱، ۲، ۳، ۲۴ و ۱۶۸ ساعت قبل به عنوان ویژگی جدید ایجاد شد.
۳. حذف مقادیر گمشده: ردیف هایی که در هر یک از ویژگی های اصلی یا تاخیری مقدار NaN داشتند، حذف شدند.
۴. کدگذاری جهت باد: ستون cbwd به صورت One-Hot کدگذاری شد.
۵. مدیریت داده های پرت: ستون Iws که مربوط به سرعت تجمعی باد است، در بازه صدک اول و نود و نهم بریده شد. (capping)
۶. استخراج ویژگی های آماری ساعتی: برای متغیر pm2.5، با استفاده از پنجره ای ۲۴ ساعته، ویژگی هایی مانند میانگین، انحراف معیار، واریانس، کمینه، بیشینه، میانه، چولگی و کشیدگی استخراج گردید.
۷. طبقه بندی آلودگی: با استفاده از مقدار pm2.5، ردیف ها به دسته های استاندارد کیفیت هوا طبقه بندی شدند (AQI Category).
۸. کدگذاری برچسب هدف: دسته بندی کیفی با استفاده از LabelEncoder به مقدار عددی تبدیل شد تا برای مدل قابل استفاده باشد.
۹. ویژگی های چرخه ای: مقادیر hour، month و weekday با استفاده از تبدیل های سینوسی و کسینوسی به ویژگی هایی چرخه ای تبدیل شدند.
۱۰. کدگذاری فصل ها: ماه ها به فصل های سال نگاشت شدند و با استفاده از توابع سینوس و کسینوس برای الگوهای دوره ای کدگذاری شدند.



۱۱. استخراج رکورد نهایی برای پیش‌بینی: پس از انجام تمامی مراحل، آخرین ردیف (که هنوز مقدار هدف آن مشخص نیست) به‌عنوان ورودی به مدل پیش‌بینی داده شد، در حالی که فقط از ۱۰ ویژگی مهم استفاده شده است.

این فرایند باعث افزایش کیفیت و پایداری مدل و همچنین استخراج ویژگی‌های وابسته به زمان شد که در پیش‌بینی آلودگی بسیار مؤثر هستند.


۲ کاهش ابعاد

برای مشاهده نوت‌بوک من اینجا کلیک کنید: [لینک گوگل کولب](#)


۱.۲ سوالات

۱.۱.۲ الف


کد پایتون این بخش برای بارگذاری و پردازش مجموعه داده Fashion MNIST طراحی شده است که شامل ۷۰,۰۰۰ تصویر سیاه‌وسفید ۲۸×۲۸ پیکسل از ۱۰ دسته مختلف پوشاک است. ابتدا داده‌های آموزشی از این مجموعه بارگذاری می‌شوند و از هر دسته (مانند تی‌شرت، شلوار و غیره) یک تصویر به صورت تصادفی انتخاب می‌شود. سپس این تصاویر در یک ردیف نمایش داده می‌شوند. **شکل ۴۷** در ادامه، نویز گاوسی با میانگین صفر و انحراف معیار ۰/۲ به تصاویر اضافه می‌شود تا نسخه‌های نویزی آن‌ها ایجاد شود. مقادیر پیکسل‌ها به بازه [۰، ۱] نرمال‌سازی و محدود می‌شوند. در نهایت، تصاویر نویزی نیز در یک ردیف جداگانه نمایش داده می‌شوند **شکل ۴۸** تا امکان مقایسه با تصاویر اصلی فراهم شود **شکل ۴۹**.



شکل ۴۷: تصاویر اصلی




شکل ۴۸: تصاویر نویزی



شکل ۴۹: تصاویر اصلی و نویزی در کنار هم

۲.۱.۲ ب

این بخش کد پایتون الگوریتم تحلیل مؤلفه‌های اصلی (PCA) را بدون استفاده از کتابخانه‌های آماده برای مجموعه داده Fashion MNIST پیاده‌سازی می‌کند. ابتدا تصاویر 28×28 پیکسل به بردارهای 784 بعدی تبدیل شده و داده‌ها نرمال‌سازی و استانداردسازی می‌شوند. سپس ماتریس کوواریانس داده‌ها محاسبه شده و مقادیر ویژه و بردارهای ویژه آن به ترتیب نزولی مرتب می‌شوند. نسبت واریانس توضیح داده شده برای هر مؤلفه اصلی و واریانس تجمعی محاسبه می‌شود تا مشخص شود چند مؤلفه برای حفظ حداقل 90% از واریانس کل کافی است. در نهایت، نتایج به صورت یک نمودار میله‌ای و خطی (شکل ۵۰ و شکل ۵۲) نمایش داده می‌شود که نسبت واریانس توضیح داده شده و واریانس تجمعی را نشان می‌دهد.




شکل ۵۰: نمودار واریانس تجمعی بر اساس مؤلفه‌ها

Number of components needed to retain 90% variance: 84

شکل ۵۱: مشاهده خروجی کد یعنی تعداد مؤلفه‌های اصلی کافی


خروجی این کد شامل یک نمودار و یک مقدار عددی (شکل ۵۱) است. نمودار با عنوان "Explained Variance Ratio by Principal Components" یک خط قرمز برای واریانس تجمعی و یک خط افقی سبز در سطح 90% واریانس را نمایش می‌دهد. خط قرمز نشان می‌دهد که واریانس تجمعی با افزایش تعداد مؤلفه‌ها به سرعت رشد می‌کند و در حدود مؤلفه ۸۴ به آستانه 90% می‌رسد. همچنین، خروجی عددی کد نشان می‌دهد که برای حفظ 90% از واریانس کل داده‌ها، به ۸۴ مؤلفه اصلی نیاز است، که این تعداد مؤلفه بخش عمده اطلاعات داده را حفظ می‌کند و برای کاهش ابعاد داده مناسب است.



شکل ۵۲: نمودار میله ای واریانس تجمعی بر اساس مؤلفه ها

۳.۱.۲ ج


این بخش کد پایتون با استفاده از کتابخانه 'scikit-learn' الگوریتم تحلیل مؤلفه‌های اصلی (PCA) را بر روی مجموعه داده (PCA) اعمال می‌کند تا ابعاد داده‌ها را کاهش دهد. ابتدا تصاویر 28×28 پیکسلی این مجموعه که شامل ۷۰,۰۰۰ تصویر از ۱۰ دسته مختلف پوشاک است، به بردارهای 784 بعدی تبدیل شده و مقادیر پیکسل‌ها به بازه $[0, 1]$ نرمال‌سازی می‌شوند. سپس PCA با تنظیم دو مؤلفه اصلی اجرا می‌شود تا داده‌ها به یک فضای دوبعدی کاهش یابند. در نهایت، یک نمودار پراکندگی دوبعدی رسم می‌شود (شکل ۵۳) که هر دسته با رنگی متفاوت نشان داده می‌شود، به منظور تحلیل بصری توزیع داده‌ها و جداسازی دسته‌ها پس از کاهش ابعاد. در این نمودار، هر نقطه نشان‌دهنده یک تصویر است و نقاط مربوط به هر یک از ۱۰ دسته (مانند تی‌شرت، شلوار، کفش و غیره) با رنگ‌های متمایز مشخص شده‌اند. محورهای x و y به ترتیب مؤلفه‌های اصلی اول و دوم را نشان می‌دهند. با وجود اینکه ممکن است برخی دسته‌ها به دلیل پیچیدگی داده‌ها هم‌پوشانی داشته باشند، الگوهای کلی توزیع دسته‌ها قابل مشاهده است، که این امر به درک بهتر ساختار داده‌ها پس از کاهش ابعاد کمک می‌کند.




شکل ۵۳: نمودار PCA

۴.۱.۲ د

خروجی کد این بخش شامل یک نمودار سه‌ردیفه است که شامل ۱۰ تصویر از هر دسته Fashion MNIST است (شکل ۵۴). ردیف اول تصاویر اصلی را نشان می‌دهد که واضح و بدون نویز هستند. ردیف دوم تصاویر نویزی را نمایش می‌دهد که به دلیل افزودن نویز گاوسی، کیفیت آن‌ها کاهش یافته و دانه‌دار به نظر می‌رسند. ردیف سوم تصاویر بازسازی‌شده با استفاده از ۱۰۰ مؤلفه اصلی PCA را نشان می‌دهد که نسبت به نسخه نویزی واضح‌تر هستند، اما برخی جزئیات ریز به دلیل کاهش ابعاد از دست رفته و تصاویر کمی تار به نظر می‌رسند. این مقایسه نشان‌دهنده توانایی PCA در حذف نویز با حفظ ساختار کلی تصاویر است. در ادامه و در شکل ۵۵ ما با ۵۰۰ مؤلفه اصلی سعی کردیم که تصاویر نویزی را بازسازی کنیم که تا حدودی موفق شدیم و به نتیجه مطلوب تری نسبت به ۱۰۰ مؤلفه رسیدیم.




شکل ۵۴: تصاویر اصلی و نویزی و بازسازی شده در کنار هم با ۱۰۰ مؤلفه اصلی



شکل ۵۵: تصاویر اصلی و نویزی و بازسازی شده در کنار هم با ۵۰۰ مؤلفه اصلی

۵.۱.۲ .

این کد پایتون الگوریتم تحلیل تمایزی خطی (LDA) را با استفاده از کتابخانه 'scikit-learn' بر روی مجموعه داده Fashion MNIST پیاده‌سازی می‌کند تا ابعاد داده‌ها را کاهش دهد. ابتدا تصاویر 28×28 پیکسلی این مجموعه که شامل ۷۰,۰۰۰ تصویر از ۱۰ دسته مختلف پوشاک است، به بردارهای ۷۸۴ بعدی تبدیل شده و مقادیر پیکسل‌ها به بازه $[0, 1]$ نرمال‌سازی می‌شوند. سپس LDA با تنظیم دو مؤلفه اجرا می‌شود تا داده‌ها به یک فضای دوبعدی کاهش یابند، با این هدف که جداسازی بین کلاس‌ها حداکثر شود. در نهایت، یک نمودار پراکنندگی دوبعدی رسم می‌شود (شکل ۵۶) که هر دسته با رنگی متفاوت نمایش داده می‌شود و نسبت واریانس توضیح داده‌شده توسط مؤلفه‌های LDA محاسبه و چاپ می‌شود (شکل ۵۷). جداسازی بین دسته‌ها نسبت به PCA واضح‌تر است، زیرا LDA بر تمایز بین کلاس‌ها تمرکز دارد. همچنین، نسبت واریانس توضیح داده‌شده توسط مؤلفه‌های LDA برابر با $[65.43\%, 34.57\%]$ است، که نشان می‌دهد مؤلفه اول 65.43% و مؤلفه دوم 34.57% از واریانس داده‌های تبدیل شده را توضیح می‌دهند، و مجموع آن‌ها 100% است، زیرا فقط دو مؤلفه در نظر گرفته شده است.



شکل ۵۶: نمودار LDA


Explained Variance Ratio by LDA Components: [0.65426124 0.34573876]

شکل ۵۷: نسبت واریانس مولفه اول و مولفه دوم

۶.۱.۲ و

این بخش به منظور محاسبه و تحلیل ماتریس‌های پراکندگی درون‌کلاسی (Sw) و بین‌کلاسی (Sb) در چارچوب الگوریتم تحلیل تمایزی خطی (LDA) برای مجموعه داده Fashion MNIST طراحی شده است. ابتدا تصاویر ۲۸×۲۸ پیکسلی این مجموعه به بردارهای ۷۸۴ بعدی تبدیل و نرمال‌سازی می‌شوند، و یک زیرمجموعه ۲۰۰۰ تایی از داده‌ها برای کارایی محاسباتی انتخاب می‌شود. ماتریس Sw با جمع پراکندگی درون هر کلاس و ماتریس Sb با استفاده از تفاوت میانگین کلاس‌ها از میانگین کلی محاسبه می‌شود. سپس، ماتریس جدایی‌پذیری ($S_w^{-1} \cdot S_b$) با اعمال یک هموارسازی کوچک برای جلوگیری از تکیه بودن Sw تشکیل شده، و مقادیر ویژه این ماتریس به صورت نزولی محاسبه و در یک نمودار میله‌ای نمایش داده می‌شود (شکل ۵۸). نمودار نشان می‌دهد که چند مقدار ویژه اول (مانند ۳۹۷/۸۴ و ۱۳۹/۴۱) به طور قابل توجهی بزرگ‌تر از بقیه هستند، در

حالی که مقادیر بعدی به سرعت به صفر یا مقادیر منفی نزدیک می شوند، که این امر بیانگر وجود چند جهت اصلی برای تمایز بین کلاس ها است. پنج مقدار ویژه برتر به ترتیب 397.84 ، 139.41 ، 107.38 ، 82.39 و 73.79 گزارش شده اند، که نشان می دهد مؤلفه های اولیه بیشترین اطلاعات جداسازی را حمل می کنند و استفاده از تعداد محدودی از این مؤلفه ها می تواند برای کاهش ابعاد کافی باشد.



شکل ۵۸: نمودار میله ای مقادیر ویژه


Top 5 eigenvalues: [397.842726 139.41070521 107.38051541 82.39168814 73.79529632]

شکل ۵۹: ۵ مقدار ویژه برتر

۷.۱.۲ ز

این بخش به منظور بررسی تأثیر تعداد ویژگی ها بر مقدار ردیابی ماتریس جدایی پذیری ($S_w^{-1} \cdot S_b$) در چارچوب تحلیل تمایزی خطی (LDA) برای مجموعه داده Fashion MNIST طراحی شده است. ابتدا تصاویر 28×28 پیکسلی این مجموعه به بردارهای 784 بعدی تبدیل و نرمال سازی شده، و یک زیرمجموعه 2000 تایی از داده ها برای محاسبات انتخاب می شود. ماتریس های پراکندگی درون کلاسی (S_w) و بین کلاسی (S_b) برای تعداد مختلف ویژگی ها (از 50 تا 784 با گام 50) محاسبه می شوند، و با اعمال یک هموارسازی کوچک برای جلوگیری از تکیه بودن S_w ماتریس جدایی پذیری تشکیل و مقدار ردیابی آن محاسبه می شود. در نهایت، این مقادیر در یک نمودار خطی رسم شده (شکل ۶۰) و تعداد بهینه ویژگی ها بر اساس حداکثر ردیابی تعیین می شود (شکل ۶۱). نمودار نشان می دهد که با افزایش تعداد ویژگی ها از 50 به 750 ، مقدار ردیابی به صورت مداوم از حدود 5 به بیش از 50 افزایش می یابد، که بیانگر بهبود جداسازی کلاس ها با افزودن ویژگی های بیشتر است. با این حال، تعداد بهینه ویژگی ها 750

گزارش شده است، که نشان می‌دهد پس از این نقطه، افزودن ویژگی‌های بیشتر تأثیر قابل توجهی بر ردیابی ندارد و ممکن است نویز اضافه کند. این نتیجه نشان‌دهنده تعادل بهینه بین اطلاعات جداسازی و پیچیدگی مدل است.



شکل ۶۰: نمودار خطی trace


Optimal number of features (where trace peaks): 750

شکل ۶۱: مقدار بهینه ویژگی‌ها

۲.۲ امتیازی

t-SNE (t-distributed Stochastic Neighbor Embedding) یک روش کاهش ابعاد غیرخطی است که برای تجسم داده‌های با ابعاد بالا در فضاها دو یا سه بعدی طراحی شده است. این روش ابتدا فاصله‌های بین نقاط داده در فضای اصلی را با استفاده از توزیع‌های گاوسی به احتمالات شباهت تبدیل می‌کند، به طوری که نقاط نزدیک‌تر احتمال شباهت بیشتری دارند. سپس، در فضای کاهش یافته (مثلاً دو بعدی)، از توزیع t-student برای مدل‌سازی شباهت‌ها استفاده می‌کند و تلاش می‌کند با کمینه کردن اختلاف (Divergence Kullback-Leibler) بین این دو توزیع، ساختار محلی داده‌ها را حفظ کند. t-SNE بیشتر برای تجسم داده‌ها مناسب است و بر حفظ ساختارهای محلی (مانند خوشه‌ها) تمرکز دارد، اما ممکن است ساختارهای جهانی را به خوبی حفظ نکند.

این بخش الگوریتم t-SNE (t-distributed Stochastic Neighbor Embedding) را بدون استفاده از کتابخانه‌های آماده برای کاهش ابعاد داده‌های مجموعه Fashion MNIST پیاده‌سازی می‌کند. ابتدا تصاویر 28×28 پیکسلی این مجموعه به بردارهای 784 بعدی تبدیل و نرمال‌سازی شده، و یک زیرمجموعه 1000 تایی از داده‌ها برای کارایی محاسباتی انتخاب می‌شود. الگوریتم با محاسبه فاصله‌های اقلیدسی در فضای اصلی و تبدیل آن‌ها به احتمالات با توزیع گاوسی (P_{ij}) آغاز می‌شود، سپس در فضای کاهش یافته با استفاده از توزیع t-student (Q_{ij}) شباهت‌ها را مدل می‌کند. با استفاده از گرادینان نزولی و کمینه کردن اختلاف Kullback-Leibler، داده‌ها به دو بعد کاهش یافته و در یک نمودار پراکندگی با رنگ‌های متفاوت برای هر کلاس نمایش داده می‌شوند (شکل ۶۲). در این نمودار، هر نقطه نماینده یک تصویر است و نقاط مربوط به ۱۰ دسته (مانند تی‌شرت، شلوار و غیره) با رنگ‌های متمایز مشخص شده‌اند. خوشه‌بندی محلی قابل توجهی در این نمودار مشاهده می‌شود، به طوری که دسته‌هایی مانند شلوار و کفش به خوبی از هم جدا شده‌اند، اما فواصل جهانی ممکن است تحریف شده باشند. این نتیجه نشان‌دهنده توانایی t-SNE در حفظ ساختارهای محلی و تجسم داده‌های پیچیده است، هرچند مقیاس محورها بسیار کوچک (در حد 10^{-4}) است که به دلیل حساسیت الگوریتم به پارامترها و نرخ یادگیری است.



شکل ۶۲: نمودار t-SNE

مقایسه با PCA و LDA

مزایای t-SNE

حفظ ساختار محلی: t-SNE در تجسم خوشه‌های محلی و جداسازی داده‌های پیچیده بسیار قوی است، و اغلب خوشه‌های واضح‌تری نسبت

به PCA و LDA ایجاد می‌کند.

غیرخطی بودن: بر خلاف PCA و LDA که روش‌های خطی هستند، t-SNE می‌تواند روابط غیرخطی را مدل کند، که برای داده‌های پیچیده مانند Fashion MNIST مفید است.

محدودیت‌های t-SNE:

عدم حفظ ساختار جهانی: t-SNE بر ساختار محلی تمرکز دارد و ممکن است فواصل جهانی بین خوشه‌ها را تحریف کند، در حالی که PCA ساختار جهانی را بهتر حفظ می‌کند.

پیچیدگی محاسباتی: t-SNE محاسبات سنگین‌تری دارد ($O(n^2)$) و برای داده‌های بزرگ کند است، در حالی که PCA و LDA سریع‌تر هستند. حساسیت به پارامترها: t-SNE به تنظیمات perplexity و نرخ یادگیری حساس است، که می‌تواند نتایج را تغییر دهد.

عدم قطعیت: t-SNE یک روش احتمالی است و نتایج ممکن است در هر اجرا متفاوت باشند، در حالی که PCA و LDA قطعی هستند.

مقایسه با PCA و LDA:

PCA (بخش ج): PCA واریانس کل را حداکثر می‌کند و ساختار جهانی را حفظ می‌کند، اما جداسازی کلاس‌ها ضعیف‌تر است (هم‌پوشانی زیاد در نمودار پراکندگی).

LDA (بخش ه): LDA بر جداسازی کلاس‌ها تمرکز دارد و به دلیل نظارت‌شده بودن، جداسازی بهتری نسبت به PCA ارائه می‌دهد، اما همچنان خطی است و ممکن است برای داده‌های غیرخطی مثل Fashion MNIST کافی نباشد.

t-SNE: در تجسم خوشه‌های محلی و جداسازی غیرخطی بهتر عمل می‌کند، اما برای وظایف کاهش ابعاد عمومی (مثلاً پیش‌پردازش برای یادگیری ماشین) مناسب نیست، در حالی که PCA و LDA کاربردهای گسترده‌تری دارند.