




گروه پژوهشی ایک



دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی برق - گروه مهندسی کنترل

یادگیری ماشین آزمون پایان ترم

نام و نام خانوادگی	علیرضا امیری
شماره دانشجویی	۴۰۲۰۲۴۱۴
تاریخ	شهریور ماه ۱۴۰۴



لینک کولب فایل

فهرست مطالب

۱	سوال ۱، سوالات هماهنگ شده	۱
۱	پاسخ سوال هماهنگ شده اول	۱.۱
۳	پاسخ سوال هماهنگ شده دوم	۲.۱
۶	پاسخ سوال ۶	۲
۶	الف	۱.۲
۱۲	ب	۲.۲
۱۴	ج	۳.۲
۱۶	د	۴.۲
۲۰	ه	۵.۲

۱ سوال ۱، سوالات هماهنگ شده

۱.۱ پاسخ سوال هماهنگ شده اول

برای داده‌هایی شامل C کلاس، ماتریس پراکنندگی بین کلاسی به صورت

$$S_B = \sum_{k=1}^C n_k (\mu_k - \mu)(\mu_k - \mu)^T$$

تعریف می‌شود. در این رابطه، μ_k میانگین کلاس k ، μ میانگین کلی داده‌ها، و n_k تعداد نمونه‌های هر کلاس است. برای اثبات کران بالای رتبه این ماتریس، ابتدا بردارهای اختلاف میانگین را تعریف می‌کنیم:

$$v_k = \mu_k - \mu, \quad k = 1, \dots, C.$$

در نتیجه می‌توان نوشت:

$$S_B = \sum_{k=1}^C n_k v_k v_k^T.$$

اکنون ماتریس

$$M = \begin{bmatrix} \sqrt{n_1} v_1 & \sqrt{n_2} v_2 & \cdots & \sqrt{n_C} v_C \end{bmatrix}$$

را در نظر می‌گیریم. این ماتریس ابعاد $d \times C$ دارد و داریم:

$$S_B = M M^T.$$

از این روترتهی S_B با رتهی M برابر است:

$$\text{rank}(S_B) = \text{rank}(MM^T) = \text{rank}(M).$$

حال نشان می‌دهیم که ستون‌های M وابستگی خطی دارند. طبق تعریف میانگین کلی:

$$\mu = \frac{1}{N} \sum_{k=1}^C n_k \mu_k, \quad N = \sum_{k=1}^C n_k.$$

با ضرب طرفین در N خواهیم داشت:

$$N\mu = \sum_{k=1}^C n_k \mu_k.$$

با انتقال جمله‌ها به یک طرف، رابطه‌ی زیر حاصل می‌شود:

$$\sum_{k=1}^C n_k \mu_k - \mu \sum_{k=1}^C n_k = 0.$$

از آنجا که $N = \sum_{k=1}^C n_k$ نتیجه می‌شود:

$$\sum_{k=1}^C n_k (\mu_k - \mu) = 0.$$

با جایگذاری $v_k = \mu_k - \mu$ ، رابطه به صورت زیر درمی‌آید:

$$\sum_{k=1}^C n_k v_k = 0.$$

این نشان می‌دهد که بردارهای v_k مستقل خطی نیستند و حداقل یک وابستگی میان آن‌ها وجود دارد. ستون‌های M نیز صرفاً نسخه‌های مقیاس‌شده از این بردارها هستند، بنابراین فضای ستونی M حداکثر بعدی برابر با $C - 1$ خواهد داشت.

نتیجه می‌گیریم:

$$\text{rank}(M) \leq C - 1 \implies \text{rank}(S_B) \leq C - 1.$$

در نتیجه، رتهی ماتریس پراکندگی بین‌کلاسی حداکثر برابر $C - 1$ است. این محدودیت ناشی از وابستگی خطی میان بردارهای اختلاف میانگین کلاس‌ها است و بدین ترتیب در روش LDA تعداد محورها مؤثر برای جداسازی کلاس‌ها نمی‌تواند بیش از $C - 1$ باشد.

TABLE 1 Modalities of the encoder and decoder in three methods.

Method	Encoder	Decoder
PCA	Linear	Linear
nPCA	Linear	Nonlinear
Autoencoder	Nonlinear	Nonlinear

شکل ۱: مقایسه روش های پیاده سازی pca

۲.۱ پاسخ سوال هماهنگ شده دوم

تحلیل مؤلفه های اصلی یا PCA یکی از متداول ترین روش های کاهش ابعاد خطی است که به طور گسترده در مصورسازی داده، کاهش نویز و استخراج ویژگی در داده های با ابعاد بالا مورد استفاده قرار می گیرد. با این حال، PCA دارای دو محدودیت ذاتی است: نخست آنکه جهت های بیشینه واریانس الزاماً معادل بیشینه نگهداشت اطلاعات نیستند، و دوم اینکه محاسبه ی آن از طریق تجزیه مقادیر منفرد (SVD) تنها یک بار انجام می شود و امکان اصلاح تدریجی ماتریس فرافکنی وجود ندارد.

به منظور غلبه بر این محدودیت ها، لی و وانگ (۲۰۲۴) روشی تحت عنوان nPCA پیشنهاد کرده اند که بازنویسی PCA در قالب یک شبکه عصبی است. در این رویکرد، PCA با استفاده از یک پرسپترون چندلایه (MLP) پیاده سازی می شود؛ به گونه ای که لایه ی رمزگذار خطی حفظ می شود و لایه ی رمزگشای غیرخطی وظیفه ی بازسازی داده را بر عهده می گیرد. این طراحی، مزیت تفسیرپذیری فرافکنی خطی را در کنار توانایی بهینه سازی تدریجی شبکه های عصبی ترکیب می کند.

اگرچه طبق این پژوهش استفاده از اتوانکودر نیز برای بازسازی PCA نیز قابل انجام است. با این حال با مقایسه ی این روش ها مطابق شکل ۴ مشاهده می کنیم که پیاده سازی این مدل با شبکه ی عصبی در قابل nPCA می تواند ساختار خطی انکودینگ را پوشش دهد




FIGURE 1
Structure of nPCA.

شکل ۲: nPCA

معماری nPCA به صورت زیر است: لایه‌ی ورودی دارای بعدی برابر با تعداد ویژگی‌های داده است. لایه‌ی پنهان اول تنها شامل دو نرون بوده و بدون تابع فعال‌ساز تعریف می‌شود تا تضمین شود که فراقکتی کاملاً خطی باقی می‌ماند. وزن‌های این لایه با بردارهای ویژه حاصل از SVD مقاداردهی اولیه می‌شوند و سپس در فرآیند آموزش با استفاده از الگوریتم SGD اصلاح می‌گردند. دو لایه‌ی پنهان بعدی هرکدام شامل ۳۲ نرون با توابع فعال‌ساز غیرخطی هستند که به عنوان رمزگشای غیرخطی عمل کرده و وظیفه‌ی بازسازی ورودی اصلی را بر عهده دارند. لایه‌ی خروجی ابعادی برابر با لایه‌ی ورودی دارد و بازسازی داده را تولید می‌کند. تابع هزینه به صورت میانگین مربعات خطا بین ورودی و خروجی تعریف شده و شبکه تا همگرایی آموزش می‌بیند. پس از اتمام آموزش، لایه‌های رمزگشا کنار گذاشته می‌شوند و تنها وزن‌های لایه‌ی رمزگذار به عنوان ماتریس فراقکتی جدید مورد استفاده قرار می‌گیرند.





FIGURE 2
Two-dimensional PCA and nPCA projection of the Anuran calls (MFCCs) dataset colored by a real label (family of Anuran).

شکل ۳: مقایسه ی تفکیک دو بعدی PCA و nPCA

این چارچوب موجب می شود nPCA جایگاهی میان روش های سنتی PCA و خودرمزگذارها داشته باشد. در حالی که PCA از رمزگذار و رمزگشای خطی استفاده می کند و خودرمزگذارها هر دو بخش را غیرخطی در نظر می گیرند، nPCA با رمزگذار خطی و رمزگشای غیرخطی طراحی شده است. بنابراین، هم تفسیرپذیری فراقکنی خطی حفظ می شود و هم بازسازی داده بهبود می یابد.

نتایج تجربی نشان داده اند که nPCA در هشت مورد از ده مجموعه داده عمومی توانسته است نسبت به PCA واریانس بیشتری از داده های خام را حفظ کند (جدول ۲). همچنین در داده های زیستی با ابعاد بالا، به ویژه در داده های توالی یابی تک سلولی RNA، عملکرد nPCA در شاخص های ارزیابی خوشه بندی نظیر ضریب سیلوئت و شاخص رند تعدیل شده به طور معناداری بهتر از سایر روش های خطی از جمله PCA، ICA و MDS گزارش شده است (جدول ۳). مقایسه های تصویری نیز نشان می دهند که فراقکنی های nPCA توانایی جداسازی خوشه هایی را دارند که در PCA و دیگر روش ها هم پوشانی پیدا می کنند (شکل های ۲ و ۳).

با وجود این، هزینه محاسباتی nPCA به دلیل نیاز به فرآیند آموزش، بیشتر از PCA سنتی است. علاوه بر آن، حساسیت به داده های پرت و مقادیر مفقود، مشابه PCA، همچنان باقی است. با این وجود، ترکیب فراقکنی خطی با بازسازی غیرخطی باعث شده است nPCA به عنوان یک نسخه ی مدرن شده از PCA، در حوزه هایی مانند تحلیل داده های زیستی با ابعاد بالا به ویژه داده های تک سلولی، جایگزین یا مکمل مناسبی برای PCA تلقی شود.



شکل ۴: توزیع داده ها در دستگاه ها

۲ پاسخ سوال ۶


۱.۲ الف

در بخش اول از این گزارش داده ها را به درون محیط پایتون فرا می خوانیم
می توان مشاهده کرد که داده های موجود در ذین دیتاست متشکل از ۷ کلاس دستگاه و ۹۲۶ نمونه و ۷۲ ویژگی استخراج شده هستند.




مشاهده می شود که ستون های و instrument name و dastgah ماهیتی از جنس ویژگی ندارند. بنابراین ابتدا ستون های لیبل را ایجاد کرده و سپس این ستون ها را از دیتاست حذف می کنیم.

سپس matirx correlation را برای این ویژگی ها رسم می کنیم.




شکل ۵: ماتریس همبستگی




شکل ۶: توزیع داده ها در دستگاه ها پس از افزایش نمونه ها

در ادامه داده ها را بر اساس داده های آموزشی نرمالایز کرده و سپس این نرمالیزه را به داده های تست منتقل می کنیم. علاوه بر این برای جبران عدم تناسب تعداد داده ها از روش oversampling برای تنظیم تعداد دقیق داده ها استفاده می شود. در این صورت داده های هر کلاس به صورت زیر خواهد بود




شکل ۷: lightgbm

سپس برای بررسی تاثیرگذاری هر یک از ویژگی ها از الگوریتم LightGBM استفاده کرده و نتیجه ی آن را می توانیم در شکل بعد مشاهده کنیم.




شکل ۸: Caption Enter




شکل ۹: Caption Enter

چنانچه مشاهده می شود بر اساس این نمودار ما می توانیم با تقریب مناسبی ۲۰ ویژگی اول را به عنوان تاثیر گذار ترین ویژگی ها انتخاب کنیم. با این حال با در نظر داشتن ادامه ی فرایند این پروژه که به اعمال pca منجر خواهد شد و یک مرحله کاهش ابعاد خواهیم داشت در اینجا از حذف تعداد زیاد ویژگی ها صرف نظر کرده و بنابراین ۵۰ ویژگی اول را نگه می داریم. با این روند pca اطلاعات بیشتری برای استخراج بهترین بردار ها در اختیار خواهد داشت. تا به اینجا ۵۰ ویژگی بهینه انتخاب شدند که در تصاویر زیر توزیع انها را می توانیم مشاهده کنیم.




شکل ۱۰: Caption Enter



شکل ۱۱: خروجی مدل های SVM


۲.۲ ب

در گام بعد پس از انتخاب این ویژگی ها و تعیین آنها به عنوان داده های آموزشی مدل های SVM با کرنل های خطی و غیر خطی را بر آن آموزش می دهیم و نتایج را در تصاویر زیر می توانیم مشاهده کنیم.



شکل ۱۲: مقایسه مدل های SVM


بر این اساس می توانیم نتیجه ی کرنل های مختلف را در این دیتا بررسی کنیم و چنانچه در نمودار زیر مشخص شده است می توان دریافت که کرنل RBF دقت بالاتری دارد.



شکل ۱۳: بهینه سازی هایپر پارامتر های SVM


۳.۲ ج

بنابراین در گام پیش کرنل RBF به عنوان کرنل برتر شناخته شد. حال با انجام فرایند Grid Search و اعمال Kfold از مرتبه ی ۵ به تنظیم هایپر پارامتر های این مدل SVM از قبیل C و Gamma خواهیم پرداخت.
با انجام این تحلیل می توانیم مقدار بهینه را به صورت زیر به دست آوریم.



شکل ۱۴: نتیجه پس SVM از بهینه سازی هایپر پارامترها


بنابراین برای مدل فعلی مقدار C برابر با ۱۰۰ و مقدار γ برابر با ۰.۱۰ در نظر گرفته می شود. حال با این پارامترها مجدداً مدل را آموزش می دهیم و نتیجه ی آن را در بخش زیر مشاهده می کنیم.




شکل ۱۵: pca

۴.۲ د

در بخش بعد نیاز است مدل pca را بر روی اعمال کنیم. با رسم pca در دو بعد و LDA در سه بعد نتایج زیر را به دست می آوریم.




شکل ۱۶: LDA



شکل ۱۷: مقایسه تغییر پارامترهای pca

در بخش بعدی نیاز است نه به منظور نمایش در دو بعد بلکه به منظور کاهش ابعاد ویژگی‌ها به وسیله ی pca مقدار بهینه ی تعداد کامپوننت های این الگوریتم را مشخص کنیم. بنابراین در یک حلقه هر بار مقدار n را تغییر داده و سپس در هر حلقه مدل svm را بر روی آن آموزش می دهیم و سپس نتایج را بررسی می کنیم.



شکل ۱۸: نتیجه مدل پس از بهینه سازی پارامتر pca

با این تغییر مشاهده می شود که بهترین میزان برای این پارامتر مقدار ۲۲ بوده و با این مقدار یک مدل آموزش داده می شود که نتایج آن را در یخس زیر مشاهده می کنیم



۵.۲ ه


در این بخش به قسمت اول از پروژه برگشته و ویژگی های جدیدی را ایجاد می کنیم. این ویژگی ها به شرح زیر هستند.

جدول ۱: ویژگی های افزوده شده از دیتاست پایه


گروه ویژگی	توضیح
MFCC Delta Features	اختلاف بین ضرایب میانگین و واریانس MFCC های مجاور.
MFCC Energy	مجموع قدر مطلق ضرایب میانگین MFCC (انرژی کلی تمبر).
Chroma Entropy	آنتروپی بردار نرمال شده ی کرما برای اندازه گیری پراکندگی گام ها.
Spectral Spread	تقریب پهنای باند طیفی (rolloff - centroid).
Spectral Skewness	نسبت انحراف معیار طیفی به میانگین سنترئوید (spectral shape).

در نتیجه با طی فرایند مجدد که در بخش های پیشین توضیح داده شد در پایان این بخش نتیجه ی زیر را برای مدل به دست خواهیم آورد که مشاهده می شود از مقدار ۴۸ درصد به مقدار ۵۳ درصد ارتقا یافته است.

در ادامه به آموزش یک مدل اتوانکودر برای این داده ها خواهیم پرداخت. ساختار مدل طراحی شده به صورت زیر خواهد بود.



شکل ۱۹: ساختار مدل اتوانکدر



شکل ۲۰: نتایج مدل پس از استخراج ویژگی با اتوانکدر

با در نظر گرفتن خروجی های این مدل به عنوان فیچر ها و آموزش مدل SVM بر آن به دست خواهیم آورد.

```
# 5) Scale with existing scaler
X_test_scaled = scaler.transform(X_test)

# 6) Select same top-50 features
X_test_top50 = X_test_scaled[:, sorted_idx[:50]]

# 7) Apply existing PCA (already fitted on train top-50)
X_test_pca = pca.transform(X_test_top50)

# 8) Predict with trained SVM
y_pred = best_svm.predict(X_test_pca)

# 9) Evaluation (if labels exist)
print("Pred :", y_pred[:20])
```

[33] ✓ 0.0s

... Pred : [2]

شکل ۲۱: پیش بینی مدل از نمونه انتخابی

در این بخش می توانیم نتیجه بگیریم که مدلی که بر مبنای pca آموزش دیده است بهترین عملکرد را داشته است. بنابراین از این مدل و وزن های به دست آمده برای آن در مرحله های مختلف استفاده کرده تا بتوانیم در نهایت نمونه ی مورد نظر را تشخیص دهیم. به طور خلاصه تبدیل هایی که بر این نمونه اعمال شده است عبارتند از:

جدول ۲: مراحل پردازش و پیش بینی روی داده ی نمونه

گام	توضیح
Feature Engineering	افزودن ویژگی های جدید با تابع generate_extra_features.
Drop Non-Features	حذف ستون های name, instrument, dastgah.
Align Columns	هم تراز کردن ستون ها با ترتیب داده های آموزشی.
Scaling	نرمال سازی با StandardScaler آموزش دیده.
Feature Selection	انتخاب ۵۰ ویژگی برتر بر اساس اهمیت LightGBM.
PCA Transformation	کاهش بُعد با PCA آموزش دیده (۲۸ مؤلفه).
SVM Prediction	پیش بینی برچسب ها با مدل RBF SVM بهینه شده.

با اعمال این فرایندها بر نمونه مشاهده می کنیم که مدل توانسته به درستی کلاس مدل را در دسته ی دو معادل با دستگاه ماهور قرار دهد.