




گروه پژوهشی ایک



دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی برق - گروه مهندسی کنترل

گزارش پروژه نهایی یادگیری ماشین
حل مسئله سینماتیک وارون در سیستم MLPM با استفاده
از روش های یادگیری ماشین

نام و نام خانوادگی	علیرضا امیری
شماره دانشجویی	۴۰۲۰۲۴۱۴
تاریخ	شهریور ماه ۱۴۰۴



لینک کولب فایل

فهرست مطالب

۱	چکیده	۱
۱	مقدمه	۲
۲	۱.۲ روابط سینماتیک مستقیم	۲
۴	۲.۲ بصری سازی نگاشت پیش سو در نقطه ی تکین	۴
۸	۳.۲ روابط سینماتیک وارون Gamma Inverse	۸
۸	۱.۳.۲ تولید دیتاست شبیه سازی شده با سیمولینک	۸
۱۰	۲.۳.۲ تحلیل داده های جریان در دیتاست شبیه سازی شده	۱۰
۱۴	۳.۳.۲ تحلیل داده های نیروی-گشتاور در دیتاست شبیه سازی شده	۱۴
۱۶	۳ رویکرد طبقه بندی جریان ها	۱۶
۲۲	۴ پیش بینی الگوهای جریان به جای مقادیر یا کلاس های مستقل	۲۲
۲۶	۵ پیش بینی الگوهای جریان (Coil) Patterns	۲۶
۳۱	۶ آزمایش یادگیری تقویتی با Soft Actor-Critic (SAC)	۳۱
۳۱	۱.۶ محیط شبیه سازی (Environment)	۳۱
۳۱	۲.۶ عامل یادگیر (SAC Agent)	۳۱
۳۲	۳.۶ فهرست ابر پارامترها	۳۲
۳۲	۴.۶ نتایج	۳۲
۳۵	۵.۶ جمع بندی	۳۵
۳۵	۷ آموزش مدل PINN	۳۵
۳۵	۱.۷ تولید دیتاست مصنوعی	۳۵
۳۹	۲.۷ شبه معکوس آستانه گذاری شده و فضای تهی به صورت بچ دار	۳۹
۴۱	۳.۷ الگوریتم CMA-ES (استراتژی تکاملی ماتریس کوواریانس)	۴۱
۴۲	۴.۷ توابع هزینه برای آموزش مدل جریان ها	۴۲
۴۴	۵.۷ مدل Physics-Informed Nullspace Network	۴۴
۴۵	۶.۷ فرآیند آموزش مدل Physics-Informed Nullspace Net	۴۵



۱ چکیده

این پروژه به بررسی و حل مسئله سینماتیک وارون در یک سامانه‌ی معلق مغناطیسی با ۱۶ سیم‌پیچ کنترلی می‌پردازد؛ سامانه‌ای که به دلیل افزونگی بالا، دارای بی‌نهایت پاسخ جریان برای تولید نیروی-گشتاور مطلوب است. در این کار ابتدا یک دیتاست واقع‌گرایانه با استفاده از شبیه‌سازی سیمولینک و حل بهینه‌ی مسئله با دستور lsqin متلب تولید شد تا قیود فیزیکی جریان‌ها رعایت گردد و پوشش کامل فضای کاری تضمین شود. سپس تحلیل آماری و تصویری روی داده‌های جریان و نیروی-گشتاور انجام گرفت. در ادامه، چندین رویکرد یادگیری ماشین شامل طبقه‌بندی جریان‌ها، پیش‌بینی الگوهای جریان، و یادگیری تقویتی با الگوریتم Soft Actor-Critic (SAC) مورد آزمایش قرار گرفت. نتایج نشان دادند که مدل‌های مستقیم در بازتولید مقادیر جریان دقت کافی ندارند و الگوهای جریان نیز به دلیل هم‌پوشانی بالا جدایی‌پذیر نیستند. با این حال، مدل پیشنهادی مبتنی بر شبکه‌ی عصبی و پروجکشن فضای تهی (Physics-Informed Nullspace Net) توانست با در نظر گرفتن توابع هزینه‌ی فیزیکی (هموارسازی، محدودیت دامنه، اسپارسیته و خطای نیروی-گشتاور)، بازتولید دقیقی از خروجی نیروی-گشتاور ارائه دهد، هرچند جریان‌ها دقیقاً منطبق با مقادیر مرجع نبودند. مقایسه‌ی این مدل با روش شبه‌معکوس نشان داد که اگرچه هر دو از نظر دقت نیروی-گشتاور عملکرد مشابهی دارند، مدل پیشنهادی جریان‌های هموارتری با قله‌های بالاتر و پراکندگی کمتر تولید می‌کند. در نهایت، این پژوهش اثبات می‌کند که روش یادگیری مبتنی بر فضای تهی در مواردی که اهداف ثانویه یا قیود اضافی مطرح باشند، برتری خود را نشان داده و می‌تواند به‌عنوان ابزاری مکمل در کنار شبه‌معکوس مورد استفاده قرار گیرد.

۲ مقدمه

موتورهای صفحه‌ای مغناطیسی (Magnetically Levitated Planar Motors, MLPM) یکی از فناوری‌های نوظهور در حوزه جابجایی و کنترل بی‌تماس اجسام محسوب می‌شوند. در این سامانه‌ها، با عبور جریان‌های کنترلی از مجموعه‌ای از سیم‌پیچ‌ها، میدان مغناطیسی تولید شده و برهم‌کنش آن با آرایه‌های مغناطیسی Halbach منجر به ایجاد نیرو و گشتاور در راستاهای مختلف می‌گردد. مزیت اصلی این معماری، دستیابی به حرکت در شش درجه آزادی (سه انتقالی و سه دورانی) با دقت و پایداری بالا و بدون تماس مکانیکی است [۱].

یکی از ویژگی‌های مهم این نوع سامانه‌ها، افزونگی کنترلی است. به عنوان مثال، در یک پلتفرم شامل ۱۶ سیم‌پیچ فعال، هدف اصلی تولید سه نیروی خطی و سه گشتاور است. این موضوع سبب می‌شود که دستگاه به شدت بیش‌محرك (over-actuated) باشد و در نتیجه، برای یک وضعیت معین، بی‌نهایت ترکیب جریانی وجود داشته باشد که همان خروجی مطلوب را ایجاد می‌کند. این افزونگی از یک سو مزایای انعطاف‌پذیری و بهینه‌سازی دارد، اما از سوی دیگر مسئله حل معکوس کینماتیک یا همان γ inverse را به یک چالش اساسی تبدیل می‌سازد.

روش‌های کلاسیک برای حل این مسئله، مبتنی بر ماتریس ژاکوبین و شبه‌معکوس آن هستند [۲]. اگرچه این روش‌ها قادر به یافتن پاسخ‌های اولیه می‌باشند، اما در شرایطی که ماتریس ژاکوبین رتبه کامل نداشته باشد یا سامانه در حالت تکینگی قرار گیرد، نتایج بهینه و فیزیکی حاصل نمی‌شوند. همچنین استفاده از الگوریتم‌های بهینه‌سازی عددی مقید می‌تواند جواب‌های دقیق‌تری ارائه دهد، اما این روش‌ها به دلیل ماهیت تکراری خود، برای پیاده‌سازی بلادرنگ مناسب نیستند [۳].

به همین دلیل، پژوهش‌های متعددی به سمت بهره‌گیری از روش‌های هوشمند و یادگیری ماشین برای حل معکوس کینماتیک سامانه‌های افزون حرکت رفته‌اند. استفاده از شبکه‌های عصبی، روش‌های یادگیری تقویتی و چارچوب‌های ترکیبی از الگوریتم‌های تکاملی و مدل‌های داده‌محور، از جمله تلاش‌های انجام‌شده در این زمینه است [۴]-[۶]. چالش اصلی در این حوزه، وجود فضای null با درجه آزادی بالا است که می‌تواند مدل‌های یادگیرنده را به سمت مینیمم‌های محلی و پاسخ‌های نامطلوب سوق دهد. در همین راستا، برخی پژوهش‌ها با ادغام قیدهای ایمنی و ساختارهای سلسله‌مراتبی در یادگیری تقویتی، سعی در هدایت عامل به سمت پاسخ‌های پایدار داشته‌اند [۷]، [۸].

با این حال، یکی از رویکردهای نوآورانه، آموزش مستقیم مدل برای شناخت فضای تهی (null space) و انتخاب ترکیب‌های بهینه جریان از میان پاسخ‌های بی‌شمار ممکن است. چنین راهبردی می‌تواند علاوه بر تضمین پایداری، قابلیت استفاده بلادرنگ در حلقه‌های کنترلی را نیز فراهم سازد. در این پروژه، با مرور ادبیات موجود و تحلیل رویکردهای پیشین، چارچوبی ترکیبی مبتنی بر یادگیری و بهینه‌سازی ارائه می‌گردد که توانایی جایگزینی

ماژول γ inverse در سامانه واقعی را خواهد داشت.

۱.۲ روابط سینماتیک مستقیم

در این بخش، معادلات ریاضی مربوط به نگاشت پیش سو که آن را با Γ نمایش می‌دهیم، ارائه می‌شود. نگاشت Γ جریان‌های سیم‌پیچ‌ها را به نیرو و گشتاور وارد بر آرایه‌ی Halbach مرتبط می‌سازد. به طور کلی، اگر بردار وضعیت جسم معلق شامل مکان و زوایای اویلر باشد، آنگاه می‌توان به صورت زیر آن را نمایش داد:

$$\mathbf{p} = [x_m \quad y_m \quad z_m \quad \alpha \quad \beta \quad \gamma]^T \in \mathbb{R}^6, \quad (1)$$

که در آن (x_m, y_m, z_m) مختصات مرکز جسم و (α, β, γ) به ترتیب زوایای دوران حول محورهای x, y, z هستند. ابتدا ماتریس‌های دوران حول سه محور تعریف می‌شوند:

$$R_x(\alpha) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \alpha & -\sin \alpha \\ 0 & \sin \alpha & \cos \alpha \end{bmatrix}, \quad (2)$$

$$R_y(\beta) = \begin{bmatrix} \cos \beta & 0 & \sin \beta \\ 0 & 1 & 0 \\ -\sin \beta & 0 & \cos \beta \end{bmatrix}, \quad (3)$$

$$R_z(\gamma) = \begin{bmatrix} \cos \gamma & -\sin \gamma & 0 \\ \sin \gamma & \cos \gamma & 0 \\ 0 & 0 & 1 \end{bmatrix}. \quad (4)$$

سپس ماتریس دوران کلی از ترکیب سه ماتریس بالا به دست می‌آید:

$$R = R_z^T(\gamma) R_y^T(\beta) R_x^T(\alpha) \in \mathbb{R}^{3 \times 3}. \quad (5)$$

برای هر سیم‌پیچ با موقعیت $\mathbf{c}_i = [c_{ix}, c_{iy}, c_{iz}]^T$ ، بردار اختلاف موقعیت بین سیم‌پیچ و مرکز جسم برابر است با:

$$\Delta \mathbf{r}_i = \begin{bmatrix} c_{ix} - x_m \\ c_{iy} - y_m \\ c_{iz} - z_m \end{bmatrix}. \quad (6)$$

این بردار با استفاده از ماتریس دوران به دستگاه مختصات جسم منتقل می‌شود:

$$\mathbf{c}'_i = R \Delta \mathbf{r}_i = \begin{bmatrix} c'_{ix} \\ c'_{iy} \\ c'_{iz} \end{bmatrix}. \quad (۷)$$

برای تعریف ضرایب، داریم:

$$\eta_x = \frac{\pi}{\tau} c'_{ix}, \quad \eta_y = \frac{\pi}{\tau} c'_{iy}, \quad (۸)$$

$$K_x = \alpha_x e^{\beta_k c'_{iz}}, \quad K_y = \alpha_y e^{\beta_k c'_{iz}}, \quad K_z = \alpha_z e^{\beta_k c'_{iz}}. \quad (۹)$$

نیروهای تولیدشده توسط سیم پیچ i عبارتند از:

$$F_x = K_x \cos(\eta_x) \sin(\eta_y), \quad (۱۰)$$

$$F_y = K_y \sin(\eta_x) \cos(\eta_y), \quad (۱۱)$$

$$F_z = K_z \sin(\eta_x) \sin(\eta_y). \quad (۱۲)$$

علاوه بر این، برای گشتاورهای مؤثر، ضرایب اصلاحی تعریف می‌شوند:

$$m_1 = \alpha_{m1} c'_{iz} + \beta_{m1}, \quad m_2 = \alpha_{m2} c'_{iz} + \beta_{m2}, \quad n = \frac{\pi}{\tau}, \quad (۱۳)$$

و بازوهای مؤثر به صورت زیر محاسبه می‌شوند:

$$r_{x1} = c'_{ix} - m_1 \tan\left(nc'_{ix} + \frac{\pi}{2}\right), \quad (۱۴)$$

$$r_{x2} = c'_{ix} - m_2 \tan\left(nc'_{ix} + \frac{\pi}{2}\right), \quad (۱۵)$$

$$r_{y1} = c'_{iy} - m_1 \tan\left(nc'_{iy} + \frac{\pi}{2}\right), \quad (۱۶)$$

$$r_{y2} = c'_{iy} - m_2 \tan\left(nc'_{iy} + \frac{\pi}{2}\right), \quad (۱۷)$$

$$r_{z1} = -c'_{iz} - \alpha_{rz}, \quad (۱۸)$$

$$r_{z2} = -c'_{iz} - \alpha_{rz}. \quad (۱۹)$$

در نهایت، گشتاورهای حاصل برابر خواهند بود با:

$$T_x = r_{y1} F_z - r_{z1} F_y, \quad (۲۰)$$

$$T_y = -r_{x1} F_z + r_{z2} F_x, \quad (۲۱)$$

$$T_z = r_{x2} F_y - r_{y2} F_x. \quad (۲۲)$$

بنابراین خروجی کامل سیم پیچ i در دستگاه معلق برابر است با:

$$\gamma_i = \begin{bmatrix} F_x & F_y & F_z & T_x & T_y & T_z \end{bmatrix}^T \in \mathbb{R}^6. \quad (23)$$

با کنار هم قرار دادن نتایج برای همه N سیم پیچ، نگاشت کلی به شکل زیر تعریف می شود:


$$\Gamma(\mathbf{p}) = \begin{bmatrix} \gamma_1 & \gamma_2 & \dots & \gamma_N \end{bmatrix} \in \mathbb{R}^{6 \times N}. \quad (24)$$

این ماتریس Γ ، توصیف کننده ی رابطه ی پیش سو بین جریان های سیم پیچ ها و نیروها و گشتاورهای اعمالی بر آرایه ی Halbach است.

۲.۲ بصری سازی نگاشت پیش سو در نقطه ی تکین

برای تکمیل معرفی معادلات نگاشت پیش سو، یک نقطه ی تکین انتخاب شد که در آن زوایای α و β برابر صفر هستند. در این نقطه، جریان های بهینه اعمال گردیدند و خروجی نیرو-گشتاور حاصل محاسبه شد. هدف از این تحلیل آن است که نشان داده شود مدل های یادگیری در مراحل بعدی باید قادر باشند این رفتار را نیز تقلید کنند، حتی اگر نقطه ی تکین به طور کلی حالت خاص و غیرعمومی باشد. به عبارت دیگر، انتظار می رود هر مدل پیشنهادی نه تنها در نقاط عادی بلکه در شرایط تکین نیز رفتار صحیح داشته باشد.


شکل ۱ توزیع نیرو-گشتاور تولید شده در این نقطه را نشان می دهد. همان طور که مشاهده می شود، هر مؤلفه ی نیرو و گشتاور الگوی مشخصی دارد که باید توسط مدل بازتولید شود.




شکل ۱: خروجی نیرو-گشتاور در نقطه ی تکین با جریان های بهینه

مقایسه‌ی حالت اشباع و بدون اشباع به‌عنوان نمونه‌ی دیگر، حالتی بررسی شد که در آن نیروی هدف $F_z = 1 \text{ N}$ تعریف شد:

- در حالت بدون اشباع، شکل ۲ نشان می‌دهد که مؤلفه‌ی F_z به‌درستی تولید شده و سایر مؤلفه‌ها نزدیک صفر هستند.
- در حالت با اشباع جریان‌ها (± 10 آمپر)، شکل ۳ نشان می‌دهد که اگرچه مؤلفه‌ی اصلی F_z همچنان غالب باقی مانده است، ولی سایر مؤلفه‌ها نیز مقداری غیرصفر تولید کرده‌اند. این همان محدودیتی است که در عمل وجود دارد و باید توسط مدل‌های آموزشی نیز بازنمایی شود.



شکل ۲: خروجی نیروی-گشتاور در حالت بدون اشباع برای نیروی هدف در راستای Z



شکل ۳: خروجی نیروی-گشتاور در حالت اشباع جریان‌ها (± 10 آمپر) برای همان ورودی

جمع‌بندی این نتایج نشان می‌دهد که داده‌های آموزشی باید شامل چنین توزیع‌هایی باشند تا مدل نهایی بتواند رفتار واقعی سامانه را تقلید کند. به‌ویژه، مدل باید قادر باشد بین حالت ایده‌آل (بدون اشباع) و حالت عملی (با اشباع) تمایز قائل شود و همچنان مؤلفه‌ی اصلی نیروی هدف را غالب نگه دارد.

۳.۲ روابط سینماتیک وارون Gamma Inverse

پس از تعریف نگاشت پیش‌سو $\Gamma(p) \in \mathbb{R}^{6 \times 16}$ که بردار جریان‌های کوپل‌ها را به بردار نیروی-گشتاور $w \in \mathbb{R}^6$ نگاشت می‌کند، اکنون مسئله‌ی اصلی یافتن نگاشت معکوس است. در این حالت، هدف یافتن بردار جریان‌ها $i \in \mathbb{R}^{16}$ برای یک وضعیت $p \in \mathbb{R}^6$ و نیروی-گشتاور مطلوب $w \in \mathbb{R}^6$ است.

$$\Gamma(p) i = w, \quad \Gamma(p) \in \mathbb{R}^{6 \times 16}, i \in \mathbb{R}^{16}, w \in \mathbb{R}^6. \quad (25)$$

به طور خلاصه، نگاشت پیش‌سو Γ از جریان‌های کوپل‌ها به بردار نیروی-گشتاور به صورت زیر تعریف می‌شود:

$$\Gamma : \mathbb{R}^{16} \rightarrow \mathbb{R}^6, \quad i \mapsto w. \quad (26)$$

حال مسئله‌ی اصلی یافتن نگاشت معکوس Γ^{-1} است. از دید ریاضی، Γ^{-1} یک نگاشت چندارزشی است که از فضای وضعیت و نیروی-گشتاور به فضای جریان‌ها نگاشت می‌کند:

$$\Gamma^{-1} : \mathbb{R}^6 \times \mathbb{R}^6 \rightarrow \mathbb{R}^{16}, \quad (p, w) \mapsto i. \quad (27)$$

از آنجا که Γ دارای رتبه‌ی کامل نیست و ابعاد آن 6×16 است، این نگاشت یکتا نبوده و مجموعه‌ای بی‌نهایت از پاسخ‌ها را تولید می‌کند. یک فرم کلی از جواب به صورت زیر بیان می‌شود:

$$i = \Gamma(p)^+ w + N z, \quad (28)$$

که در آن: $\Gamma(p)^+$ شبه‌معکوس Moore-Penrose است؛ $N \in \mathbb{R}^{16 \times 10}$ پایه‌ی فضای تهی (null space) است؛ $z \in \mathbb{R}^{10}$ بردار ضرایب آزاد است که درجه‌های آزادی افزونه را نمایش می‌دهد. بنابراین، Γ^{-1} در واقع یک خانواده‌ی نگاشت است که از میان آن‌ها باید با استفاده از معیارهای بهینگی و قیود فیزیکی جریان مناسب انتخاب شود.

۱.۳.۲ تولید دیتاست شبیه‌سازی شده با سیمولینک

در کنار تولید دیتاست مصنوعی تصادفی (بخش قبل)، می‌توان با استفاده از شبیه‌سازی سامانه در محیط Simulink یک دیتاست واقع‌گرایانه‌تر تولید کرد. در این حالت، مدل دینامیکی سیستم محرک‌ها اجرا می‌شود و پاسخ واقعی جریان‌ها استخراج می‌گردد. منطق کلی به صورت زیر است:

۱. تعریف سیگنال‌های ورودی در ابتدای شبیه‌سازی، بازه‌های مختلف برای وضعیت و نیروی-گشتاور در نظر گرفته می‌شوند:

- موقعیت‌ها: x_m به صورت رمپ بین $[-0.15, 0.15]$ متر تغییر می‌کند؛ y_m به صورت مقادیر پله‌ای گسسته (۷ مقدار) تست می‌شود؛ z_m ثابت است.

- زوایا: $\alpha, \beta, \gamma \in \{-5^\circ, 0, +5^\circ\}$.

- بردارهای نیروی-گشتاور: شامل مجموعه‌ی پایه (بردارهای واحد در هر جهت از فضا) و همچنین حدود ۲۰ بردار تصادفی نرمال‌شده روی کره‌ی واحد:

$$\mathcal{W} = \{\mathbf{e}_1, \dots, \mathbf{e}_6\} \cup \{\mathbf{w}_1, \dots, \mathbf{w}_{20}\}, \quad \|\mathbf{w}_i\|_2 = 1.$$

۲. حلقه‌ی شبیه‌سازی برای هر ترکیب از y_m ، زوایا (α, β, γ) و نیروی-گشتاور $\mathbf{w}$:

۱. سیگنال وضعیت $\mathbf{p}(t)$ و سیگنال نیروی-گشتاور $\mathbf{w}(t)$ به صورت timeseries ساخته و به محیط Simulink داده می‌شود.

۲. مدل Simulink اجرا می‌شود (sim('Actuator_Investigation')) تا پاسخ باز حلقه‌ی جریان‌ها محاسبه گردد.

۳. جریان‌های خروجی از لاگ سیگنال‌ها استخراج می‌شوند: $\mathbf{i}(t) \in \mathbb{R}^{16}$.

۴. در صورت نیاز جریان‌ها مجدداً نمونه‌برداری (resample) می‌شوند تا هم‌طول با بردار زمان N باشند.

۳. استفاده از حل بهینه‌ی معکوس Γ در این دیتاست، به جای استفاده از شبه‌معکوس مرسوم Moore–Penrose، برای حل معکوس Γ از دستور lsqin در MATLAB استفاده می‌شود. این دستور مسئله‌ی کمترین مربعات با قیود جریان‌ها را حل می‌کند:

$$\mathbf{i}^* = \arg \min_{\mathbf{i}} \|\Gamma(\mathbf{p})\mathbf{i} - \mathbf{w}\|_2^2, \quad \text{s.t. } i_{\min} \leq i_k \leq i_{\max}, \quad k = 1, \dots, 16. \quad (29)$$

به این ترتیب، قیود سخت روی جریان‌های مجاز رعایت شده و جریان‌های فیزیکی و قابل اجرا تولید می‌شوند.

۴. ذخیره‌سازی نتایج برای هر شبیه‌سازی، داده‌ها شامل:

- وضعیت‌ها: $(x_m, y_m, z_m, \alpha, \beta, \gamma)$

- جریان‌های بهینه: $(I_1^*, \dots, I_{16}^*)$ به دست آمده از lsqin

- نیروی-گشتاور اعمالی: $\mathbf{w}_{\text{sim}} = \Gamma(\mathbf{p})\mathbf{i}^*$

به این صورت هم جریان‌های هدف برای آموزش در دسترس هستند و هم نیروی-گشتاور خروجی که برای راستی‌آزمایی مدل در آینده می‌تواند مورد استفاده قرار گیرد.

۵. پوشش کامل فضای کاری ایده‌ی اصلی این شبیه‌سازی، تولید دیتاستی است که پوشش کامل فضای کاری را فراهم کند. به همین دلیل:

- موقعیت‌ها و زوایا به صورت سیستماتیک پیمایش می‌شوند،

- مجموعه‌ی متنوعی از بردارهای نیروی-گشتاور آزمایش می‌شود،

- در نتیجه ترکیب‌های مختلف وضعیت-زاویه-نیرو کل فضای عملیاتی را پوشش می‌دهند.

۶. یکپارچه‌سازی و ذخیره در پایان، تمام داده‌ها پس از کنترل صحت ابعاد و هم‌راستاسازی، در فایل MATLAB ذخیره می‌شوند:

```
output_currents) input_data, save('actuator_dataset.mat',.
```

۷. مزیت این روش این نوع دیتاست بر اساس رفتار واقعی سیستم در محیط شبیه‌سازی شده به دست می‌آید. بنابراین:

- اثرات دینامیکی، تاخیرها و قیود سخت‌افزاری (مانند اشباع جریان‌ها) در داده‌ها منعکس می‌شوند،
 - جریان‌های بهینه با قیود فیزیکی محاسبه می‌شوند،
 - و نیروی-گشتاور ذخیره‌شده امکان بررسی صحت پیش‌بینی‌های مدل را فراهم می‌کند.
- در نتیجه مدل نهایی که روی این دیتاست آموزش می‌بیند، به واقعیت نزدیک‌تر و قابل‌اعتمادتر خواهد بود.

۲.۳.۲ تحلیل داده‌های جریان در دیتاست شبیه‌سازی شده

پس از تولید دیتاست دوم (شبیه‌سازی شده با سیمولینک و حل بهینه‌ی معکوس Γ)، لازم است داده‌ها مورد بررسی قرار گیرند تا الگوها و ویژگی‌های موجود بهتر درک شوند. در این بخش، نتایج تحلیل آماری و تصویری جریان‌های ۱۶ کانال ارائه شده است.

۱. توزیع جریان‌ها در هر کانال در شکل ۴ توزیع جریان‌های هر یک از ۱۶ کوئل نشان داده شده است. همان‌طور که دیده می‌شود:


- مقادیر جریان در اطراف صفر بیشترین تراکم را دارند.
- بخش قابل توجهی از جریان‌ها در مقادیر اشباع ± 10 آمپر قرار گرفته‌اند.
- در هر نمونه ترکیبی از جریان‌های نزدیک به صفر و جریان‌های اشباع شده مشاهده می‌شود.

۲. بررسی دامنه و الگوی کلی جریان‌ها شکل ۵ به صورت نمودار ویولن دامنه‌ی جریان‌ها را در هر کانال نشان می‌دهد. نتایج نشان می‌دهند:


- هر کانال مقادیر محدودی در بازه‌ی $[-10, +10]$ دارد.
- در کانال‌های ابتدایی مقادیر اشباع بیشتر رخ می‌دهند.
- با افزایش شماره‌ی کانال، اشباع کمتر و مقادیر نزدیک به صفر بیشتر دیده می‌شود؛ بدین معنا که کوئل‌های با شماره‌ی بالاتر کمتر فعال می‌شوند.

۳. همبستگی بین کانال‌ها شکل ۶ ماتریس همبستگی بین جریان‌های کانال‌ها را نمایش می‌دهد. هدف بررسی این بود که آیا برخی کانال‌ها همبستگی بالایی دارند و می‌توان مدل را ساده‌تر کرد. اما نتایج نشان می‌دهند:


- بیشتر نواحی ماتریس به رنگ سبز (مقادیر نزدیک به صفر) هستند.
- همبستگی معناداری بین کانال‌ها وجود ندارد.
- بنابراین نمی‌توان برخی کانال‌ها را حذف یا ادغام کرد بدون از دست دادن اطلاعات.



شکل ۴: توزیع جریان‌ها در هر کانال (هیستوگرام) برای دیتاست دوم




شکل ۵: نمودار ویولن جریان‌ها برای هر کانال در دیتاست دوم



شکل ۶: ماتریس همبستگی جریان‌ها بین کانال‌ها در دیتاست دوم

نقشه‌ی حرارتی جریان‌ها شکل ۷ نقشه‌ی حرارتی جریان‌های ۱۶ کوئل را برای ۱۰۰۰ نمونه‌ی تصادفی نشان می‌دهد. این نمایش مشخص می‌کند که جریان‌ها خروجی‌های مستقل نیستند، بلکه در کنار هم عمل کرده و نیروی-گشتاور نهایی را ایجاد می‌کنند. به همین دلیل، دیدن آن‌ها به صورت همزمان (و نه به صورت مجزا یا توزیع تک‌کاناله) بهترین راه برای درک رفتار واقعی سیستم و خروجی مدل است.



شکل ۷: نقشه‌ی حرارتی جریان‌های ۱۶ کوئل

۴. جمع‌بندی این تحلیل‌ها نشان می‌دهند که:


۱. جریان‌ها ترکیبی از مقادیر نزدیک صفر و اشباع هستند.
 ۲. کوپل‌های با شماره‌ی بالاتر کمتر فعال می‌شوند.
 ۳. بین کانال‌ها همبستگی مشخصی وجود ندارد و هر کانال رفتار مستقلی دارد.
- این نتایج اهمیت استفاده از مدل کامل را تأیید می‌کنند و نشان می‌دهند که ساده‌سازی ساختار با حذف برخی کانال‌ها منطقی نخواهد بود.

۳.۳.۲ تحلیل داده‌های نیروی-گشتاور در دیتاست شبیه‌سازی شده

علاوه بر بررسی جریان‌ها، نیروی-گشتاور خروجی نیز تحلیل شد تا بازه و توزیع آن مشخص شود.

۱. دامنه‌ی نیروی-گشتاور در شکل ۸ جعبه‌نمودار (Boxplot) برای هر یک از اجزای نیروی-گشتاور نمایش داده شده است. نتایج نشان می‌دهند:


- مؤلفه‌های نیرویی (F_x, F_y, F_z) دارای بازه‌های گسترده‌تری هستند.
- مؤلفه‌های گشتاوری (T_x, T_y, T_z) دارای دامنه‌های محدودتر هستند.
- این موضوع مطابق انتظار است، زیرا در ورودی مدل نیز نیروها در مقیاس بالاتری تعریف شده بودند.



شکل ۸: توزیع و دامنه‌ی نیروی-گشتاور (Boxplot) برای هر مؤلفه در دیتاست دوم

۲. همبستگی بین مؤلفه‌های نیروی-گشتاور در شکل ۹ ماتریس همبستگی بین اجزای نیروی-گشتاور را نشان می‌دهد. نتایج نشان می‌دهند:

- همبستگی قوی بین اجزای مختلف نیروها یا گشتاورها مشاهده نمی‌شود.
- برخی همبستگی‌های خفیف بین نیروها و گشتاورها وجود دارد، ولی کلیت ماتریس نزدیک به سبز (مقادیر نزدیک صفر) است.
- این امر نشان می‌دهد که هر مؤلفه به‌طور مستقل کنترل می‌شود و تداخل زیادی بین کانال‌ها وجود ندارد.



شکل ۹: ماتریس همبستگی بین اجزای نیروی-گشتاور در دیتاست دوم


۳ رویکرد طبقه‌بندی جریان‌ها

در این بخش، تلاش شد مسئله‌ی پیش‌بینی جریان‌های کویل به‌جای یک مسئله‌ی رگرسیون پیوسته، به‌صورت یک مسئله‌ی طبقه‌بندی (classification) مدل‌سازی شود. دلیل اصلی این انتخاب آن بود که در توزیع جریان‌ها مشاهده شد بخش عمده‌ای از داده‌ها حول سه حالت اصلی قرار دارند: جریان منفی اشباع (حدود -10 آمپر)، حالت خاموش (0 آمپر)، و جریان مثبت اشباع (حدود $+10$ آمپر). در نتیجه، می‌توان جریان هر کویل را در یکی از سه کلاس قرار داد:

$$(30) \quad \text{آمپر } +10 : I \approx +10 \text{ کلاس } 2, \quad \text{آمپر (خاموش) } 0 : I \approx 0 \text{ کلاس } 1, \quad \text{آمپر } -10 : I \approx -10 \text{ کلاس } 0$$


پیش‌پردازش داده‌ها ابتدا داده‌ها پاک‌سازی شدند و نمونه‌هایی که جریانشان از محدوده‌ی مجاز (± 10 آمپر) فراتر رفته بود حذف گردید. سپس ویژگی‌های اضافی (مانند سینوس و کسینوس زوایا) اضافه شد تا خاصیت تناوبی متغیرهای زاویه‌ای در داده‌ها حفظ شود.

توزیع مجموع جریان‌ها شکل ۱۰ توزیع مجموع قدرمطلق جریان‌ها را در کل نمونه‌ها نشان می‌دهد. این تصویر به ما حس بهتری از میزان کلی جریان عبوری از سیستم می‌دهد، که نمایش بهتری نسبت به جریان تک‌کاناله است.




شکل ۱۰: توزیع مجموع قدرمطلق جریان‌ها در دیتاست

کلاسترینگ جریان‌ها به کمک الگوریتم K-Means با سه خوشه، جریان‌ها خوشه‌بندی شدند. شکل ۱۱ نشان می‌دهد که این سه خوشه تقریباً منطبق بر مقادیر -10 ، 0 و $+10$ آمپر هستند و بنابراین ایده‌ی تبدیل مسئله به طبقه‌بندی تأیید می‌شود.



شکل ۱۱: خوشه‌بندی جریان‌ها با الگوریتم K-Means (سه خوشه)


توزیع کلاس‌ها برای هر کویل در شکل ۱۲ توزیع کلاس‌ها برای هر یک از ۱۶ کویل نشان داده شده است. این نتایج نشان می‌دهد که برخی کویل‌ها بیشتر در حالت خاموش بوده‌اند، در حالی که کویل‌های دیگر بیشتر در حالت فعال (رو به جلو یا رو به عقب) قرار داشته‌اند.



شکل ۱۲: توزیع کلاس‌ها در هر کویل (خاموش، جریان مثبت، جریان منفی)


مدل مبتنی بر **SIREN** و فیزیک‌محور مدل تعریف‌شده در این بخش یک معماری ترکیبی است که هم از شبکه‌های عصبی سینوسی (SIREN) و هم از روابط فیزیکی سیستم استفاده می‌کند. ورودی مدل شامل ویژگی‌های استخراج‌شده (n_{features}) و بردار نیروی-گشتاور هدف ($\mathbf{w} \in \mathbb{R}^6$) است. ابتدا با استفاده از لایه‌های SIREN نگاشت معکوس Γ^{-1} به صورت یک ماتریس (16×6) یاد گرفته می‌شود. سپس، به جای پیش‌بینی مستقیم جریان‌ها، یک عملگر فیزیکی (Dot product) بین این Γ^{-1} و بردار نیروی-گشتاور اعمال می‌شود تا جریان‌های ۱۶ کویل به دست آیند. در ادامه، برای هر کویل یک سر خروجی مجزا در نظر گرفته شده که با لایه‌های SIREN پردازش شده و در نهایت احتمال تعلق جریان به یکی از پنج کلاس را با تابع softmax ارائه می‌دهد. این ساختار باعث می‌شود که مدل نه تنها از داده‌های آموزشی یاد بگیرد، بلکه به طور صریح از ساختار فیزیکی سامانه (رابطه $\mathbf{i} = \Gamma^{-1}\mathbf{w}$) نیز بهره‌برد و بدین ترتیب هم دقت و هم قابلیت تفسیرپذیری بهبود یابد.

ماتریس اغتشاش مدل شکل ۱۳ ماتریس اغتشاش نرمال‌شده برای پیش‌بینی کلاس جریان در کویل ۱۶م را نشان می‌دهد. همان‌طور که دیده می‌شود، مدل به خوبی قادر است حالت خاموش (کلاس ۱) را تشخیص دهد، اما بین دو کلاس جریان مثبت و منفی دچار سردرگمی می‌شود. به عبارت دیگر، مدل توانسته است «خاموش/روشن بودن» کویل را یاد بگیرد، اما در تشخیص جهت جریان ضعیف عمل کرده است.



شکل ۱۳: ماتریس اغتشاش برای کویل ۱۶م در مسئله طبقه‌بندی

تاریخچه‌ی آموزش مدل شکل ۱۴ منحنی آموزش و اعتبارسنجی مدل را نشان می‌دهد. مدل همگرا شده و کاهش خطا متوقف شده است، که بیانگر این است که برای بهبود بیشتر باید بر جداسازی کلاس‌ها (مثلاً با استفاده از روش‌های PCA یا t-SNE) تمرکز شود.



شکل ۱۴: منحنی خطای آموزش و اعتبارسنجی مدل طبقه‌بندی

جمع‌بندی این آزمایش نشان داد که مدل می‌تواند حالت «خاموش بودن» کوپل را با دقت بالا شناسایی کند، اما در تشخیص جهت جریان (مثبت یا منفی) دچار اشتباه می‌شود. این موضوع نشان می‌دهد که برای جداسازی بهتر کلاس‌ها نیاز به استفاده از روش‌های کاهش بعد یا ویژگی‌های غنی‌تر وجود دارد.

تحلیل جدایی‌پذیری کلاس‌ها با t-SNE از آنجا که مدل‌های قبلی در پیش‌بینی مستقیم کلاس جریان‌ها موفقیت چندانی نداشتند، تصمیم گرفتیم بررسی کنیم که آیا خود کلاس‌های جریان‌ها (بدون توجه به ویژگی‌های ورودی) از هم جدایی‌پذیر هستند یا خیر. به همین منظور، تنها برچسب‌های جریان‌های ۱۶ کوپل در نظر گرفته شدند و تحلیل t-SNE برای نمایش جدایی‌پذیری کلاس‌ها در فضای دوبعدی انجام شد.


شکل ۱۶ نتایج این تحلیل را نشان می‌دهد. در این نمودارها رنگ‌ها نمایانگر کلاس‌ها هستند:

• کلاس ۰: جریان منفی اشباع (10- آمپر)،

• کلاس ۱: خاموش (۰ آمپر)،

• کلاس ۲: جریان مثبت اشباع (10+ آمپر).

از نتایج مشخص است که کلاس خاموش (کلاس ۱) تا حدی از دو کلاس دیگر جدا می‌شود، به‌ویژه در کوپل‌های با شماره‌های بالاتر، ولی این جداسازی در کوپل‌های ابتدایی کمتر قابل مشاهده است. در مقابل، دو کلاس جریان مثبت و منفی (کلاس‌های ۰ و ۲) به‌خوبی از یکدیگر تفکیک‌پذیر نیستند و به‌طور قابل‌توجهی هم‌پوشانی دارند. این موضوع نشان می‌دهد که تشخیص «خاموش بودن» کوپل نسبتاً آسان است، اما تشخیص جهت جریان چالش‌برانگیز باقی می‌ماند و همین امر کار طبقه‌بندی را دشوار می‌سازد.



شکل ۱۵: نتایج تحلیل t-SNE برای کلاس‌های جریان در ۱۶ کویل

۴ پیش‌بینی الگوهای جریان به‌جای مقادیر یا کلاس‌های مستقل

پس از مشاهده‌ی اینکه جریان‌های مستقل (یا حتی کلاس‌های آن‌ها) جدایی‌پذیری بالایی ندارند و مدل در پیش‌بینی دقیق آن‌ها دچار مشکل می‌شود، ایده‌ی جدیدی مطرح شد: به‌جای پیش‌بینی تک‌تک جریان‌ها، الگوهای جریان (یا patterns) را شناسایی کنیم. این الگوها مجموعه‌هایی از رفتار مشترک کوئل‌ها هستند که در عمل به‌طور تکراری در داده‌ها مشاهده می‌شوند.

منطق الگوریتم مراحل اصلی الگوریتم به شرح زیر است:

۱. ابتدا داده‌های جریان‌های کلاس‌بندی‌شده به‌صورت One-Hot کدگذاری شدند تا هر مقدار کلاس جریان (۰، ۱ یا ۲) به‌صورت بردار دودویی نمایش داده شود.

۲. برای کاهش ابعاد و جلوگیری از انفجار ویژگی‌ها، Truncated SVD اعمال شد و بردارهای ویژگی به حدود ۴۰ مؤلفه‌ی اصلی کاهش یافتند.

۳. سپس با استفاده از UMAP داده‌ها به فضای ۱۰ بعدی نگاشت شدند که هم ساختار محلی و هم ساختار کلی داده‌ها را حفظ می‌کند.

۴. روی این فضای کاهش‌یافته، یک مدل Gaussian Mixture Model (با شروع از خوشه‌بندی اولیه توسط MiniBatch K-Means) آموزش داده شد.


۵. برای تعیین تعداد بهینه‌ی خوشه‌ها، معیار BIC محاسبه شد و در نهایت مقدار $k = 20$ به‌عنوان تعداد خوشه‌ی بهینه انتخاب گردید.

۶. هر خوشه یک «الگوی پایه» یا Prototype محسوب شد. این پروتوتایپ‌ها بر اساس مد (بیشترین مقدار تکراری) هر ویژگی ساخته شدند.

۷. برای هر پروتوتایپ دو معیار گزارش شد:


- Support: درصد نمونه‌هایی که به این خوشه تعلق دارند.
- Stability: درصد نمونه‌های درون خوشه که با پروتوتایپ (مد) همسان هستند.

نتایج شکل ۱۶ الگوهای پایه‌ی جریان‌ها را نشان می‌دهد. در این تصویر هر ردیف یک پروتوتایپ (از ۲۰ پروتوتایپ) و هر ستون یک کوئل است. رنگ‌ها نشان‌دهنده‌ی کلاس جریان (۰: منفی، ۱: خاموش، ۲: مثبت) هستند. همان‌طور که دیده می‌شود، بسیاری از پروتوتایپ‌ها الگوهای متمایزی ایجاد کرده‌اند و نمونه‌های زیادی در دیتاست با این الگوها مطابقت دارند.




شکل ۱۶: ۲۰ پروتوتایپ اصلی جریان‌ها با مد هر ویژگی و مقادیر Support و Stability

در شکل ۱۷ سهم نسبی هر پروتوتایپ در دیتاست نشان داده شده است. به وضوح مشاهده می شود که برخی الگوها (مانند پروتوتایپ های ۱۰ و ۰) بیشترین سهم را دارند، در حالی که برخی دیگر سهم بسیار کمی دارند. این موضوع بیانگر آن است که تنها تعداد محدودی از الگوها بخش عمده ای از رفتار سامانه را پوشش می دهند.



شکل ۱۷: میزان مشارکت متوسط هر پروتوتایپ در کل دیتاست

شکل ۱۸ میانگین وزن های ترکیبی نمونه ها در هر خوشه را نمایش می دهد. این تصویر نشان می دهد که پروتوتایپ ها تا حد زیادی مستقل از یکدیگر عمل می کنند، زیرا اکثر خوشه ها به یک پروتوتایپ خاص وابسته اند و هم پوشانی کمی بین آن ها وجود دارد.



شکل ۱۸: میانگین وزن‌های ترکیبی نمونه‌ها برای هر خوشه و پروتوتایپ

در نهایت، شکل ۱۹ توزیع داده‌های واقعی به همراه پروتوتایپ متناظر آن‌ها را نشان می‌دهد. این مقایسه به‌خوبی تأیید می‌کند که بسیاری از نمونه‌های دیتاست به‌طور مستقیم با الگوهای شناسایی شده همخوانی دارند و بنابراین پیش‌بینی الگوهای جریان به‌جای مقادیر یا کلاس‌های مستقل می‌تواند راه‌حل ساده‌تر و مؤثرتری باشد.

۵ پیش‌بینی الگوهای جریان (Coil Patterns)

پس از شناسایی پروتوتایپ‌ها و مشاهده‌ی اینکه جریان‌ها و حتی کلاس‌های آن‌ها به‌سختی قابل پیش‌بینی هستند، ایده‌ی جدیدی مطرح شد: به‌جای پیش‌بینی مستقیم جریان هر کوئل، الگوی کلی جریان‌ها (Pattern) پیش‌بینی شود. این الگوها ترکیب‌های مشخصی از وضعیت کوئل‌ها بودند که در داده‌ها به‌طور مکرر تکرار می‌شدند.

ساخت مجموعه‌داده برای الگوها برای هر نمونه، بردار جریان‌های کلاس‌بندی شده به نزدیک‌ترین پروتوتایپ اختصاص داده شد. هر پروتوتایپ یک الگوی پایه‌ی جریان بود و هر نمونه می‌توانست ترکیبی خطی از چند پروتوتایپ باشد. به این ترتیب، هدف مدل تبدیل به پیش‌بینی برجسب پروتوتایپ (سخت یا نرم) شد. برای این کار:

- برجسب سخت (Y_{hard}) برابر با خوشه‌ی غالب نمونه تعریف شد.


- برجسب نرم (Y_{soft}) احتمال تعلق نمونه به هر الگو بود.

همچنین برای کاهش سوگیری، داده‌ها متوازن‌سازی شدند تا تعداد نمونه‌ها در هر الگو تقریباً برابر باشد.

آزمایش با رگرسیون لجستیک در گام نخست، یک مدل ساده‌ی Logistic Regression برای پیش‌بینی الگوها آموزش داده شد. همان‌طور که در شکل ۲۰ دیده می‌شود، این مدل کاملاً ناتوان بود و بیشتر نمونه‌ها را به یک الگو نسبت داد. این نتیجه نشان داد که ویژگی‌های موجود در داده‌ها قابلیت جداسازی الگوها را ندارند.




شکل ۱۹: مقایسه‌ی نمونه‌های واقعی دیتاست و پروتوتایپ‌های جریان




شکل ۲۰: ماتریس اغتشاش پیش‌بینی الگوها با مدل لجستیک

تحلیل جدایی‌پذیری با t -SNE برای بررسی بیشتر، داده‌ها با روش t -SNE به فضای دوبعدی نگاشت شدند. شکل ۲۱ نشان می‌دهد که ۲۰ الگو به‌طور کامل درهم‌تنیده هستند و هیچ مرزی بین آن‌ها وجود ندارد. این امر تأیید کرد که حتی با روش‌های غیرخطی کاهش‌بعد نیز جداسازی الگوها امکان‌پذیر نیست.



شکل ۲۱: نمایش دوبعدی داده‌ها با t -SNE و رنگ‌بندی بر اساس الگوها

نتایج مدل‌های ساده و شبکه‌ی عصبی حتی با استفاده از داده‌های متوازن و مدل‌های پیچیده‌تر، مانند شبکه‌های عصبی عمیق مبتنی بر SIREN، پیش‌بینی الگوها ناکام ماند. شکل ۲۲ و ؟؟ نتایج این مدل‌ها را نشان می‌دهند. در بهترین حالت، مدل تنها قادر به شناسایی یک الگوی خاص بود و سایر الگوها کاملاً با آن اشتباه گرفته شدند. این موضوع ثابت کرد که الگوهای جریان هم‌پوشانی بسیار بالایی دارند و به‌صورت قابل اطمینان جداسازی نمی‌شوند.



شکل ۲۲: ماتریس اغتشاش مدل شبکه‌ی عصبی برای پیش‌بینی الگوها

جمع بندی این بخش نشان داد که پیش بینی جریان ها در سطح تک کوئل یا حتی کلاس بندی آن ها امکان پذیر نیست و تعمیم آن به پیش بینی الگوهای کلی کوئل ها نیز نتیجه بخش نخواهد بود. دلیل اصلی، هم پوشانی شدید بین الگوها و عدم جدایی پذیری آن ها در فضای ویژگی است. بنابراین، این مسیر پژوهشی ادامه نیافت، زیرا مشخص شد که نه از طریق مدل های خطی و نه از طریق مدل های عمیق، پیش بینی الگوهای جریان به شکل قابل اطمینان امکان پذیر نیست.

۶ آزمایش یادگیری تقویتی با Soft Actor-Critic (SAC)

پس از ناکامی رویکردهای مبتنی بر رگرسیون و طبقه بندی، یک آزمایش مبتنی بر یادگیری تقویتی (Reinforcement Learning) طراحی شد تا سیاستی برای تولید جریان های کوئل بیاموزد. ایده ی اصلی این بود که حتی اگر یادگیری مستقیم نگاشت Γ^{-1} دشوار باشد، شاید با تعریف پاداش مناسب بتوان مدلی آموزش داد که با آزمون و خطا راهبرد مطلوب را کشف کند.

۱.۶ محیط شبیه سازی (Environment)

محیط Gym تعریف شده شامل موارد زیر بود:

- وضعیت (Observation): بردار شامل ویژگی های وضعیت و نیروی-گشتاور نرمال شده $(\mathbf{p}, \mathbf{w}) \in \mathbb{R}^{12}$.

- عمل (Action): بردار جریان های ۱۶ کوئل $\mathbf{i} \in [-10, 10]^{16}$.

- پاداش (Reward): بر اساس معیارهای زیر:

۱. خطای نیروی-گشتاور: $\|\Gamma(\mathbf{p})\mathbf{i} - \mathbf{w}\|_2$.

۲. رعایت محدودیت جریان ها ($|i_k| \leq 10$).

۳. همخوانی علامت جریان ها با جریان های واقعی (حداقل 80%).

۴. جریمه برای بزرگی جریان ها (تشویق به پراکندگی کمتر).

۵. جریمه بر اساس مؤلفه های فضای تهی برای رعایت معادلات فیزیکی.

در صورت موفقیت (خطای کم + قیود برقرار)، پاداش بزرگ مثبت 100+ اختصاص داده می شود؛ در غیر این صورت، ترکیبی از جریمه ها اعمال می گردید.

۲.۶ عامل یادگیر (SAC Agent)

عامل از الگوریتم Soft Actor-Critic استفاده می کرد:

- Actor: یک شبکه ی عصبی که جریان های ۱۶ کوئل را تولید می کند. خروجی در بازه ی $[-10, 10]$ محدود می شود. همچنین برای سازگاری با SAC توزیع گاوسی تعریف می شود.

- Critic: دو شبکه ی عصبی موازی (Q_1, Q_2) که ارزش عمل پیشنهادی را محاسبه می کنند.

- Buffer Replay: ذخیره ی تجربیات (s, a, r, s') برای نمونه برداری تصادفی و کاهش همبستگی داده ها.

منطق SAC الگوریتم SAC بر اساس بیشینه‌سازی بازده و آنتروپی عمل می‌کند:

$$J(\pi) = \sum_t \mathbb{E}_{(s_t, a_t) \sim \pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t))], \quad (31)$$

که در آن α ضریب وزن‌دهی به آنتروپی است. این باعث می‌شود سیاست به جای همگرایی به یک عمل قطعی، مجموعه‌ای متنوع از اعمال را حفظ کند.

۳.۶ فهرست ابرپارامترها

پارامتر	مقدار
تعداد کوئل‌ها (n_{coils})	۱۶
ابعاد وضعیت (pose) + wrench	۱۲
حداکثر جریان	$10 \pm$ آمپر
تعداد اپیزودها	۵۰۰
اندازه بافر	۵۰۰۰
اندازه دسته	۳۲
یادگیری Actor و Critic	$lr = 10^{-4}$ Adam.
ضریب (γ)	۹۹.۰
نرخ بروزرسانی هدف (τ)	۰.۵۰
ضریب آنتروپی (α)	۰.۱
وزن قیود فیزیکی	۰.۴۰
وزن تقلید (Supervised)	۵.۰

جدول ۱: ابرپارامترهای مورد استفاده در آموزش SAC


۴.۶ نتایج

پیشرفت پاداش‌ها شکل ۲۳ روند پاداش‌ها در طول اپیزودها را نشان می‌دهد. مقدار خام (آبی) نوسانات زیادی دارد و میانگین متحرک ۵۰ اپیزودی (نارنجی) تقریباً حول 600- ثابت مانده است. این امر نشان می‌دهد که عامل به سیاست پایدار و موفق همگرا نشده است.




شکل ۲۳: روند پاداش‌ها در طول آموزش SAC

پیش‌بینی جریان‌ها شکل ۲۴ جریان‌های واقعی و جریان‌های پیش‌بینی شده را برای یک نمونه نشان می‌دهد. هرچند جریان‌های پیش‌بینی شده در بازه‌ی مجاز $[-10, 10]$ قرار دارند و بعضی از آن‌ها به جریان‌های واقعی نزدیک هستند، اما الگوی کلی به‌درستی بازتولید نشده است.



شکل ۲۴: مقایسه‌ی جریان‌های واقعی و جریان‌های پیش‌بینی شده توسط SAC

پاداش تجمعی شکل ۲۵ پاداش تجمعی را در طول اپیزودها نشان می‌دهد. برخلاف انتظار که باید شیب منحنی در انتها به صفر نزدیک شود (بیانگر یادگیری پایدار)، منحنی همچنان با شیب نزولی ادامه دارد. این نتیجه تأیید می‌کند که عامل نتوانسته است سیاستی کارآمد بیاموزد.



شکل ۲۵: پاداش تجمعی در طول اپیزودها

۵.۶ جمع‌بندی

آزمایش یادگیری تقویتی با SAC نشان داد که:

- هرچند جریان‌های پیش‌بینی شده در محدوده‌ی فیزیکی معتبر باقی می‌مانند، دقت کافی در بازتولید جریان‌ها وجود ندارد.
 - پاداش‌ها پایدار نشده‌اند و سیاست یادگرفته‌شده همگرا نشده است.
 - حتی با اعمال قیود فیزیکی در تابع هزینه، یادگیری بهبود چشمگیری نداشته است.
- این نتایج بیانگر آن است که رویکرد یادگیری تقویتی در شرایط حاضر و با فضای عمل بزرگ (۱۶ خروجی پیوسته) کارایی کافی برای یادگیری معکوس Γ ندارد.

۷ آموزش مدل PINN

۱.۷ تولید دیتاست مصنوعی

در صورتی که داده‌های واقعی یا فایل CSV آماده وجود نداشته باشد، می‌توان یک دیتاست مصنوعی بر اساس مدل فیزیکی Γ تولید کرد. این فرآیند شامل مراحل زیر است:

۱. محدوده‌ی نمونه‌برداری

مقادیر ورودی در بازه‌های تصادفی تولید می‌شوند:

$$x_m \sim \mathcal{U}(-0.15, 0.15), \quad (32)$$

$$y_m \sim \mathcal{U}(-0.15, 0.15), \quad (33)$$

$$z_m = 0.005, \quad (34)$$

$$\alpha, \beta \sim \mathcal{U}\left(\frac{-5^\circ}{\text{rad}}, \frac{5^\circ}{\text{rad}}\right), \quad (35)$$

$$\gamma \sim \mathcal{U}(-\pi, \pi), \quad (36)$$

$$I_k \sim \mathcal{U}(-10, 10), \quad k = 1, \dots, 16. \quad (37)$$

۲. محاسبه‌ی نگاشت پیش‌سو

برای هر وضعیت $\mathbf{p} = (x_m, y_m, z_m, \alpha, \beta, \gamma)$ ، ماتریس پیش‌سو $\Gamma(\mathbf{p}) \in \mathbb{R}^{6 \times 16}$ محاسبه می‌شود.

۳. محاسبه‌ی نیروی-گشتاور

با داشتن جریان‌ها $\mathbf{i} \in \mathbb{R}^{16}$ ، نیروی-گشتاور حاصل برابر است با:

$$\mathbf{w} = \Gamma(\mathbf{p}) \mathbf{i}, \quad \mathbf{w} \in \mathbb{R}^6. \quad (38)$$

۴. ذخیره‌سازی داده‌ها

برای هر نمونه یک ردیف شامل موارد زیر ثبت می‌شود:

- مختصات و زوایا: $(x_m, y_m, z_m, \alpha, \beta, \gamma)$
- جریان‌های ۱۶ کویل: $(I_1, I_2, \dots, I_{16})$
- خروجی نیروی-گشتاور: $(w_1, w_2, \dots, w_6)$

این داده‌ها به صورت یک جدول در CSV ذخیره می‌شوند:

$$\text{CSV row} = \{\mathbf{p}, \mathbf{i}, \mathbf{w}\}. \quad (39)$$

۵. خروجی

در پایان، دیتاست تولیدشده یک مجموعه‌ی N -تایی از سه‌تایی‌ها خواهد بود:

$$\mathcal{D} = \{(\mathbf{p}^{(j)}, \mathbf{i}^{(j)}, \mathbf{w}^{(j)}) \mid j = 1, \dots, N\}. \quad (40)$$

۶. تحلیل داده‌های تولیدشده


برای بررسی کیفیت و توزیع داده‌های تولیدشده، مجموعه‌ای از تحلیل‌های آماری و بصری انجام شد. این تحلیل‌ها به درک بهتر از محدوده‌ی پوشش داده‌ها و توزیع جریان‌ها و نیرو-گشتاورها کمک می‌کند.

توزیع ویژگی‌ها و خروجی‌ها شکل ۲۶ توزیع متغیرهای ورودی (شامل $x, y, z, \alpha, \beta, \gamma$), خروجی‌های نیرو-گشتاور $(F_x, F_y, F_z, T_x, T_y, T_z)$ و نمونه‌هایی از جریان‌های کویل‌ها را نشان می‌دهد. همان‌طور که مشاهده می‌شود:


- توزیع مکانی و زاویه‌ای تقریباً یکنواخت است و فضای کاری به طور کامل پوشش داده شده است.
- نیروها و گشتاورها غالباً حول مقدار صفر متمرکز هستند ولی دارای دم‌های بلند بوده و مقادیر بزرگ نیز مشاهده می‌شود.
- جریان‌های کویل‌ها در محدوده $[-10, 10]$ آمپر پراکندگی کامل دارند که هم شامل مقادیر اشباع و هم مقادیر نزدیک صفر است.

تحلیل نیرو-گشتاور شکل ۲۷ مجموعه‌ای از تحلیل‌های تکمیلی نیرو-گشتاور را نشان می‌دهد:

- توزیع بزرگی نیرو-گشتاور نشان می‌دهد بیشتر داده‌ها در محدوده‌های کوچک متمرکز هستند.
- نسبت نیرو به گشتاور نشان‌دهنده‌ی آن است که نیروی خروجی معمولاً غالب بر گشتاور است.
- مقایسه‌ی بزرگی جریان‌ها و بزرگی نیرو-گشتاور بیانگر رابطه‌ی تقریباً خطی بین این دو است.
- توزیع جهت‌گیری نیروها و گشتاورها یکنواخت بوده و بیانگر پوشش کامل فضای سه‌بعدی است.



شکل ۲۶: توزیع ورودی‌ها، خروجی‌ها و جریان‌ها در دیتاست تولیدشده



شکل ۲۷: تحلیل آماری و توزیع نیرو-گشتاور در دیتاست



جمع‌بندی این تحلیل‌ها نشان می‌دهد دیتاست تولیدشده هم از نظر محدوده‌ی ورودی‌ها و هم از نظر توزیع خروجی‌ها متوازن است و پوشش مناسبی از فضای کاری فراهم می‌آورد. وجود مقادیر اشیاع، مقادیر نزدیک صفر و مقادیر متوسط در جریان‌ها و نیرو-گشتاورها تضمین می‌کند که مدل‌های یادگیری بتوانند طیف کامل رفتار سامانه را بیاموزند.

۲.۷ شبه‌معکوس آستانه‌گذاری شده و فضای تهی به صورت بیچدار

برای محاسبه‌ی نگاشت معکوس Γ^{-1} در حالت افزونه، از تجزیه‌ی مقدار منفرد (SVD) استفاده می‌کنیم. ورودی Γ در هر گام برابر است با:

$$\Gamma \in \mathbb{R}^{6 \times 16}. \quad (41)$$

گام اول: تجزیه‌ی مقدار منفرد

تجزیه‌ی SVD به صورت زیر نوشته می‌شود:

$$\Gamma = U \Sigma V^T, \quad (42)$$

که در آن:

- $U \in \mathbb{R}^{6 \times 6}$ ماتریس متعامد،
- $\Sigma \in \mathbb{R}^{6 \times 16}$ ماتریس قطری شامل مقادیر منفرد،
- $V \in \mathbb{R}^{16 \times 16}$ ماتریس متعامد راست است.

گام دوم: اعمال آستانه روی مقادیر منفرد

برای جلوگیری از ناپایداری عددی، مقادیر منفرد کوچک‌تر از یک آستانه‌ی نسبی صفر می‌شوند. آستانه به صورت زیر تعریف می‌شود:

$$\text{thresh} = \epsilon \cdot \max(s), \quad \epsilon = 10^{-3}, \quad (43)$$

و سپس بردار keep تعریف می‌شود:

$$\text{keep}_i = \begin{cases} 1 & s_i > \text{thresh}, \\ 0 & s_i \leq \text{thresh}. \end{cases} \quad (44)$$

در نهایت، معکوس مقادیر منفرد به صورت محدود محاسبه می‌شود:

$$s_i^{-1} = \begin{cases} \frac{1}{s_i} & s_i > \text{thresh}, \\ 0 & \text{otherwise}. \end{cases} \quad (45)$$

گام سوم: محاسبه شبه معکوس

شبه معکوس Moore–Penrose آستانه گذاری شده برابر است با:

$$\Gamma^+ = V_{(:,1:6)} \Sigma^+ U^\top, \quad (46)$$

که در آن:

• $V_{(:,1:6)} \in \mathbb{R}^{16 \times 6}$ شامل ۶ بردار منفرد اول است،

• $\Sigma^+ = \text{diag}(s_i^{-1}) \in \mathbb{R}^{6 \times 6}$.

نتیجه:

$$\Gamma^+ \in \mathbb{R}^{16 \times 6}. \quad (47)$$

گام چهارم: پروژکتور روی فضای قابل دستیابی

پروژکتور روی زیرفضای نیروی-گشتاور قابل دستیابی به صورت زیر است:

$$P = \Gamma \Gamma^+ = U \text{diag}(\text{keep}) U^\top, \quad (48)$$

که در آن $P \in \mathbb{R}^{6 \times 6}$ عملگر پروجکشن است.

گام پنجم: محاسبه فضای تهی

فضای تهی $\mathcal{N}(\Gamma)$ توسط ۱۰ بردار منفرد آخر V تعریف می شود:

$$N = V_{(:,7:16)} \in \mathbb{R}^{16 \times 10}. \quad (49)$$

نتیجه

در نهایت سه خروجی اصلی داریم:

$$\Gamma^+ \in \mathbb{R}^{16 \times 6} \quad \text{شبه معکوس آستانه گذاری شده}, \quad (50)$$

$$N \in \mathbb{R}^{16 \times 10} \quad \text{پایه ی فضای تهی}, \quad (51)$$

$$P \in \mathbb{R}^{6 \times 6} \quad \text{پروژکتور روی فضای خروجی قابل دستیابی}. \quad (52)$$

۳.۷ الگوریتم CMA-ES (استراتژی تکاملی ماتریس کوواریانس)

در این بخش، منطق ریاضی و مراحل الگوریتم CMA-ES که برای بهینه‌سازی مسائل با ابعاد کوچک (اینجا $N = 10$) پیاده‌سازی شده است، توضیح داده می‌شود. این روش یک الگوریتم جستجوی تصادفی و تطبیقی است که در هر تکرار جمعیتی از نمونه‌ها را تولید کرده و توزیع تولید نمونه‌ها را بر اساس بهترین کاندیداها به‌روز می‌کند.

مرحله‌ی مقداردهی اولیه

فرض کنید نقطه‌ی اولیه $\mathbf{x}_0 \in \mathbb{R}^N$ داده شده باشد. میانگین اولیه و واریانس مقیاس به صورت زیر تعریف می‌شود:

$$\mathbf{x}^{(0)} = \mathbf{x}_0, \quad \sigma^{(0)} = \sigma_0. \quad (53)$$

اندازه‌ی جمعیت (λ) و تعداد والدین (μ) به صورت زیر انتخاب می‌شود:

$$\lambda = 4 + \lfloor 3 \ln(N) \rfloor, \quad \mu = \lfloor \frac{\lambda}{2} \rfloor. \quad (54)$$

وزن‌های انتخاب برای بهترین μ نمونه:

$$w_i = \frac{\ln(\mu + 0.5) - \ln(i)}{\sum_{j=1}^{\mu} (\ln(\mu + 0.5) - \ln(j))}, \quad i = 1, \dots, \mu. \quad (55)$$

مرحله‌ی نمونه‌گیری

در هر تکرار، بردارهای تصادفی زیر تولید می‌شوند:

$$\mathbf{z}_k \sim \mathcal{N}(0, I_N), \quad k = 1, \dots, \lambda. \quad (56)$$

با استفاده از تجزیه‌ی کوواریانس $\mathbf{C} = \mathbf{B}\mathbf{D}^2\mathbf{B}^\top$ ، نمونه‌ها به صورت زیر ساخته می‌شوند:

$$\mathbf{y}_k = \mathbf{B}\mathbf{D}\mathbf{z}_k, \quad \mathbf{x}_k = \mathbf{x}^{(g)} + \sigma^{(g)}\mathbf{y}_k. \quad (57)$$

در اینجا g شماره‌ی نسل است.

مرحله‌ی انتخاب و به‌روزرسانی میانگین

نمونه‌ها بر اساس مقدار تابع هدف مرتب می‌شوند. سپس میانگین وزنی بهترین μ نمونه به عنوان مرکز جدید انتخاب می‌شود:

$$\mathbf{x}^{(g+1)} = \sum_{i=1}^{\mu} w_i \mathbf{x}_{i:\lambda}, \quad (58)$$

که $\mathbf{x}_{i:\lambda}$ نشان‌دهنده‌ی i -امین بهترین نمونه از میان λ نمونه است.

بهروزرسانی مسیرهای تکاملی

بردار مسیرهای انباشته شده برای انطباق مقیاس و کوواریانس به صورت زیر به روز می شوند:

$$\mathbf{p}_\sigma \leftarrow (1 - c_\sigma)\mathbf{p}_\sigma + \sqrt{c_\sigma(2 - c_\sigma)\mu_{\text{eff}}} \mathbf{C}^{-\frac{1}{2}} \frac{\mathbf{x}^{(g+1)} - \mathbf{x}^{(g)}}{\sigma^{(g)}}, \quad (59)$$

$$\mathbf{p}_c \leftarrow (1 - c_c)\mathbf{p}_c + h_\sigma \sqrt{c_c(2 - c_c)\mu_{\text{eff}}} \frac{\mathbf{x}^{(g+1)} - \mathbf{x}^{(g)}}{\sigma^{(g)}}, \quad (60)$$

که در آن h_σ یک شاخص باینری پایداری است.

بهروزرسانی ماتریس کوواریانس

ماتریس کوواریانس بر اساس ترکیبی از حافظه گذشته و پراکندگی نمونه های جدید به روز می شود:

$$\mathbf{C} \leftarrow (1 - c_1 - c_\mu)\mathbf{C} + c_1 (\mathbf{p}_c \mathbf{p}_c^\top + (1 - h_\sigma)c_c(2 - c_c)\mathbf{C}) + c_\mu \sum_{i=1}^{\mu} w_i \mathbf{y}_{i:\lambda} \mathbf{y}_{i:\lambda}^\top. \quad (61)$$

بهروزرسانی انحراف معیار کلی

پارامتر مقیاس σ با استفاده از طول مسیر $\mathbf{p}_\sigma$ به صورت زیر به روز می شود:

$$\sigma^{(g+1)} = \sigma^{(g)} \cdot \exp\left(\frac{c_\sigma}{d_\sigma} \left(\frac{\|\mathbf{p}_\sigma\|}{E\|\mathcal{N}(0, I)\|} - 1\right)\right), \quad (62)$$

که در آن d_σ ضریب میرایی و $E\|\mathcal{N}(0, I)\|$ مقدار میانگین نرم بردار گاوسی است.

خروجی نهایی

الگوریتم پس از چندین تکرار خاتمه یافته و بهترین نمونه ی مشاهده شده به عنوان تقریب جواب بهینه گزارش می شود:

$$\mathbf{x}^* = \arg \min_{\mathbf{x}_k} f(\mathbf{x}_k). \quad (63)$$

۴.۷ توابع هزینه برای آموزش مدل جریان ها

برای بهینه سازی یادگیری جریان های سیم پیچ و تطبیق آن ها با نیروی-گشتاور مطلوب، چندین تابع هزینه تعریف شده اند. در ادامه، هر یک از این توابع به صورت ریاضی آورده می شود.

۱. هموارسازی شبکه‌ی جریان‌ها

برای کاهش تغییرات ناگهانی بین سیم‌پیچ‌های مجاور، هزینه‌ی هموارسازی به صورت اختلاف جریان‌های همسایه در شبکه‌ی 4×4 تعریف می‌شود:

$$\mathcal{L}_{\text{smooth}}(I) = \frac{1}{B} \sum_{b=1}^B \left(\sum_{i=1}^4 \sum_{j=1}^3 |I_{b,i,j+1} - I_{b,i,j}| + \sum_{i=1}^3 \sum_{j=1}^4 |I_{b,i+1,j} - I_{b,i,j}| \right), \quad (64)$$

که در آن $I \in \mathbb{R}^{B \times 16}$ و به شکل شبکه 4×4 بازچینش شده است.

۲. محدودیت دامنه‌ی جریان (hinge)

برای جلوگیری از اشباع جریان‌ها، جریانی که از مقدار مجاز $\pm i_{\max}$ فراتر رود جریمه می‌شود:

$$\mathcal{L}_{\text{hinge}}(I) = \frac{1}{B} \sum_{b=1}^B \sum_{k=1}^{16} \max(0, |I_{b,k}| - i_{\max}), \quad (65)$$

که در اینجا $i_{\max} = 8.0$ است.

۳. کمینه‌سازی پراکندگی **L1** (اسپارسیته)

برای تشویق به استفاده‌ی کمینه از کویل‌ها، نُرم ℓ_1 جریان‌ها به عنوان جریمه افزوده می‌شود:

$$\mathcal{L}_{\text{sparse}}(I) = \frac{1}{B} \sum_{b=1}^B \sum_{k=1}^{16} |I_{b,k}|. \quad (66)$$

۴. خطای میانگین مربعات نیروی-گشتاور

برای انطباق خروجی مدل با بردار نیروی-گشتاور هدف، هزینه‌ی خطای میانگین مربعات تعریف می‌شود:

$$\mathcal{L}_{\text{wrench}}(\hat{\mathbf{w}}, \mathbf{w}) = \frac{1}{B} \sum_{b=1}^B \sum_{j=1}^6 (\hat{w}_{b,j} - w_{b,j})^2, \quad (67)$$

که در آن $\hat{\mathbf{w}} \in \mathbb{R}^6$ خروجی پیش‌بینی‌شده و $\mathbf{w}$ مقدار هدف است.

۵. تابع هزینه کلی

در عمل، تابع هزینه کلی به صورت ترکیبی خطی از اجزای فوق در نظر گرفته می‌شود:

$$\mathcal{L}_{\text{total}} = \lambda_1 \mathcal{L}_{\text{smooth}} + \lambda_2 \mathcal{L}_{\text{hinge}} + \lambda_3 \mathcal{L}_{\text{sparse}} + \lambda_4 \mathcal{L}_{\text{wrench}}, \quad (68)$$

که ضرایب λ_i بر اساس اهمیت هر معیار انتخاب می‌شوند.

۵.۷ مدل Physics-Informed Nullspace Network

این مدل یک شبکه‌ی عصبی یادگیری ماشین است که با استفاده از اطلاعات فیزیکی مربوط به فضای تهی (null space) جریان‌های کوئل را بازسازی کرده و نیروی-گشتاور متناظر را پیش‌بینی می‌کند. ساختار مدل به صورت زیر است:

۱. خروجی فضای تهی

شبکه‌ی عصبی یک بردار $\mathbf{z} \in \mathbb{R}^{10}$ تولید می‌کند که مختصات در فضای تهی است. این بردار از طریق لایه‌های متراکم (Dense) و نرمال‌سازی دسته‌ای (BatchNorm) و در نهایت یک لایه‌ی خروجی با $\tanh$ به دست می‌آید:

$$\mathbf{z} = \tanh(f_{\theta}(\mathbf{x})) \cdot s_z, \quad \mathbf{z} \in \mathbb{R}^{10}, \quad (69)$$

که در آن f_{θ} شبکه‌ی عصبی با پارامترهای θ و s_z یک ضریب مقیاس‌پذیر است.

۲. محاسبه‌ی نگاشت پیش‌سو Γ

برای هر وضعیت $\mathbf{p}$ ، نگاشت پیش‌سو محاسبه می‌شود:

$$\Gamma(\mathbf{p}) \in \mathbb{R}^{6 \times 16}. \quad (70)$$

سپس با استفاده از SVD، شبه‌معکوس و پایه‌ی فضای تهی استخراج می‌گردند:

$$\Gamma^+ \in \mathbb{R}^{16 \times 6}, \quad (71)$$

$$N \in \mathbb{R}^{16 \times 10}, \quad (72)$$

$$P = \Gamma \Gamma^+ \in \mathbb{R}^{6 \times 6}. \quad (73)$$

۳. بازسازی جریان‌ها

جریان‌های سیم‌پیچ به صورت مجموع یک جواب خاص و یک ترکیب خطی از فضای تهی بازسازی می‌شوند:

$$\mathbf{i} = \mathbf{i}_0 + N\mathbf{z}, \quad (74)$$

که در آن:

$$\mathbf{i}_0 = \Gamma^+ \mathbf{w}, \quad \mathbf{w} \in \mathbb{R}^6. \quad (75)$$

$\mathbf{i}_0 \in \mathbb{R}^{16}$ یک جواب با کمترین نرم است و $N\mathbf{z}$ جبران‌کننده در فضای تهی می‌باشد.

۴. پیش‌بینی نیروی-گشتاور

با داشتن جریان بازسازی‌شده، نیروی-گشتاور پیش‌بینی‌شده برابر است با:

$$\hat{\mathbf{w}} = \Gamma \mathbf{i}, \quad \hat{\mathbf{w}} \in \mathbb{R}^6. \quad (۷۶)$$

۵. خروجی نهایی مدل

مدل سه خروجی ارائه می‌دهد:

$$\mathbf{i} \in \mathbb{R}^{16}, \quad \text{جریان‌های کوئل} \quad (۷۷)$$

$$\hat{\mathbf{w}} \in \mathbb{R}^6, \quad \text{نیروی-گشتاور پیش‌بینی‌شده} \quad (۷۸)$$

$$\mathbf{z} \in \mathbb{R}^{10}, \quad \text{مختصات در فضای تهی} \quad (۷۹)$$

۶.۷ فرآیند آموزش مدل Physics-Informed Nullspace Net

در این بخش، مراحل آموزش مدل به صورت گام‌به‌گام تشریح می‌شود تا جریان کلی آن روشن گردد.

۱. بارگذاری و تقسیم داده‌ها

ابتدا داده‌ها از فایل CSV خوانده می‌شوند. هر نمونه شامل:

• بردار وضعیت (۶ بعدی): $(x_m, y_m, z_m, \alpha, \beta, \gamma)$

• بردار نیروی-گشتاور هدف (۶ بعدی): $(F_x, F_y, F_z, T_x, T_y, T_z)$

سپس داده‌ها به سه بخش تقسیم می‌شوند:

$$\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{val}} \cup \mathcal{D}_{\text{test}}, \quad (۸۰)$$

که به ترتیب برای آموزش، اعتبارسنجی و آزمون استفاده می‌شوند.

۲. نرمال‌سازی داده‌ها

برای پایدارسازی آموزش، نرمال‌سازی با استفاده از میانگین و انحراف معیار روی داده‌های آموزشی انجام می‌شود:

$$\tilde{\mathbf{p}} = \frac{\mathbf{p} - \mu_p}{\sigma_p}, \quad (۸۱)$$

$$\tilde{\mathbf{w}} = \frac{\mathbf{w} - \mu_w}{\sigma_w}. \quad (۸۲)$$

ورودی شبکه شامل الحاق وضعیت نرمال‌شده و نیروی-گشتاور نرمال‌شده است:

$$\mathbf{x} = [\tilde{\mathbf{p}}, \tilde{\mathbf{w}}] \in \mathbb{R}^{12}. \quad (۸۳)$$

۳. مدل و بهینه‌ساز

مدل Physics-Informed Nullspace Net تعریف می‌شود که خروجی‌های آن:

$$\mathbf{z} \in \mathbb{R}^{10}, \quad \text{مختصات فضای تهی} \quad (۸۴)$$

$$\mathbf{i} \in \mathbb{R}^{16}, \quad \text{جریان کویل‌ها} \quad (۸۵)$$

$$\hat{\mathbf{w}} \in \mathbb{R}^6, \quad \text{نیروی-گشتاور پیش‌بینی شده} \quad (۸۶)$$

بهینه‌سازی با Adam و نرخ یادگیری $\eta = 10^{-3}$ انجام می‌شود.

۴. تابع هزینه

تابع هزینه‌ی کل ترکیبی از چند جزء است:

$$\mathcal{L} = \lambda_{\text{wrench}} \mathcal{L}_{\text{wrench}} + \lambda_1 \mathcal{L}_1 + \lambda_{\text{smooth}} \mathcal{L}_{\text{smooth}} + \lambda_{\text{mag}} \mathcal{L}_{\text{mag}} + \lambda_{\text{aux}} \mathcal{L}_{\text{aux}}, \quad (۸۷)$$

که در آن:

- $\mathcal{L}_{\text{wrench}}$: خطای MSE بین نیروی-گشتاور پیش‌بینی شده و نیروی هدف پروژکت شده روی زیرفضای قابل دسترسی.
- $\mathcal{L}_1$: جریمه‌ی اسپارسیته (مجموع قدرمطلق جریان‌ها).
- $\mathcal{L}_{\text{smooth}}$: هموارسازی شبکه‌ی جریان (اختلاف بین کویل‌های مجاور).
- $\mathcal{L}_{\text{mag}}$: جریمه برای جریان‌های اشباع شده $|i| > i_{\text{max}}$.
- $\mathcal{L}_{\text{aux}}$: نزدیک‌سازی بردار $\mathbf{z}$ به جواب بهینه‌شده توسط CMA-ES.

۵. استفاده از CMA-ES برای بهبود

به‌طور تصادفی (با احتمال معین)، بخشی از داده‌ها به الگوریتم CMA-ES داده می‌شوند تا بردار $\mathbf{z}$ بهینه‌سازی شود:

$$\mathbf{z}^* = \arg \min_{\mathbf{z}} (\lambda_{\text{smooth}} \mathcal{L}_{\text{smooth}} + \lambda_1 \mathcal{L}_1 + \lambda_{\text{mag}} \mathcal{L}_{\text{mag}}). \quad (۸۸)$$

سپس شبکه جریمه می‌شود تا خروجی $\mathbf{z}$ نزدیک به $\mathbf{z}^*$ باشد:

$$\mathcal{L}_{\text{aux}} = \|\mathbf{z} - \mathbf{z}^*\|^2. \quad (۸۹)$$

۶. حلقه‌ی آموزش

آموزش به‌صورت چندین تکرار (epoch) انجام می‌شود:

۱. محاسبه‌ی خروجی‌های مدل برای هر بچ.

۲. محاسبه‌ی ضرر کل $\mathcal{L}$.

۳. محاسبه‌ی گرادیان‌ها با backpropagation.

۴. به‌روزرسانی وزن‌ها با Adam.

۵. ارزیابی روی مجموعه‌ی اعتبارسنجی.

۷. ذخیره‌سازی و گزارش

در پایان:

- وزن‌های شبکه ذخیره می‌شوند.
- مقیاس‌گذارهای وضعیت و نیروی-گشتاور ذخیره می‌شوند.
- نمودار تاریخچه‌ی آموزش و اعتبارسنجی ترسیم و ذخیره می‌شود.

۸. خروجی نهایی

خروجی فرآیند آموزش شامل موارد زیر است:

(۹۰) (نرمالایزر نیروی-گشتاور، نرمالایزر وضعیت، مدل آموزش‌دیده)

نمونه‌های نتایج شکل ۲۸ تعدادی نمونه از پیش‌بینی‌های مدل را نشان می‌دهد. در هر نمونه:


- نمودار سمت چپ جریان‌های واقعی و جریان‌های پیش‌بینی شده برای ۱۶ کوئل را مقایسه می‌کند.
 - نمودار میانی نیرو-گشتاور هدف و نیرو-گشتاور بازتولیدشده توسط جریان‌های پیش‌بینی شده را نشان می‌دهد.
 - ماتریس جریان‌ها (شبکه‌ی 4×4) الگوی جریان تولیدی مدل را نمایش می‌دهد.
 - نمودار سمت راست خطای مطلق جریان هر کوئل را نشان می‌دهد.
- همان‌طور که مشخص است، هرچند جریان‌ها همیشه دقیقاً با مقادیر واقعی مطابقت ندارند، ولی نیرو-گشتاور نهایی تقریباً به‌طور کامل بازتولید می‌شود.

آمار عملکرد کلی شکل ۲۹ توزیع خطاهای نیرو-گشتاور و خطای جریان‌ها را نشان می‌دهد.

- خطای نیرو-گشتاور بسیار کوچک است (میانگین حدود 0.041) و در بیش از ۹۹٪ موارد تقریباً صفر است.
- خطای جریان‌ها به‌طور متوسط حدود 3.75 آمپر است، که نشان‌دهنده‌ی وجود چندین ترکیب جریان معتبر برای تولید همان نیروی-گشتاور است.
- همبستگی بین خطای نیرو-گشتاور و خطای جریان‌ها ناچیز است، زیرا حتی با جریان‌های متفاوت، خروجی نیرو-گشتاور می‌تواند درست بازتولید شود.




شکل ۲۸: نمونه‌هایی از مقایسه‌ی جریان‌ها و نیرو-گشتاورهای واقعی و پیش‌بینی شده



شکل ۲۹: توزیع خطاهای نیرو-گشتاور و جریان‌ها در مجموعه‌ی آزمون


گزارش تفصیلی عملکرد نتایج کمی مدل در جدول ۲ خلاصه شده‌اند. این نتایج نشان می‌دهند که مدل در بازتولید نیرو-گشتاور به طور کامل موفق است، هرچند جریان‌های تولیدی دقیقاً با مقادیر مرجع برابر نیستند.



شکل ۳۰: خروجی مدل برای نمونه‌ی تکین (نمای دوبعدی میدان نیرو-گشتاور).



Simulated Wrench Output with Saturation



شکل ۳۱: خروجی مدل برای نمونه‌ی تکین (نمای سه‌بعدی میدان نیرو-گشتاور).



همان‌گونه که در تصاویر ۳۰ و ۳۱ مشاهده می‌شود، مدل توانسته است رفتار مرجع را در موقعیت تکین مورد نظر بازتولید کند. هرچند در برخی نواحی مقادیر منفی کوچک به جای صفر ظاهر شده‌اند، اما با توجه به ماهیت نقطه‌ی تکین و این‌که بازتولید دقیق چنین شرایطی ذاتاً غیرممکن است، این میزان خطا قابل قبول تلقی می‌شود. در مجموع، نتایج نشان می‌دهند که مدل یاد گرفته است ساختار کلی رفتار نیرو-گشتاور در این حالت خاص را به درستی پیش‌بینی نماید.

شاخص	میانگین	انحراف معیار	کمینه	بیشینه	میانه
خطای نیرو-گشتاور	۰.۴۱۵۰	۰.۷۲۱۰	۰.۰۰۰۰	۱۸۰۹.۰	۰.۰۰۱۰
MAE جریان‌ها	۷۵۵۸.۳	۶۳۷۱.۰	۴۵۱۲.۲	۶۵۷۲.۴	۸۹۵۱.۳
نرخ موفقیت (< 0.5)	۱۰۰٪				
نرخ موفقیت (< 1.0)	۱۰۰٪				
نرخ موفقیت (< 2.0)	۱۰۰٪				
نرخ موفقیت (< 5.0)	۱۰۰٪				


جدول ۲: آمار تفصیلی عملکرد مدل روی مجموعه‌ی آزمون

۹. مقایسه‌ی نهایی با شبه‌معکوس پایه


در این بخش، مدل پیشنهادی (شبکه‌ی عصبی همراه با نگاشت شبه‌معکوس و پیش‌بینی در فضای تهی) با روش پایه‌ی شبه‌معکوس ساده مقایسه می‌شود. ارزیابی‌ها بر اساس مجموعه‌ای از شاخص‌ها انجام شده و برای هر شاخص هم توزیع داده‌ها و هم مقایسه‌ی میانگین‌ها ارائه شده است. نتایج هر بخش همراه با شکل‌های مربوطه آورده شده‌اند.

۱. هموارسازی جریان‌ها شکل ۳۲ نتایج تحلیل هموارسازی جریان‌ها را نشان می‌دهد. میانگین نمره‌ی هموارسازی در مدل شبکه‌ی عصبی برابر با حدود ۱۱۲ است، در حالی که در روش شبه‌معکوس ساده حدود ۹۸ به دست آمده است. بنابراین شبکه‌ی عصبی جریان‌های «هموارتر» و با تغییرات کمتر تولید می‌کند.

۲. جریمة‌ی بزرگی جریان‌ها (> 8 آمپر) شکل ۳۳ توزیع جریمة‌ی بزرگی جریان‌ها را نشان می‌دهد. میانگین جریمة در شبکه‌ی عصبی حدود ۱.۴۸ است، در حالی که در شبه‌معکوس حدود ۰.۷۳ به دست آمده است. این موضوع نشان می‌دهد شبکه‌ی عصبی موارد بیشتری از عبور جریان‌ها از حد آستانه را تولید می‌کند که از نظر ایمنی محرک‌ها مطلوب نیست.




شکل ۳۲: مقایسه‌ی هموارسازی جریان‌ها بین دوروش




شکل ۳۳: مقایسه‌ی جریمه‌ی بزرگی جریان‌ها ($8 > \text{آمپر}$) بین دوروش

۳. شاخص پراکندگی $L1$ شکل ۳۴ نشان می‌دهد که مقدار میانگین شاخص پراکندگی $L1$ در شبکه‌ی عصبی برابر با حدود ۵۵ و در شبه‌معکوس حدود ۴۳ است. بنابراین شبکه‌ی عصبی تمایل دارد جریان را در میان کوئل‌های بیشتری توزیع کند و از این رو تخصیص‌ها کمتر «تک» هستند.




شکل ۳۴: مقایسه‌ی شاخص پراکندگی $L1$ بین دو روش

۴. خطای **Wrench MSE** همان‌طور که در شکل ۳۵ مشاهده می‌شود، اختلاف خطای MSE بین دو روش بسیار ناچیز و در حد 10^{-3} است. این نشان می‌دهد که هر دو روش از نظر دقت در بازتولید نیرو-گشتاور عملکرد مشابهی دارند.




شکل ۳۵: مقایسه‌ی خطای Wrench MSE بین دو روش

۵. تعداد کویل‌های فعال شکل ۳۶ نشان می‌دهد که هر دو روش به‌طور میانگین از حدود ۱۵ تا ۱۶ کویل استفاده می‌کنند. با این حال، شبکه‌ی عصبی کمی بیشتر (میانگین ۱۵.۶۸ در برابر ۱۵.۵۷) کویل‌ها را فعال می‌کند. بنابراین شبکه‌ی عصبی برای دستیابی به هموارسازی بیشتر، کارایی را قربانی کرده و کویل‌های بیشتری را به کار می‌گیرد.




شکل ۳۶: مقایسه‌ی تعداد کویل‌های فعال بین دو روش

۶. توازن جریان‌ها بر اساس شکل ۳۷، میانگین توازن جریان‌ها در شبه‌معکوس برابر با ۰.۷۹ و در شبکه‌ی عصبی برابر با ۰.۷۲ است. این بدین معناست که شبه‌معکوس جریان‌ها را متوازن‌تر توزیع می‌کند، در حالی که شبکه‌ی عصبی این ویژگی را تا حدی قربانی می‌نماید.




شکل ۳۷: مقایسه‌ی توازن جریان‌ها بین دوروش

۷. پیشینه‌ی جریان‌ها همان‌طور که در شکل ۳۸ مشاهده می‌شود، میانگین پیشینه‌ی جریان‌ها در شبکه‌ی عصبی برابر با حدود ۸.۶ آمپر است، در حالی که در شبه‌معکوس حدود ۷.۳ آمپر است. این موضوع بیانگر آن است که شبکه‌ی عصبی بیشتر به سمت اشباع نزدیک می‌شود و کوپل‌ها را تحت فشار بیشتری قرار می‌دهد.



شکل ۳۸: مقایسه‌ی پیشینه‌ی جریان‌ها بین دو روش

۸. مقایسه‌ی کلی سیاست‌ها در نهایت، شکل ۳۹ نتایج ترکیبی مقایسه‌ی سیاست‌ها را به صورت نمودارهای پراکندگی، هیستوگرام‌ها و تحلیل بازده کوپل‌ها نشان می‌دهد. این تحلیل ترکیبی تأکید می‌کند که سیاست مبتنی بر شبکه‌ی عصبی اگرچه هموارسازی بیشتری دارد و از نظر دقت با شبه‌معکوس قابل مقایسه است، ولی از نظر ایمنی، تنگی و فشار روی کوپل‌ها ضعیف‌تر عمل می‌کند.



شکل ۳۹: مقایسه‌ی کلی سیاست‌های شبکه‌ی عصبی و شبه‌معکوس

جمع‌بندی نهایی

- نقاط قوت شبکه‌ی عصبی: جریان‌های هموارتر، دقت مشابه با شبه‌معکوس در بازتولید نیرو-گشتاور.
 - نقاط ضعف شبکه‌ی عصبی: جریان‌های اوج بالاتر، کاهش تنکی، توازن کمتر در استفاده از کوپل‌ها، افزایش تعداد کوپل‌های فعال.
 - مزیت شبه‌معکوس: ایمن‌تر و کارآمدتر از نظر فشار جریان و توازن کوپل‌ها، هرچند جریان‌ها کمتر هموار هستند.
- به طور کلی، انتخاب بین این دو رویکرد به اولویت‌های مسئله بستگی دارد: اگر هموارسازی و سازگاری یادگیری اهمیت بیشتری داشته باشد، شبکه‌ی عصبی گزینه‌ی مناسبی است. در مقابل، اگر محدودیت‌های سخت‌افزاری، فرسایش، گرمایش یا ایمنی مدنظر باشد، شبه‌معکوس انتخاب برتری خواهد بود.

مراجع

- a of implementation and Design Maglev: "Modular Khamesee, B. M. and Stewart, C. Trakarnchaiyo, C. Xu, Z. [۱]
۲۰۲۴, ۱۰۳۱۴۸ p, ۹۹ vol. Mechatronics, array," Halbach ۲D a levitate to system levitation magnetic modular
- con- kinematics the from obtained robots redundant for Jacobian "Extended Martins, D. and Dias, A. Simas, H. [۲]
۲۰۱۲, ۱۰۱۶-۱۰۰۵ pp, ۵ vol. Mechatronics, in Series Symposium ABCM strains,"
- networks neural using manipulators redundant of kinematics inverse "Real-time Farrokhi, M. and Toshani H. [۳]
۵ no, ۶۲ vol. Systems, Autonomous and Robotics approach," Lyapunov-based A programming: quadratic and
۲۰۱۴, ۷۸۱-۷۶۶ pp.
- frame- learning-based "Machine Kugi, A. and Nguyen, A. Hartl-Nesic, C. Schwegel, M. Beck, F. Vu, N. M. [۴]
Nov. Mechatronics, manipulators," redundant for kinematics inverse analytical the solving optimally for work
۲۰۲۲
- Merzouki, R. and KOM, M. Coelen, V. Lakhal, O. Ahanda, Mvogo B. J. J. Melingui, A. Kouabon, Jiokou G. A. [۵]
Machine and Mechanism manipulators," redundant DOF high of kinematics inverse to framework learning "A
۲۰۲۰, ۱۰۳۹۷۸ p, ۱۵۳ vol. Theory,
- hy- a in redundancy actuator solving "Sub-optimally Sharma, N. and Sun, Z. Munro, P. Mao, Z.-H. Bao, X. [۶]
Intelligent of Journal International structure," network neural multi-layer a with system neuroprosthetic brid
۲۰۱۹, ۳۴۰-۳۲۴ pp, ۳ vol. Applications, and Robotics
- hierarchical with learning reinforcement efficient based space "Null Stoyanov, T. and Stork, A. J. Yang, Q. [۷]
۲۰۲۱ (ECMR), Robots Mobile on Conference European Proc. in constraints," safety
- in robot," surgical flexible a for learning redundancy space "Null Caldwell, G. D. and Calinon, S. Bruno, D. [۸]
۲۰۱۴ (ICRA), Automation and Robotics on Conference International IEEE Proc.